



TECNOLÓGICO NACIONAL DE MÉXICO

INSTITUTO TECNOLÓGICO DE TLÁHUAC

“LA ESENCIA DE LA GRANDEZA RADICA EN LAS RAICES”

TITULACIÓN INTEGRAL POR:

INFORME TÉCNICO

NOMBRE DE LA EMPRESA:

INFOTEC Centro de Investigación e Innovación en Tecnologías de la
Información y Comunicación

TÍTULO DEL PROYECTO:

Diseño e implementación de un contenedor de basura inteligente basado en
Inteligencia Artificial para INFOTEC Centro de Investigación e Innovación en
Tecnologías de la Información y Comunicación.

PARA OBTENER EL TÍTULO DE:

INGENIERO EN SISTEMAS COMPUTACIONALES

P R E S E N T A N :

Alvarado Márquez Francisco Javier

Mejía Gaucín Audrey Melissa

Pérez Juárez Carlos Iván

Soto Chávez José Luis

ASESORES:

Ing. Fabiola Rueda Segundo

Dr. Juan Antonio Vega Garfias



Tláhuac, Ciudad de México, febrero 2026.

ANEXO XXII

ANEXO III

Agradecimientos

Francisco Javier Alvarado Marquez

A lo largo de mi vida he comprendido que soy distinto, que hay algo en mí que me hace brillar de una manera particular. Incluso al crecer junto a mi hermano, recorriendo etapas al mismo tiempo, siempre sentí que mi forma de ser y de ver el mundo era diferente.

Durante mucho tiempo pensé que quizá nunca llegaría lejos, que esa diferencia sería un obstáculo y no una fortaleza. Sin embargo, hoy agradezco profundamente a todo aquello que me impulsó cuando ya no me quedaban fuerzas. A la fortaleza que me enseñaron mi papá, mi mamá, mi hermano y mis amigos; sin su apoyo, nada de esto habría sido posible.

Agradezco, en primer lugar, a mí mismo, por no rendirme incluso en los momentos en los que dudé de mis capacidades y del sentido del camino. Este trabajo es resultado de la constancia, el esfuerzo y la decisión de seguir adelante aun cuando el proceso no fue sencillo.

A mi familia nuclear, por el apoyo brindado a lo largo de esta etapa, por su paciencia y por estar presentes de distintas formas durante mi formación académica y personal.

A mis profesores, por los conocimientos compartidos, la guía constante y las observaciones que contribuyeron tanto al desarrollo de este proyecto como a mi crecimiento académico y profesional.

A mis mejores amigos, Daniel, Cesar, Martin, Axel y Javier por el aprendizaje compartido, el apoyo mutuo y los momentos que hicieron más llevadero este proceso.

Finalmente, agradezco a todas las experiencias tanto las favorables como las difíciles que me permitieron aprender, madurar y avanzar hacia la siguiente etapa de mi vida profesional.

Este trabajo es una prueba de lo capaz que soy; de que, más allá de cualquier dificultad, mi mayor fortaleza ha sido jamás rendirme. Soy capaz de muchísimas cosas, incluso cuando el camino ha estado lleno de obstáculos.

Quiero concluir con una frase que ha definido mi vida desde que era niño:

“Si un perdedor hace muchos esfuerzos, quizá pueda sobrepasar el poder de un guerrero distinguido.”

Audrey Melissa Mejía Gaucín.

A Dios, por darme la bendición de poder estar aquí, a mis padres Irack Mejía Fonseca y María Guadalupe Gaucín Villanueva, gracias por pausar sus sueños para hacer realidad los míos, por todo el apoyo, consejos, por ser los mejores papás para mí, a mis hermanas Ingrid y Katia, quiénes han sido mi inspiración para poder dar lo todo de mí y tratar de ser un buen ejemplo.

Durante este proceso también tengo agradecimientos especiales, quiénes me acompañaron durante el proceso no solo universitario, si no también durante toda mi vida, mis abuelos quiénes siempre estuvieron para un consejo, un abrazo, una bendición y un chiste para reírme cuando la carrera parecía difícil, es para mí un honor que ellos 4 me puedan acompañar en este gran logro, nuestro logro y los que faltan.

A mis amigos y compañeros de un mismo sueño, Jonathan, Santiago, Hydrocell que, con estrés, pequeñas discusiones (casi nulas), llegamos a lo más alto juntos. Gracias por todas aquellas experiencias, por hacer de un proyecto, una experiencia inolvidable y un gran final de mi vida estudiantil. A la Licenciada Karen que me ayudó a convertirme en una mejor versión y confió siempre en mí.

Gracias a mí misma por ser tan fuerte estos últimos 5 años y ser la persona tan grandiosa que soy, estoy orgullosa de mí.

Carlos Iván Pérez Juárez

Dedico este trabajo a mi familia. Gracias por haberme dado la oportunidad de estudiar y por apoyarme en cada decisión. Su confianza ha sido mi mayor motor para no rendirme.

A mi pareja, Joselyn, por su comprensión y apoyo constante. Gracias por celebrar mis victorias y ayudarme a levantarme en los momentos difíciles. Tu presencia ha sido clave para culminar esta etapa.

Finalmente, quiero agradecer a mis profesores por su tiempo y enseñanzas, a mis compañeros de equipo por el apoyo mutuo durante estos meses de estudio y trabajo, y por último a mi mejor amiga por haber estado a mi lado durante el trayecto de mi estudio y su apoyo.

José Luis Soto Chávez

A Dios, por darme la oportunidad de llegar hasta este momento, por la fortaleza, la paciencia y la guía necesarias para culminar una de las etapas más importantes de mi vida.

A mis padres, José Luis Soto Castellanos y Silvia Chávez Ponce, por su amor incondicional, apoyo constante y sacrificio a lo largo de todos estos años. Gracias por creer en mí, por sus consejos y por ser el pilar que me impulsó a seguir adelante incluso en los momentos más difíciles.

A mis hermanos, Silvia Susana Soto Chávez y Rebeca Soto Chávez, por su apoyo, compañía y motivación constante. Y de manera muy especial, a mi hermano Armando Soto Chávez, quien hoy se encuentra en el cielo, pero siempre presente en mi vida. Gracias por ayudarme a ser una mejor persona, por enseñarme el verdadero significado del amor, la empatía y la fortaleza, y por ser una inspiración permanente en cada paso que doy. Este logro también es para ti.

A mis docentes y asesores, por compartir sus conocimientos, experiencia y orientación durante mi formación académica, contribuyendo de manera significativa a mi crecimiento profesional y personal.

A mis compañeros y amigos, por el apoyo, los aprendizajes compartidos y los momentos que hicieron este camino más llevadero. De manera especial, agradezco a Montserrat Martínez, por su amistad, apoyo incondicional, palabras de aliento y por acompañarme en los momentos más importantes de este proceso académico y personal.

Finalmente, me agradezco a mí mismo por la perseverancia, el esfuerzo y la determinación demostrados a lo largo de este camino, por no rendirme ante las dificultades y por haber llegado hasta aquí con orgullo, aprendizaje y crecimiento personal.

Resumen

En México, la adecuada gestión y clasificación de desechos se considera un reto importante, el cual tiene un impacto directo en la eficacia del reciclaje y en el medio ambiente. Hoy en día, la mayoría de los residuos sólidos urbanos no son separados correctamente, lo que reduce su uso y sea propenso a generar más contaminación. En respuesta a esta problemática, se hace necesario desarrollar soluciones tecnológicas que ayuden a gestionar los residuos de una manera más eficaz y sostenible.

El propósito de este proyecto es crear un sistema automatizado que, a través de la inteligencia artificial, logre distinguir y clasificar desperdicios orgánicos e inorgánicos, aumentando así la rapidez y exactitud en esta labor diaria. Con este fin, se creó y puso en marcha un prototipo que emplea un microcontrolador, sensor ultrasónico para identificar objetos y un servomotor para el aislamiento físico de los residuos. Además, se incorporó una pantalla que muestra el historial de clasificaciones en tiempo real, lo que proporciona una interfaz informativa y útil.

El proyecto fue llevado a cabo en INFOTEC, que es el Centro de Investigación e Innovación en Tecnologías de la Información y Comunicación. Esta es una entidad pública del Gobierno Federal Mexicano, cuyo propósito es promover la transformación digital de la nación a través de la investigación, la innovación, el desarrollo de soluciones tecnológicas y la formación académica. En este marco, el trabajo actual se sitúa en las esferas de aplicación de las TIC con miras a la sustentabilidad urbana y al bienestar medioambiental.

SCRUM, un marco ágil que posibilitó la organización del trabajo en sprints (fases iterativas y controladas de desarrollo), fue el método utilizado para desarrollar el sistema. Esto promovió la colaboración, la adaptación a las modificaciones y la entrega constante de resultados útiles. Esta metodología posibilitó que la creación del software y hardware se unieran eficazmente.

Los resultados preliminares indican que el sistema alcanzó un 82 % de confianza en la clasificación exitosa de materiales, evidenciando un desempeño eficiente en los procesos de detección. Asimismo, se observó un flujo de comunicación y procesamiento adecuado entre los distintos componentes del sistema, lo que contribuye a su correcto funcionamiento.

En general, el proyecto ayuda a promover prácticas tecnológicas sostenibles y a desarrollar soluciones novedosas en el área de gestión inteligente de desechos en México.

Palabras clave: Gestión de residuos, clasificación automatizada, inteligencia artificial, aprendizaje profundo, microcontroladores, ESP32, sensor ultrasónico, servomotor, pantalla TFT, SCRUM, TIC

Abstract

In Mexico, the proper management and classification of waste represent a significant challenge, directly impacting recycling efficiency and environmental sustainability. Currently, most municipal solid waste is not adequately separated, which limits its reuse and increases pollution levels. In response to this issue, this project proposes the development of a technological solution aimed at improving waste management through automation and artificial intelligence.

The objective of this project is to design and implement an automated system capable of distinguishing and classifying organic and inorganic waste using artificial intelligence, thereby increasing the speed and accuracy of this daily task. To achieve this, a functional prototype was developed that integrates a microcontroller, an ultrasonic sensor for object detection, and a servomotor for the physical separation of waste. Additionally, a display was incorporated to show real-time classification history, providing an informative and user-friendly interface.

The project was carried out at INFOTEC, the Research and Innovation Center for Information and Communication Technologies, a Mexican federal public institution focused on promoting national digital transformation through research, innovation, technological development, and academic training. Within this context, the project contributes to the application of ICTs for urban sustainability and environmental well-being.

The SCRUM agile framework was employed to guide the development process, organizing the work into iterative and controlled sprints. This methodology fostered collaboration, adaptability to changes, and continuous delivery of functional results, enabling effective integration of both software and hardware components.

Preliminary results indicate that the system achieved an 82% confidence level in successful material classification, demonstrating efficient detection performance. Furthermore, adequate communication and processing flow among system components were observed, contributing to its overall reliability. Overall, this project promotes sustainable technological practices and presents an innovative approach to intelligent waste management solutions in Mexico.

Keywords: Waste management, automated sorting, artificial intelligence, deep learning, microcontrollers, ESP32, ultrasonic sensor, servomotor, TFT display, SCRUM, ICT

Contenido

Agradecimientos	I
Resumen	IV
Abstract	V
Contenido	VI
Índice de Figuras	IX
Índice de Tablas.....	XI
Índice de Acrónimos.....	XII
Índice de Siglas.....	XIII
Introducción	1
Generalidades	2
2.1 Planteamiento del problema.....	2
2.2 Objetivos	3
2.2.1 Objetivo general	3
2.2.2 Objetivos específicos	3
2.3 Justificación.....	4
2.4 Caracterización de la empresa en la que participo.....	5
2.4.1 Datos generales de la empresa.....	5
2.4.2 Descripción del departamento o área de trabajo	7
2.5 Problemas a resolver	7
2.6 Alcances y limitaciones.....	8
2.6.1 Alcances	8
2.6.2 Limitaciones	9
Marco teórico.....	10
3.1 Investigaciones previas.....	10
3.1.1 Proyectos académicos e investigativos en México	10
3.1.2 Innovaciones tecnológicas e industriales	10
3.2 Bases teóricas	12
3.2.1 Sistemas embebidos y microcontroladores	12
3.2.2 Sensores de proximidad	12
3.2.3 Actuadores electromecánicos.....	12
3.2.4 Visualización de información mediante pantallas oled	13
3.2.5 Inteligencia artificial y aprendizaje automático.....	13
3.2.6 Visión por computadora.....	13

3.2.7 Clasificación de imágenes mediante inteligencia artificial.....	13
3.2.8 Comunicación cliente-servidor y APIs REST	14
3.3 Antecedentes	15
3.3.1 Contexto general del problema.....	15
3.3.2 Evolución de la clasificación de residuos	16
3.3.3 Problemática de clasificación de residuos.....	17
3.3.4 Avances tecnológicos en clasificación y automatización de residuos	18
3.3.5 Proyectos y aplicaciones específicas.....	19
3.4 Enfoque metodológico del proyecto	20
3.4.1 Importancia del proyecto en el contexto actual.....	20
3.5 ¿Qué es una metodología de desarrollo?.....	21
3.5.1 Metodologías de desarrollo tradicionales	21
3.5.2 Metodologías de desarrollo ágiles.....	22
3.5.3 Comparación tradicional vs ágil	23
3.5.4 Metodología SCRUM	24
3.5.5 Metodología SCRUM aplicada al desarrollo del proyecto	24
Desarrollo	25
4.1 Entrevistas y Análisis de Requerimientos.....	26
4.1.1 Aspectos generales del código.	28
4.1.2 Hardware a utilizar.....	29
4.2 Planificación y Ejecución de la Metodología Scrum.	32
4.2.1 Construcción del servidor.	33
4.2.2 Implementación del sistema mecánico.	34
4.2.3 Integración del ESP32 con el backend mediante un endpoint.....	36
4.2.4 Elección del dataset y entrenamiento del modelo de IA.....	37
4.3 Diseño de la Arquitectura del Sistema.	39
4.3.1 Módulo C++: Esp32ToPythonOledHttpCAM.ino.	39
4.3.2 Módulo Python: appHTTP.py.	55
4.3.3 Módulo Python: pruebaModelosTF.py.	63
4.3.4 Módulo Python: ManejadorHTTP.py.....	67
4.4 Diseño del Modelo de Inteligencia Artificial	74
4.4.1 Elección de arquitectura de inteligencia artificial.	74
4.4.2 Selección y evolución del dataset.....	74
4.4.3 Estrategia y procesamiento del conjunto de datos.....	76
4.4.4 Scripts de procesamiento	78
4.4.5 Scripts de entrenamiento	81
4.5 Ensamblaje e integración del sistema embebido.	93
4.5.1 Conexión eléctrica y lógica del sistema	93

4.5.2 Distribución física de los componentes.....	94
4.5.3 Render en 3D del producto final para producción	99
Pruebas y resultados	104
5.1 Explicación de pruebas realizadas	105
5.1.1 Pruebas Unitarias por Módulo: Hardware	105
5.1.2 Pruebas Unitarias por Módulo: Software	106
5.2 Evaluación de las pruebas realizadas	106
5.2.1 Prueba Hardware	106
5.2.2 Pruebas del Servidor y Arquitectura Backend	111
5.2.3 Pruebas de Rutas (API REST)	112
5.2.4 Prueba Modelo de Inteligencia Artificial	115
5.3 Prueba de prototipo en tiempo real.....	128
5.3.1 Escenario 1: Inicialización del sistema.....	128
5.3.2 Escenario 2: Objeto detectado sin confianza suficiente.....	135
5.3.3 Escenario 3: Objeto detectado no biodegradable.....	137
5.3.4 Escenario 4: Objeto detectado biodegradable.....	139
5.4 Resultados finales.....	141
Conclusiones.....	143
Glosario	146
Referencias	151

Índice de Figuras

<i>Ilustración 1 Ubicación de INFOTEC.</i>	6
<i>Ilustración 2 Servomotor MG90S.</i>	29
<i>Ilustración 3 Sensor ultrasónico HC-SR04.</i>	29
<i>Ilustración 4 ESP32-S3 N16R8.</i>	30
<i>Ilustración 5 Pantalla oled 128x64 i2c.</i>	31
<i>Ilustración 6 Cámara esp32 OV2640.</i>	31
<i>Ilustración 7 Diagrama de clases esp32.</i>	43
<i>Ilustración 8 Diagrama secuencia de esp32 y servidor.</i>	51
<i>Ilustración 9 Diagrama de flujo del loop esp32.</i>	52
<i>Ilustración 10 Diagrama secuencia Long Polling.</i>	59
<i>Ilustración 11 Diagrama de clases Python.</i>	62
<i>Ilustración 12 Diagrama de flujo AcomodoDataset.</i>	79
<i>Ilustración 13 Diagrama de flujo AcomodoDatasetTestTrain.</i>	80
<i>Ilustración 14 Código entrenamiento RestNet-50.</i>	86
<i>Ilustración 15 Código entrenamiento MobileNetV2.</i>	89
<i>Ilustración 16 Consola de entrenamiento FT.</i>	92
<i>Ilustración 17 Diagrama de electrónico.</i>	94
<i>Ilustración 18 ESP32 S3 Cam ubicación.</i>	95
<i>Ilustración 19 Iluminación prototipo.</i>	96
<i>Ilustración 20 Cableado y protoboard prototipo.</i>	97
<i>Ilustración 21 Sensor ultrasónico frente al prototipo.</i>	98
<i>Ilustración 22 Pantalla Oled en el prototipo.</i>	98
<i>Ilustración 23 Servomotor en el prototipo y conexión a la tapa.</i>	99
<i>Ilustración 24 Modelo 3D construcción inicial.</i>	100
<i>Ilustración 25 Modelado en tres posiciones.</i>	101
<i>Ilustración 26 Modelo 3D finalizado versión manufacturable.</i>	102
<i>Ilustración 27 Visión interna del modelo 3D.</i>	103
<i>Ilustración 28 Prueba servomotor.</i>	107
<i>Ilustración 29 Prueba sensor.</i>	108
<i>Ilustración 30 Prueba pantalla oled.</i>	109
<i>Ilustración 31 Prueba cámara.</i>	110
<i>Ilustración 32 Matriz de confusión de ResNet50.</i>	116
<i>Ilustración 33 Prueba real ResNet50.</i>	117
<i>Ilustración 34 Curva ROC de ResNet50.</i>	117
<i>Ilustración 35 Matriz de confusión de MobileNetV2 primera iteración.</i>	119
<i>Ilustración 36 Prueba real MobileNetV2 primera iteración.</i>	120
<i>Ilustración 37 Curva Roc MobileNetV2 primera iteración.</i>	120
<i>Ilustración 38 Matriz de confusión de MobileNetV2 segunda iteración.</i>	122
<i>Ilustración 39 Prueba real MobileNetV2 segunda iteración.</i>	123
<i>Ilustración 40 Curva Roc MobileNetV2 segunda iteración.</i>	123
<i>Ilustración 41 Matriz de confusión de MobileNetV2 tercera iteración.</i>	125
<i>Ilustración 42 Prueba real MobileNetV2 tercera iteración.</i>	126
<i>Ilustración 43 Curva Roc MobileNetV2 tercera iteración.</i>	126
<i>Ilustración 44 Fase de inicialización de pantalla correcta.</i>	128
<i>Ilustración 45 Fase de inicialización de servomotor correcta.</i>	129
<i>Ilustración 46 Inicialización cámara.</i>	130
<i>Ilustración 47 Fase de inicialización de cámara correcta.</i>	131
<i>Ilustración 48 Conectando WIFI.</i>	132

<i>Ilustración 49 Fase de inicialización de WIFI correcta.....</i>	<i>133</i>
<i>Ilustración 50 Sistema inicializado correcto.</i>	<i>134</i>
<i>Ilustración 51 Notificación objeto detectado.....</i>	<i>135</i>
<i>Ilustración 52 Confianza insuficiente mensaje del servidor.</i>	<i>136</i>
<i>Ilustración 53 Notificación objeto detectado no-bio.</i>	<i>137</i>
<i>Ilustración 54 Mensaje de confirmación no-bio.</i>	<i>138</i>
<i>Ilustración 55 Notificación objeto detectado bio.</i>	<i>139</i>
<i>Ilustración 56 Mensaje de confirmación bio.....</i>	<i>140</i>

Índice de Tablas

Tabla 1 Comparación tradicional vs ágil.....	23
Tabla 2 Nombre de instancias	28
Tabla 3 Cronograma de actividades.....	32
Tabla 4 Construcción del Servidor Flask.....	34
Tabla 5 Implementación del sistema mecánico.....	35
Tabla 6 Integración del ESP32 con el backend mediante un endpoint.	37
Tabla 7 Elección del dataset y entrenamiento del modelo de IA.	39
Tabla 8 Definición de variables iniciales ESP32.	41
Tabla 9 Atributos del setup del microcontrolador.....	42
Tabla 10 Funcionalidad de Esp32ToPythonOledHttpCAM.....	54
Tabla 11 Definición de variables iniciales appHTTP.....	56
Tabla 12 Resumen funcionalidad main.....	61
Tabla 13 Atributos del constructo de “pruebaModelosIATF”.	64
Tabla 14 Funcionalidad de pruebaModelosTF.	66
Tabla 15 Atributos del constructo de “manejadorHTTP”.	68
Tabla 16 Significado códigos http.....	69
Tabla 17 Funcionalidad: ManejadorHTTP.	73
Tabla 18 Tabla de Conexiones.	93
Tabla 19 Resultados servomotor.....	107
Tabla 20 Resultados sensor	108
Tabla 21 Resultados pantalla oled	109
Tabla 22 Resultados cámara	110
Tabla 23 Métricas de los modelos de IA.	115

Índice de Acrónimos

Acrónimo	Significado
CONACYT	Consejo Nacional de Ciencia y Tecnología Organismo público de México encargado de promover y financiar actividades relacionadas con la investigación científica, el desarrollo tecnológico y la innovación.
SEDEMA	Secretaría del Medio Ambiente de la Ciudad de México Institución local encargada de diseñar e implementar políticas ambientales en la Ciudad de México, incluyendo la gestión de residuos sólidos y la mitigación de la contaminación.
SEMARNAT	Secretaría de Medio Ambiente y Recursos Naturales Institución local encargada de diseñar e implementar políticas ambientales en la Ciudad de México, incluyendo la gestión de residuos sólidos y la mitigación de la contaminación.
INFOTEC	Centro de Investigación e Innovación en Tecnologías de la Información y Comunicación Es un centro público de investigación en México, especializado en el desarrollo e innovación de productos y servicios tecnológicos.
YOLO	You Only Look Once (Solo miras una vez) Es un algoritmo de visión por computadora diseñado para la detección de objetos en tiempo real. Se analiza una imagen completa en una sola pasada para identificar y localizar múltiples objetos simultáneamente.
OpenCV	Open Source Computer Vision Library (Biblioteca de visión artificial de código abierto) Librería de visión por computadora de código abierto ampliamente utilizada para el procesamiento de imágenes y videos.

Índice de Siglas

Sigla	Significado
IA	Inteligencia Artificial Rama de la informática que desarrolla sistemas capaces de realizar tareas que normalmente requieren de la inteligencia humana, como el reconocimiento de patrones, la toma de decisiones o el aprendizaje a partir de datos.
HTTP	HyperText Transfer Protocol. Protocolo de comunicación utilizado para la transferencia de información en la web entre clientes y servidores.
IoT	Internet Of Things (Internet de las Cosas.) Paradigma tecnológico que conecta objetos físicos cotidianos a internet, permitiendo la recolección y el intercambio de datos en tiempo real para mejorar procesos y servicios.
TFT	Thin Film Transistor (Transistor de película delgada) Tecnología de pantalla basada en transistores de película delgada, utilizada en monitores y dispositivos portátiles como la pantalla ILI9341, que ofrece buena resolución y bajo consumo.
TIC	Tecnologías de la Información y la Comunicación Conjunto de recursos, herramientas y sistemas tecnológicos que permiten gestionar, procesar, almacenar y transmitir información, como computadoras, redes e internet.
ESP32	ESPRESSIF 32 bits Es un microcontrolador de bajo costo y bajo consumo de energía, diseñados por la empresa Espressif Systems. Se le conoce técnicamente como un SoC (System on a Chip), lo que significa que en un solo chip integra procesador, memoria y módulos de comunicación.

Capítulo 1

Introducción

La creciente generación de residuos sólidos urbanos constituye uno de los retos más apremiantes ambientales. El manejo inadecuado de estos residuos provoca impactos negativos significativos en el medio ambiente, tales como la contaminación del suelo, del agua y del aire, además de obstaculizar los procesos de reciclaje y valorización de materiales. En la mayoría de los casos, la separación de la basura depende del conocimiento, la conciencia y la voluntad de las personas, lo que deriva en errores frecuentes de clasificación y, en consecuencia, en una reducción considerable de la eficiencia de los sistemas de tratamiento y aprovechamiento de residuos.

Ante este panorama, el avance tecnológico se presenta como una alternativa viable para mejorar la gestión de los residuos. En particular, la inteligencia artificial y la visión por computadora han demostrado un gran potencial para automatizar tareas que tradicionalmente han dependido de la intervención humana, permitiendo incrementar la precisión, rapidez y confiabilidad de diversos procesos. La aplicación de estas tecnologías en el ámbito ambiental abre nuevas oportunidades para optimizar la separación de residuos y fomentar prácticas sustentables.

El presente trabajo se centra en el desarrollo de un prototipo que integra un modelo de inteligencia artificial, un microcontrolador encargado de la adquisición y el procesamiento de datos, así como una interfaz gráfica que permite la visualización inmediata de los resultados obtenidos. El objetivo principal es establecer una base tecnológica que facilite la implementación de soluciones escalables, contribuyendo así a la optimización de la gestión de residuos y a la promoción de prácticas sustentables mediante el uso de herramientas actuales.

El presente documento se organiza de la siguiente manera: en el Capítulo 2 se presentan las generalidades del proyecto, así como información general del mismo. El Capítulo 3 corresponde al marco teórico, en el cual se analizan investigaciones previas, las bases teóricas relacionadas, además de los antecedentes del problema y el enfoque metodológico empleado para el desarrollo. En el Capítulo 4 se detalla el desarrollo del sistema. Posteriormente, el Capítulo 5 presenta las pruebas realizadas al prototipo, abarcando pruebas unitarias de hardware y software, la evaluación del desempeño del sistema, las pruebas del modelo de inteligencia artificial y los resultados obtenidos en condiciones reales de operación. Finalmente, el Capítulo 6 expone las conclusiones del trabajo, destacando los resultados alcanzados, las aportaciones del proyecto y las posibles líneas de mejora y desarrollo futuro.

Capítulo 2

Generalidades

2.1 Planteamiento del problema

La producción de residuos sólidos es un problema fundamental tanto ambiental como social a escala global. La ausencia de una cultura de separación, el aumento demográfico y la alta demanda de productos han llevado a un aumento considerable en el número de desechos que terminan en basurales a cielo abierto y rellenos sanitarios. Si estos desechos se clasificaran adecuadamente desde su origen, una gran parte de ellos podrían reciclarse o reutilizarse.

En numerosas comunidades, la separación de residuos continúa realizándose de manera manual por parte de usuarios o trabajadores del sector, lo que conlleva diversas problemáticas. Entre ellas se destacan los errores humanos en la clasificación, la exposición directa a materiales peligrosos, la lentitud de los procesos y la baja motivación para llevar a cabo esta actividad de forma correcta. Estas limitaciones afectan directamente la eficiencia de los sistemas de recolección y reciclaje, así como la sostenibilidad de la gestión de residuos.

Ante este panorama, resulta necesario el desarrollo e implementación de soluciones tecnológicas innovadoras que permitan optimizar y automatizar el proceso de clasificación de residuos sólidos. En este sentido, el uso de dispositivos de bajo costo combinados con técnicas de inteligencia artificial representa una alternativa viable para el diseño de sistemas capaces de detectar y clasificar residuos en tiempo real, incrementando la precisión y eficiencia del proceso.

Asimismo, es fundamental promover iniciativas que atiendan la necesidad de mejorar la seguridad, confiabilidad y efectividad en la gestión de residuos. La carencia de mecanismos accesibles y eficientes que faciliten la separación adecuada en el punto de disposición final limita el alcance de las estrategias de reciclaje y reutilización, especialmente en contextos con recursos económicos y capacitación técnica limitados.

Este proyecto enfocado en esta problemática busca reducir la dependencia de procesos manuales, disminuir los riesgos para las personas involucradas y fortalecer la cultura de clasificación correcta de los residuos. De esta manera, se contribuye a optimizar la cadena de manejo de desechos, incrementar las tasas de aprovechamiento de materiales y generar un impacto positivo tanto ambiental como social, respondiendo a una necesidad real y creciente en la gestión sostenible de residuos.

2.2 Objetivos

2.2.1 Objetivo general

Diseñar y desarrollar un sistema que permita identificar y clasificar distintos tipos de residuos mediante inteligencia artificial, para optimizar la gestión de basura, reducir errores de separación y contribuir a la sostenibilidad ambiental en INFOTEC Centro de Investigación e Innovación en Tecnologías de la Información y Comunicación.

2.2.2 Objetivos específicos

Investigación y Análisis Técnico:

- Investigar las herramientas y tecnologías disponibles para desarrollar un sistema eficiente de clasificación de basura, asegurando una base técnica sólida que permita un diseño confiable.
- Evaluar diferentes opciones de materiales y métodos para seleccionar la alternativa más efectiva en términos de calidad, costo y funcionamiento, optimizando los recursos del proyecto.

Planificación y Gestión del Proyecto:

- Establecer prioridades en la construcción del prototipo, la implementación del software y la integración del hardware para asegurar una ejecución eficiente.
- Definir un plan de trabajo estructurado mediante la metodología ágil SCRUM, estableciendo sprints de desarrollo que permitan avanzar de forma iterativa y controlada en las distintas etapas del proyecto.

Diseño y Arquitectura del Sistema:

- Diseñar el modelo 3D del sistema para definir su estructura y funcionamiento, optimizando la disposición del hardware y la lógica de operación para un rendimiento eficiente.
- Definir la arquitectura del software y su integración con el hardware, asegurando la compatibilidad entre componentes para un funcionamiento estable y escalable.

Implementación e Integración:

- Ensamblar los componentes electrónicos necesarios para el funcionamiento del sistema de clasificación de residuos, garantizando robustez y operatividad.

- Implementar el software de reconocimiento de imágenes con inteligencia artificial y programar el microcontrolador con el objetivo de lograr una clasificación automática y precisa.

Pruebas y Validación:

- Realizar pruebas de funcionamiento del sistema para verificar la precisión del modelo de IA y la respuesta del hardware ante los tipos de residuos, validando la efectividad de la solución.

2.3 Justificación

Durante nuestra formación en la carrera de Ingeniería en Sistemas Computacionales, adquirimos las bases teóricas y prácticas necesarias para la creación de un sistema aplicando herramientas modernas. Estas capacidades nos han permitido identificar y abordar una problemática crítica: la ineficiente gestión de residuos, causada por la dificultad de clasificar la basura de manera correcta. Los métodos de separación actuales son manuales, lo que los hace imprecisos y lentos, limitando la recuperación de materiales valiosos. Esta situación es alarmante, ya que solo el 5% de los residuos se separa adecuadamente en la fuente. Por lo tanto, el desarrollo de un sistema automatizado para la clasificación de residuos se vuelve fundamental. Este proyecto se justifica por la necesidad de optimizar los procesos de reciclaje, fomentar prácticas más sostenibles y mejorar la gestión de desechos, aprovechando los conocimientos adquiridos y los recursos proporcionados por INFOTEC Centro De Investigación e Innovación en Tecnologías de la Información y Comunicación, para ofrecer una solución tecnológica a este desafío ambiental y social.

2.4 Caracterización de la empresa en la que participo

La residencia profesional se llevará a cabo en las instalaciones de INFOTEC Centro de Investigación e Innovación en Tecnologías de la Información y Comunicación, específicamente en la planta baja dentro del área de la biblioteca. Este espacio cuenta con recursos bibliográficos especializados en inteligencia artificial y programación general, brindando un entorno adecuado para el desarrollo del proyecto.

2.4.1 Datos generales de la empresa

Nombre: INFOTEC Centro de Investigación e Innovación en Tecnologías de la Información y Comunicación.

Domicilio: Av. San Fernando 37, Toriello Guerra, Tlalpan, 14050, Ciudad de México.

Teléfono: 55 5624 2800.

Titular de la empresa: Dr. Juan Mario Beltrán Valle, Director Adjunto de Administración.

Actividades que realiza:

Centro Público de Investigación del Gobierno Federal, contribuye a la Transformación Digital de México, a través de la investigación, la innovación, la formación académica y el desarrollo de productos y servicios TIC. Sus alcances abarcan al sector público y privado, habilitando caminos que conduzcan hacia un México moderno y de inclusión digital. [1]

Misión

Contribuir a la transformación digital de México, a través de la investigación, la innovación, la formación académica y el desarrollo de productos y servicios TIC.

Visión

Ser un Centro Público de Investigación que habilite los caminos que conduzcan hacia un México Moderno y de Inclusión Digital, a través de su presencia en los sectores público y privado.

Valores

Colaboración: Es la capacidad que tenemos de sumar nuestro talento dentro y fuera de la organización, y una excelente forma de crear añadir valor.

Innovación: Como valor de nuestra organización es la capacidad de idear, diseñar, experimentar y construir nuevas prácticas, procesos, productos y estructuras capaces de crear valor e implantar con éxito soluciones a retos.

2.4.2 Descripción del departamento o área de trabajo

- Nombre del departamento: Biblioteca.
- Descripción del área en que se participó: Este espacio cuenta con recursos bibliográficos especializados en inteligencia artificial y programación general, brindando un entorno adecuado para el desarrollo del proyecto.

2.5 Problemas a resolver

La problemática que da origen al presente proyecto surge de la falta de infraestructura tecnológica que permita clasificar los residuos de manera rápida, eficaz y confiable, lo cual limita la correcta gestión de los desechos. Actualmente, la separación de residuos depende en gran medida del criterio humano, lo que introduce errores frecuentes, baja eficiencia y una recuperación limitada de materiales reutilizables. Esta situación evidencia la necesidad de desarrollar un sistema tecnológico accesible que integre herramientas modernas para mejorar la precisión y confiabilidad del proceso de clasificación.

Uno de los principales problemas a resolver dentro del proyecto y del equipo de trabajo son las dificultades en la comunicación y coordinación durante el desarrollo del proyecto. Mantener una comunicación efectiva entre los integrantes resulta fundamental para lograr una adecuada asignación de tareas, una correcta toma de decisiones técnicas y una resolución oportuna de los problemas que surgen en las distintas etapas del desarrollo.

Otro reto relevante es la curva de aprendizaje es asociada a las tecnologías empleadas. En particular, el uso y entrenamiento de modelos de inteligencia artificial requiere la comprensión de conceptos avanzados, así como el manejo adecuado de datos y herramientas especializadas. De manera similar, el desarrollo sobre el microcontrolador ESP32 y el uso de módulos implican un proceso de adaptación técnica, especialmente en lo referente a la programación en lenguaje C++ y al control de periféricos y comunicaciones.

Asimismo, se presenta el desafío de gestionar un servidor para el procesamiento, almacenamiento y comunicación de datos, lo cual demanda conocimientos en administración de servicios, configuración de entornos y manejo de la comunicación entre el sistema embebido y la plataforma de análisis. Este aspecto es clave para garantizar la estabilidad, disponibilidad y seguridad del sistema.

Finalmente, uno de los problemas más complejos es la correcta integración y fusión de múltiples tecnologías. La combinación de estos componentes exige una planificación cuidadosa, una documentación clara y la realización de pruebas constantes, con el fin de asegurar que todos los elementos funcionen de manera coordinada y confiable dentro del sistema propuesto.

2.6 Alcances y limitaciones

2.6.1 Alcances

El presente proyecto se centra en el desarrollo de un prototipo funcional cuyo objetivo principal es demostrar la viabilidad de la clasificación automática de residuos sólidos pequeños a partir del uso de recursos tecnológicos limitados. Para ello, se implementó un sistema basado en un microcontrolador ESP32, capaz de distinguir entre residuos orgánicos e inorgánicos, incorporando una interfaz de interacción tanto a nivel web como mediante hardware. Esta interfaz proporciona retroalimentación al usuario a través de una pantalla, en la cual se muestra el resultado del proceso ejecutado por el microcontrolador y el modelo de clasificación. El prototipo desarrollado no pretende constituirse como un producto final ni como una solución comercial, sino como una prueba de concepto que valida la posibilidad de automatizar el proceso de separación de residuos utilizando los medios técnicos y económicos disponibles.

Dentro de este alcance, el proyecto contempla el uso de inteligencia artificial mediante el desarrollo y adaptación de modelos de aprendizaje profundo basados en arquitecturas preentrenadas como ResNet50 y MobileNetV2. Dichos modelos fueron ajustados utilizando un conjunto de datos compuesto por imágenes de residuos orgánicos e inorgánicos de uso cotidiano. El propósito de esta implementación es evidenciar que, aun bajo restricciones de procesamiento, almacenamiento y disponibilidad de datos, es posible entrenar modelos capaces de identificar patrones visuales y realizar una clasificación automática con un nivel de precisión aceptable dentro de un entorno controlado.

Adicionalmente, el alcance del proyecto incluye el diseño y desarrollo conceptual de la estructura física del sistema mediante la generación de un modelo tridimensional. Este diseño representa una aproximación a lo que podría ser un producto final orientado a un entorno de producción, permitiendo visualizar la disposición de los componentes electrónicos y mecánicos, así como la lógica espacial del sistema. No obstante, dicho modelo 3D debe entenderse como una propuesta conceptual que define la dirección futura del proyecto, más que como un diseño definitivo.

Asimismo, el proyecto abarca la integración básica entre el hardware y el software, empleando módulos compatibles con plataformas tipo Arduino junto con el microcontrolador ESP32. Se logró establecer una comunicación funcional entre la cámara, los sensores, los actuadores y los modelos de inteligencia artificial además del servidor web que usa, permitiendo la ejecución de un ciclo completo de detección y clasificación de residuos. Esta integración se limita a garantizar la coordinación esencial entre los componentes del sistema, sin abordar aspectos avanzados como la optimización de tiempos de respuesta, la robustez frente a fallos, la operación continua en entornos reales o la escalabilidad del sistema.

2.6.2 Limitaciones

El desarrollo de la presente investigación está sujeto a una serie de condicionantes de carácter técnico, operativo y presupuestal que delimitan su alcance y definen el marco de acción del prototipo resultante.

En primera instancia, la clasificación de residuos se restringió a dos categorías principales, omitiendo subclasificaciones más específicas. Aunque el procesamiento de las imágenes y la inferencia del modelo de inteligencia artificial se ejecutan de manera remota en un servidor externo, se optó por una estructura de categorías simplificada para optimizar el diseño mecánico del prototipo. Esta decisión estratégica permitió reducir la complejidad de los mecanismos de separación. De manera complementaria, la escala física del dispositivo impone una restricción dimensional, limitando el procesamiento exclusivamente a objetos de tamaño reducido y volúmenes moderados, de acuerdo con la infraestructura mecánica diseñada.

En lo que respecta al desempeño operativo, el sistema manifiesta una dependencia crítica hacia condiciones ambientales controladas. Variables externas como la fluctuación en la iluminación o la presencia de residuos altamente deformados, contaminados o mezclados pueden comprometer la precisión de la detección. Debido a que el proyecto no integra mecanismos avanzados de adaptación automática a entornos no controlados los cuales demandarían una infraestructura de procesamiento superior, su eficacia se encuentra vinculada a un entorno de operación estable. En este sentido, el sistema ha sido concebido exclusivamente como un prototipo experimental. Por consiguiente, el diseño no aborda requerimientos propios de una solución de producción.

Desde una perspectiva metodológica, la efectividad del modelo de inteligencia artificial está intrínsecamente ligada a la representatividad y diversidad del conjunto de datos utilizado durante la fase de entrenamiento. El alcance de este estudio no contempla la recopilación masiva de datos ni la implementación de sistemas de reentrenamiento continuo. Estas decisiones se vieron influenciadas significativamente por el factor presupuestal, dado que la construcción y experimentación se llevaron a cabo en un entorno académico con recursos limitados. En consecuencia, se priorizó la accesibilidad económica y la funcionalidad básica del prototipo sobre parámetros de alta fiabilidad a largo plazo o resistencia industrial.

Finalmente, aunque la arquitectura del sistema se diseñó bajo un enfoque modular para facilitar su escalabilidad futura, dichas ampliaciones permanecen fuera de la ejecución actual. Aspectos como la integración con servicios en la nube, la automatización integral de procesos, el análisis de datos a gran escala o la transición hacia una infraestructura lista para producción han sido considerados únicamente desde un plano conceptual. Estas dimensiones, junto con la incorporación de nuevas categorías de materiales, se reservan como líneas de investigación para trabajos futuros que cuenten con una base operativa y financiera más robusta.

Capítulo 3

Marco teórico

3.1 Investigaciones previas

La gestión de residuos en México enfrenta retos importantes: se generan más de 100 mil toneladas diarias, pero sólo 84% se recolecta y solo 10% se recicla [2]. La inteligencia artificial (IA) surge como herramienta clave para mejorar esta situación. Por ejemplo, la IA permite sistemas automáticos de clasificación visual que aceleran el reciclaje [3]. En el contexto mexicano, las investigaciones destacan la potencialidad de redes neuronales y visión por computadora para reconocer y separar residuos sólidos.

3.1.1 Proyectos académicos e investigativos en México

CNN (Convolutional Neural Networks también conocida como Redes Neuronales Convolucionales) **para residuos**. En México se han entrenado modelos CNN sobre cámaras en tiempo real. Por ejemplo, investigadores del IPN (Instituto Politécnico Nacional) desarrollaron un algoritmo CNN que clasifica cuatro tipos de residuos reciclables, logrando una precisión superior al 89% [4]. Este sistema incluso activa salidas de hardware (Arduino) para accionar máquinas de separación, demostrando su aplicabilidad en procesos reales. De manera similar, un grupo del TecNM (Tecnológico Nacional de México) empleó YOLOv8 (un detector de objetos avanzado) con una webcam para clasificar basura doméstica. El modelo entrenado alcanzó una precisión global del 86% con inferencia rápida (50 ms por imagen) [5], lo cual es suficiente para implementaciones en sensores en contenedores inteligentes.

Prototipos y puntos inteligentes. Se han desarrollado prototipos de puntos de reciclaje inteligentes (smart bins) en universidades mexicanas. Por ejemplo, Sánchez Yáñez y Márquez [3] (2024) mencionan el diseño de un “*punto ecológico inteligente*” basado en MobileNet que clasificó residuos con 97.9% de acierto usando una Raspberry Pi. Estos dispositivos combinan visión artificial con microcontroladores (IoT) para asistir al usuario en la separación correcta de plástico, papel, metal, etc. Además, alumnos del Tec Milenio [6] (Nuevo León) crearon “*RevoTrash*”, un basurero inteligente con IA que identifica y clasifica automáticamente la basura y educa a los usuarios. En pruebas piloto en colegios de Monterrey, 9 de cada 10 personas usaron este dispositivo correctamente, evidenciando el impacto social de integrar IA en el reciclaje.

3.1.2 Innovaciones tecnológicas e industriales

Empresas líderes en clasificación de residuos llevan sus soluciones a México. Por ejemplo, la noruega TOMRA presentó su línea AUTOSORT™ en la Expo Residuos 2023 (Ciudad de México). Estos sistemas combinan sensores de alta resolución (hasta 320 mil puntos de escaneo por

segundo) con cámaras de color y visión NIR (Near Infrared también conocido como Infrarrojo Cercano) [2]. Esta tecnología permite identificar plásticos, metales y papeles con altísima precisión y altos niveles de pureza al separarlos, optimizando la rentabilidad del reciclaje. TOMRA reporta que sus equipos ya están instalados en miles de plantas globales y ayudan a recuperar una gran cantidad de materiales valiosos en México y el mundo.

En el ámbito emprendedor y académico surgen proyectos que llevan estas tecnologías a la práctica. Un caso destacado es SIR Soluciones Ambientales (CDMX), un startup centrado en gestión inteligente de residuos urbanos e industriales [7]. SIR (Servicios Integrales de Residuos) desarrolla plataformas digitales y servicios para optimizar la separación en origen y el reciclaje avanzado, en respuesta a la generación de más de 13 mil toneladas diarias de basura en la capital.

Más allá de la robótica, la convergencia con el Internet de las cosas permite crear contenedores inteligentes urbanos. Equipados con sensores ultrasónicos y cámaras con IA, estos contenedores pueden monitorear en tiempo real su nivel de llenado y detectar residuos inadecuados, enviando alertas para recolecciones dinámicas más eficientes. Este procesamiento de datos suele realizarse en el propio dispositivo; en otras palabras, se emplea edge computing, procesando la información donde se genera sin depender de la nube [8]. Esto es especialmente útil en zonas con conectividad limitada.

Un ejemplo académico reciente («WasteNet») implementó IA en un contenedor mediante un miniordenador Jetson Nano: clasificó seis categorías de desechos con un 97 % de precisión sin conexión externa [9]. Esta alta exactitud ayuda a evitar la contaminación cruzada del reciclaje y hace más amigable el sistema al usuario.

3.2 Bases teóricas

El presente apartado describe los fundamentos teóricos que sustentan el desarrollo del sistema inteligente de clasificación de residuos. Se abordan los conceptos principales para comprender los sistemas embebidos, sensores, actuadores, visualización de información, así como los principios de inteligencia artificial, visión por computadora y comunicación cliente-servidor que permiten el funcionamiento integral del sistema.

3.2.1 Sistemas embebidos y microcontroladores

Los sistemas embebidos son dispositivos electrónicos diseñados para realizar funciones específicas de forma autónoma. En estos sistemas, el microcontrolador actúa como unidad central de procesamiento, conteniendo en un único circuito integrado la CPU, memoria y periféricos de E/S necesarios para la tarea. A diferencia de un ordenador de propósito general, un sistema embebido no es reconfigurable por el usuario y suele ejecutarse con recursos limitados [10].

3.2.2 Sensores de proximidad

Un sensor de proximidad es un componente que detecta la presencia o movimiento de objetos cercanos sin contacto físico [11]. Al no requerir contacto directo, evita el desgaste mecánico y puede operar en ambientes difíciles. Existen varios tipos: inductivos (detectan metales mediante campos magnéticos), capacitivos (miden cambios en capacitancia ante cualquier material), magnéticos (activados por imanes) y ópticos (como los infrarrojos y ultrasónicos). Por ejemplo, los sensores ultrasónicos emiten pulsos de sonido de alta frecuencia y calculan la distancia midiendo el tiempo de regreso del eco [12]. Cuando el pulso refleja en un objeto, se determina la distancia al objetivo según la fórmula de tiempo de vuelo. De modo similar, los sensores infrarrojos emiten luz infrarroja y detectan la señal reflejada por objetos cercanos, activándose al superar un umbral de retorno.

3.2.3 Actuadores electromecánicos

Los actuadores son dispositivos que convierten una señal eléctrica en movimiento mecánico. Estos reciben las decisiones computacionales y realizan acciones físicas, cerrando el lazo sensorial-actuador [13]. Un caso típico es el servomotor, un actuador rotativo de alto rendimiento diseñado para control preciso de posición angular. Un servomotor incluye un motor eléctrico conectado a un mecanismo de engranajes y un sistema de retroalimentación; recibe una señal (PWM) que indica la posición deseada, ajusta su movimiento y comprueba constantemente el ángulo real mediante sensores internos para corregir el error [14]. Dicho de otra forma, el servomotor desplaza su eje a la dirección correspondiente, ejecutando un movimiento suave y exacto. Otros ejemplos de actuadores electromecánicos son los motores DC (rotativos sencillos) y los actuadores lineales (para movimiento rectilíneo), que también transforman la energía eléctrica en desplazamiento mecánico.

3.2.4 Visualización de información mediante pantallas oled

Las pantallas OLED (Organic Light Emitting Diode) son componentes de visualización ideales por su eficiencia y calidad de imagen. Estas pantallas generan luz mediante capas orgánicas emisoras al paso de corriente, sin necesitar retroiluminación. Gracias a esto, son extremadamente delgadas, flexibles y pueden apagar píxeles de forma individual, logrando negros puros y alto contraste. Además, ofrecen respuesta rápida y amplio ángulo de visión. Entre sus ventajas destacan la precisión de color y el menor consumo energético (especialmente en imágenes oscuras) [15].

3.2.5 Inteligencia artificial y aprendizaje automático

La Inteligencia Artificial (IA) es un área de la informática que se enfoca en crear sistemas capaces de realizar tareas que requerirían inteligencia humana, como el aprendizaje, el razonamiento y la percepción. Los algoritmos de IA procesan información del entorno y toman decisiones complejas con base en datos estructurados o no estructurados. Una disciplina clave de la IA es el aprendizaje automático (Machine Learning), donde los sistemas ajustan sus parámetros automáticamente aprendiendo de conjuntos de datos. En este enfoque, el modelo numérico se entrena con ejemplos etiquetados para mejorar su precisión y eficiencia con el tiempo [16].

3.2.6 Visión por computadora

La visión por computador (o visión artificial) es la rama de la IA dedicada a interpretar y comprender imágenes y vídeos digitales. Combina técnicas de procesamiento digital de imágenes, análisis de patrones y aprendizaje automático para extraer información relevante del contenido visual. Por ejemplo, un pipeline típico incluye adquisición de imagen, preprocesamiento, extracción de características (bordes, texturas, formas) y clasificación. Las aplicaciones abarcan desde detección de objetos y reconocimiento facial hasta análisis de escenas complejas [17].

3.2.7 Clasificación de imágenes mediante inteligencia artificial

La categorización de imágenes a través de IA implica la asignación automática de una etiqueta o clase a una imagen, tomando como referencia su contenido visual. Las redes neuronales profundas, en particular las CNN, que adquieren jerarquías de rasgos directamente a partir de los píxeles, son el fundamento principal de este procedimiento. En una red neuronal convolucional (CNN), las capas más cercanas a la entrada son capaces de identificar texturas simples y bordes, en tanto que las capas más profundas pueden detectar patrones más complejos y abstractos, como la forma completa de un objeto. Según investigaciones recientes, la precisión en la clasificación de imágenes se incrementa considerablemente cuando se emplean técnicas de aprendizaje profundo y CNN. Cuando se entrena el modelo con miles o cientos de imágenes etiquetadas, la red tiene la capacidad de diferenciar las categorías al fusionar información de distintos niveles de detalle [18].

3.2.8 Comunicación cliente-servidor y APIs REST

La comunicación cliente-servidor es un modelo donde un cliente realiza peticiones a un servidor remoto y este último atiende las solicitudes procesándolas y devolviendo respuestas. En este diseño, los componentes están desacoplados: el cliente inicia la solicitud y el servidor responde con los datos o acción requerida.

Para la comunicación entre dispositivos se suelen usar APIs RESTful. Una API RESTful opera sobre HTTP (Hyper Text Transfer Protocol también conocido como Protocolo de transferencia de hipertexto), definiendo recursos identificados por URLs y utilizando métodos estándar como GET o POST. Cuando el cliente envía una petición al servidor, lo hace mediante una solicitud HTTP POST al endpoint adecuado; el servidor atiende la petición, ejecuta y retorna la respuesta en formato JSON.

El formato JSON (JavaScript Object Notation) es independiente del lenguaje y legible tanto por humanos como máquinas [19].

3.3 Antecedentes

3.3.1 Contexto general del problema

La gestión de los residuos sólidos en México constituye uno de los principales desafíos ambientales y sociales de las últimas décadas. El acelerado crecimiento urbano, el incremento en los patrones de consumo y la limitada infraestructura destinada al manejo adecuado de los desechos han generado un aumento sostenido en la producción de residuos sólidos urbanos. De acuerdo con datos de la Secretaría de Medio Ambiente y Recursos Naturales (SEMARNAT), en el país se generan diariamente más de 120 mil toneladas de residuos sólidos urbanos, de los cuales una proporción significativa no recibe un tratamiento ni disposición final adecuados, lo que impacta negativamente en la salud pública, los ecosistemas y la calidad de vida de la población [20].

En este contexto, la gestión eficiente de los residuos sólidos se ha convertido en una prioridad dentro de las políticas ambientales tanto a nivel nacional como local. Estas políticas promueven estrategias basadas en los principios de la economía circular, los cuales priorizan la reducción, reutilización y reciclaje de los residuos. Sin embargo, la implementación efectiva de dichas estrategias enfrenta diversos retos, entre los que destacan la insuficiente infraestructura tecnológica, la limitada participación ciudadana y la baja eficiencia de los procesos tradicionales de separación y clasificación, los cuales suelen realizarse de manera manual.

En respuesta a esta problemática, el Centro de Investigación e Innovación en Tecnologías de la Información y Comunicación (INFOTEC) ha impulsado iniciativas orientadas al desarrollo de soluciones tecnológicas que promuevan la sostenibilidad ambiental. Estas iniciativas fomentan la integración de herramientas digitales, inteligencia artificial y sistemas embebidos con el objetivo de proponer alternativas innovadoras que optimicen la gestión de los residuos sólidos.

En este contexto, el presente trabajo se enfoca en el diseño e implementación de un sistema automatizado para la clasificación de residuos sólidos, utilizando diversas técnicas para la identificación de residuos. El sistema propuesto emplea tecnologías emergentes como el microcontrolador ESP32, Inteligencia Artificial y dispositivos de visualización, con el fin de mejorar la eficiencia y precisión en el proceso de clasificación.

De esta forma, el proyecto integra un enfoque interdisciplinario y formativo, combinando innovación, sostenibilidad y tecnología para contribuir al manejo responsable de los residuos [21].

3.3.2 Evolución de la clasificación de residuos

La Ciudad de México, a través de la Secretaría del Medio Ambiente (SEDEMA), ha implementado diversos programas orientados a la recolección, tratamiento y disposición final de los residuos sólidos urbanos, los cuales incluyen campañas de separación en origen, fortalecimiento de la infraestructura de recolección y estrategias permanentes de educación ambiental dirigidas a la ciudadanía [22]. Estas acciones responden a la necesidad de enfrentar los crecientes impactos ambientales y sociales derivados del aumento sostenido en la generación de residuos, producto del crecimiento urbano y de los patrones de consumo actuales.

La clasificación de residuos en México ha experimentado una evolución significativa durante las últimas décadas, impulsada por la urgencia de reducir los efectos negativos asociados a la disposición inadecuada de los desechos urbanos. Tradicionalmente, la gestión de residuos se basaba en la recolección conjunta de basura orgánica e inorgánica, lo que dificultaba los procesos de reciclaje, incrementaba la contaminación ambiental y aceleraba la saturación de los sitios de disposición final. Ante este panorama, a nivel nacional se han promovido iniciativas enfocadas en la separación en origen como una estrategia clave para mejorar el aprovechamiento de materiales reciclables y disminuir la carga ambiental sobre los rellenos sanitarios, respaldadas por normativas federales y programas de educación ambiental impulsados por la Secretaría de Medio Ambiente y Recursos Naturales (SEMARNAT) [23].

En este contexto, la Ciudad de México ha desempeñado un papel destacado en la modernización de los esquemas de clasificación de residuos. La SEDEMA ha establecido lineamientos y campañas dirigidas a fortalecer la cultura de separación en hogares, comercios y espacios públicos. Uno de los avances más relevantes ha sido la adopción de un sistema de separación que distingue entre residuos orgánicos, residuos inorgánicos reciclables, residuos inorgánicos no reciclables y residuos de manejo especial y voluminosos, lo cual ha permitido optimizar los procesos de recolección y aumentar la cantidad de materiales valorizados [22].

Adicionalmente, la SEDEMA ha impulsado programas de valorización de residuos, la instalación de centros de acopio, la realización de jornadas comunitarias de reciclaje y campañas permanentes de sensibilización ambiental. Estas acciones forman parte de una estrategia integral orientada no solo a mejorar la gestión de los residuos sólidos urbanos, sino también a promover la corresponsabilidad ciudadana y avanzar hacia modelos de desarrollo sostenible alineados con los principios de la economía circular y las políticas ambientales globales [24].

Esta evolución se ha visto reforzada por los lineamientos federales establecidos en la Ley General para la Prevención y Gestión Integral de los Residuos, la cual define la separación primaria como un elemento fundamental del manejo integral de los residuos sólidos urbanos y establece la

responsabilidad de las entidades federativas y municipios en la implementación de programas locales de gestión adecuada de los residuos [22].

Un ejemplo representativo de este proceso de fortalecimiento normativo es la reforma impulsada por el gobierno de la Ciudad de México, mediante la cual se establece que, a partir del 1° de enero de 2026, la separación de residuos será obligatoria en la capital del país. Bajo el programa denominado “Transforma tu ciudad, cada residuo en su lugar”, se exige que hogares, comercios, escuelas y oficinas clasifiquen sus desechos en tres categorías principales: residuos orgánicos, residuos inorgánicos reciclables y residuos inorgánicos no reciclables [25]. Como parte de esta estrategia, se estima que al menos el 50 % de las aproximadamente 8 mil toneladas de residuos generadas diariamente en la ciudad puedan ser recicladas o aprovechadas de manera adecuada [25].

Esta iniciativa contempla además un calendario de recolección diferenciada por días, campañas de educación ambiental y una mayor inversión en infraestructura de recolección, con el objetivo de garantizar el cumplimiento del nuevo esquema y mejorar la eficiencia del sistema de manejo de residuos sólidos urbanos [26].

En conjunto, la evolución de la clasificación de residuos en México y, particularmente, en la Ciudad de México refleja una transición progresiva hacia prácticas más eficientes, sostenibles y orientadas a la economía circular. Este marco contextual sienta las bases para el desarrollo e implementación de soluciones tecnológicas, como el sistema automatizado propuesto en este proyecto, que contribuyen a la mejora continua de la gestión de residuos urbanos.

3.3.3 Problemática de clasificación de residuos

A nivel mundial, la inadecuada separación de residuos sólidos continúa siendo uno de los principales obstáculos para el desarrollo de sistemas de reciclaje eficientes y sostenibles. Esta problemática genera contaminación cruzada, entendida como la mezcla de residuos orgánicos e inorgánicos, así como de materiales reciclables con desechos no reciclables, lo que reduce significativamente la calidad de los materiales recuperados y aumenta los costos operativos asociados a los procesos de separación y tratamiento [27].

En el contexto mexicano, esta situación se manifiesta en la baja tasa de separación efectiva tanto en los hogares como en los espacios públicos, así como en la saturación de los centros de transferencia y de los rellenos sanitarios. A pesar de la implementación de programas de educación ambiental y de normativas orientadas a promover la separación en la fuente, una proporción considerable de los residuos sólidos urbanos continúa llegando mezclada a los sitios de disposición final. Esto limita su aprovechamiento y ocasiona diversos impactos ambientales negativos, entre los que destacan la emisión de gases de efecto invernadero, la proliferación de fauna nociva y la contaminación del suelo y de los cuerpos de agua.

Ante este panorama, han surgido diversas iniciativas enfocadas en fortalecer la cultura de la separación de residuos y en incorporar soluciones tecnológicas que disminuyan la dependencia del factor humano en estos procesos. En este contexto, la presente propuesta tiene como objetivo explorar la viabilidad de sistemas inteligentes aplicados a la gestión de residuos sólidos urbanos, con el fin de mejorar los procesos de separación en entornos controlados y espacios públicos. De esta manera, se busca complementar los esfuerzos institucionales y las campañas gubernamentales existentes, como “Transforma tu ciudad, cada basura en su lugar”, impulsada por el Gobierno de la Ciudad de México para fomentar la correcta clasificación de los residuos desde su origen [28].

3.3.4 Avances tecnológicos en clasificación y automatización de residuos

En los últimos años, la incorporación de tecnologías como la inteligencia artificial (IA), la visión por computadora y los sensores IoT (Internet Of Things también conocido como Internet de las Cosas) ha transformado de manera significativa los procesos de gestión y clasificación de residuos a nivel mundial. Estas herramientas tecnológicas permiten optimizar la separación de materiales, reducir costos operativos y aumentar la precisión en la identificación de distintos tipos de desechos, contribuyendo a sistemas de reciclaje más eficientes y sostenibles.

A nivel internacional, se han desarrollado sistemas avanzados basados en IA, como Vision AI, los cuales han demostrado una alta capacidad para detectar residuos contaminados, identificar materiales incorrectamente clasificados y monitorear en tiempo real los niveles de sobrellenado en contenedores. Estas funcionalidades no solo mejoran la calidad del material recuperado, sino que también optimizan la logística de recolección y la toma de decisiones en la gestión de residuos sólidos urbanos [29].

De manera similar, diversas empresas especializadas han implementado soluciones industriales de clasificación automática de residuos mediante modelos de aprendizaje profundo entrenados con millones de imágenes. Estas plataformas permiten una reducción significativa de la intervención manual en plantas de reciclaje, incrementan la velocidad de procesamiento y alcanzan tasas de eficiencia superiores a las obtenidas mediante métodos tradicionales de separación [30].

En el contexto nacional, México ha comenzado a incorporar estas tecnologías a través de proyectos piloto, iniciativas gubernamentales y estudios académicos orientados a la modernización de la gestión de residuos urbanos. Investigaciones recientes evidencian que la integración de microcontroladores, sistemas de visión por computadora y redes neuronales permite automatizar la clasificación de residuos en tiempo real, facilitando la separación entre residuos orgánicos e inorgánicos directamente desde el punto de generación. [31]

No obstante, la implementación de estas soluciones enfrenta aún diversos desafíos, entre los que destacan la limitada infraestructura tecnológica en ciertos municipios, los costos asociados a su adopción y la necesidad de capacitar a operadores y personal técnico especializado. A pesar

de estas limitaciones, el avance científico, junto con el creciente interés gubernamental en estrategias de digitalización ambiental, sugiere un escenario favorable para la adopción progresiva de sistemas inteligentes de gestión de residuos en México durante los próximos años [28].

3.3.5 Proyectos y aplicaciones específicas

A nivel internacional, se han desarrollado proyectos innovadores que integran inteligencia artificial, sensores avanzados y sistemas robóticos con el propósito de mejorar la eficiencia y precisión en los procesos de gestión y clasificación de residuos sólidos. Estas iniciativas evidencian una tendencia global hacia la automatización y digitalización de los sistemas de reciclaje, orientada a reducir la intervención manual y optimizar el aprovechamiento de materiales [32].

En Europa, particularmente en Finlandia, empresas como Remeo y ZenRobotics han liderado la automatización del reciclaje mediante la implementación de sistemas robóticos equipados con visión por computadora, cámaras infrarrojas y algoritmos de clasificación en tiempo real. Estas soluciones permiten identificar y separar más de 2 000 objetos por hora, demostrando la viabilidad y eficiencia de la robótica industrial aplicada a centros de reciclaje modernos [33].

Por su parte, en Estados Unidos se ha impulsado el uso de contenedores inteligentes como una estrategia para optimizar la recolección y el monitoreo de residuos urbanos. Estos dispositivos integran sensores de nivel de llenado, sistemas de comunicación inalámbrica y modelos predictivos, lo que posibilita notificar de manera automática a los servicios municipales cuando es necesario realizar el vaciado. Como resultado, se logra una reducción significativa de los costos operativos, así como la prevención de la saturación de contenedores en espacios públicos [34].

En el contexto de América Latina, diversas iniciativas promovidas por organismos internacionales, como el Banco Interamericano de Desarrollo (BID), han incorporado técnicas de inteligencia artificial para la predicción de la generación de residuos, la optimización de rutas de recolección y el análisis de patrones de comportamiento ciudadano. Estos proyectos se orientan al fortalecimiento de modelos de economía circular, fomentando la reutilización y el reciclaje de materiales, además de contribuir a la modernización de la infraestructura de gestión de residuos en los países de la región [34].

3.4 Enfoque metodológico del proyecto

A pesar de los avances tecnológicos logrados a nivel internacional en materia de clasificación automatizada de residuos, la mayoría de estas soluciones continúan siendo costosas, de difícil acceso y diseñadas principalmente para entornos industriales o plantas especializadas de reciclaje. Equipos basados en robótica avanzada, sensores industriales y sistemas de visión artificial de alto rendimiento representan inversiones significativas que resultan inviables para la gran mayoría de municipios, pequeñas comunidades o incluso hogares. Esta brecha tecnológica genera un rezago considerable en la adopción de prácticas eficientes de separación de residuos, especialmente en países como México, donde la infraestructura de gestión de desechos es limitada y persisten desafíos como la contaminación cruzada, la falta de separación en origen y la saturación de sitios de disposición final.

En este contexto, el presente proyecto adquiere una relevancia particular al proponer una alternativa accesible, escalable y de bajo costo, empleando tecnologías como ESP32, servidores e inteligencia artificial. Este prototipo está pensado para operar como herramienta de apoyo para la correcta clasificación de residuos, reducir la dependencia del trabajo manual y fomentar una cultura de reciclaje más efectiva entre la población.

3.4.1 Importancia del proyecto en el contexto actual

El manejo inadecuado de residuos representa uno de los principales retos ambientales en México. De acuerdo con SEMARNAT, el país genera más de 120 mil toneladas de residuos sólidos urbanos al día, y una parte considerable termina sin separación adecuada. [20] Al facilitar la correcta clasificación en el punto de origen, este proyecto contribuye de manera directa a:

- Reducir la contaminación cruzada entre residuos orgánicos e inorgánicos.
- Mejorar la calidad del material reciclado.
- Disminuir la cantidad de desechos que llegan a rellenos sanitarios.
- Apoyar políticas públicas de separación obligatoria que se implementarán en los próximos años.
- Incrementar la educación ambiental mediante un sistema interactivo y visual.

Además, al basarse en hardware económico, reutilizable y ampliamente documentado, este prototipo puede ser adoptado por entornos corporativos como INFOTEC.

3.5 ¿Qué es una metodología de desarrollo?

Las metodologías de desarrollo de software constituyen un elemento fundamental en el ámbito de la programación, ya que permiten organizar y gestionar el trabajo en equipo de manera estructurada y eficiente. A lo largo del tiempo, estas metodologías han evolucionado significativamente, pasando de ser simples herramientas de organización a convertirse en un pilar esencial para el desarrollo productivo y eficaz de soluciones de software.

En términos generales, las metodologías de desarrollo de software pueden definirse como un conjunto de técnicas, procesos y métodos organizativos aplicados al diseño, construcción y mantenimiento de sistemas informáticos. Su principal objetivo es establecer una estructura de trabajo que permita a los equipos de desarrollo coordinar sus actividades de forma óptima, garantizando la calidad del producto final y el cumplimiento de los objetivos planteados.

El desarrollo de software es una actividad particularmente compleja, especialmente cuando involucra sistemas de gran escala y equipos multidisciplinarios. La ausencia de una metodología claramente definida puede generar desorganización, retrasos, errores recurrentes y, en consecuencia, resultados insatisfactorios. Por ello, la adopción de una metodología adecuada resulta clave para mitigar riesgos y mejorar la eficiencia del proceso [35].

3.5.1 Metodologías de desarrollo tradicionales

Las metodologías de desarrollo tradicionales (o clásicas) se basan en ciclos secuenciales y planificados por adelantado. El ejemplo más representativo es el modelo en cascada, donde el proyecto se divide en fases estrictas (análisis de requisitos, diseño, construcción, pruebas y mantenimiento) y no se avanza a la siguiente fase hasta que la anterior ha sido aprobada [36]. Este enfoque favorece la documentación completa y la estabilidad inicial, por lo que es útil cuando los requisitos son bien conocidos de antemano. Sin embargo, su rigidez dificulta la adaptación a cambios tardíos: cualquier modificación en etapas avanzadas es compleja o costosa de implementar. En general, las metodologías tradicionales requieren definir desde el inicio qué se va a construir y un plan fijo, lo que reduce la flexibilidad ante imprevistos.

Además del modelo en cascada, existen otros enfoques tradicionales derivados. Por ejemplo, el modelo incremental también trabaja por fases, pero va entregando gradualmente funcionalidades añadidas al sistema en cada iteración [37]. El modelo en espiral combina iteraciones con análisis de riesgos; cada ciclo incluye planificación, evaluación de riesgos, prototipado y revisión del cliente, acercándose progresivamente a los objetivos deseados. Otro caso es el desarrollo por prototipos, que parte de construir versiones iniciales sencillas del sistema para obtener retroalimentación temprana de los usuarios. En todos estos métodos tradicionales se mantiene la idea de fases definidas y controladas, lo que aporta claridad y seguimiento estricto, pero mantiene la característica de baja adaptabilidad a cambios durante el proceso.

3.5.2 Metodologías de desarrollo ágiles

Las metodologías ágiles surgieron para superar la rigidez de los enfoques clásicos. Se basan en ciclos de trabajo iterativos e incrementales, con entregas frecuentes y enfoque en la retroalimentación continua del cliente. A diferencia de cascada, el desarrollo ágil permite ajustar el alcance y los requisitos en cada iteración, maximizando la adaptabilidad y la velocidad de entrega [36]. Estas metodologías ponen énfasis en la colaboración del equipo, la comunicación directa y la mejora continua del producto. Los valores del Manifiesto Ágil priorizan los procesos ligeros sobre la documentación excesiva y las respuestas rápidas al cambio sobre la planificación rígida, por lo que favorecen equipos multifuncionales que trabajan codo a codo con los usuarios.

Entre las metodologías ágiles más difundidas se encuentran Scrum, Kanban, Extreme Programming (XP), Lean Software Development, Crystal, entre otras. Por ejemplo, Scrum organiza el trabajo en iteraciones cortas (“sprints”) y define roles y rituales específicos [37]. Kanban enfatiza el flujo continuo y la flexibilidad en las tareas. XP incorpora prácticas de alta calidad como desarrollo en parejas y pruebas unitarias continuas. En todos los casos, el objetivo es entregar incrementos operativos del producto con regularidad, permitiendo validar el progreso y reducir riesgos a través del feedback del cliente. En proyectos con requisitos inciertos o que cambian rápido, las metodologías ágiles suelen mantener mejor alineados el desarrollo con las necesidades reales y mejoran la capacidad de adaptación.

3.5.3 Comparación tradicional vs ágil

Aspecto	Tradicional	Ágil
Flujo de trabajo	Emplean un ciclo secuencial y rígido con fases sucesivas bien definidas.	Usan un ciclo iterativo e incremental.
Planificación y flexibilidad	La mayoría de la planificación se realiza al inicio y los cambios posteriores son difíciles de incorporar, lo que resulta en baja flexibilidad.	Permiten ajustes constantes en cada iteración basados en la retroalimentación, fomentando alta adaptabilidad.
Estructura de equipo	Los equipos suelen estar organizados con roles especializados y jerárquicos (analistas, diseñadores, programadores, etc.).	Los equipos son multifuncionales, autoorganizados y colaboran estrechamente; la autoorganización promueve la responsabilidad compartida y la mejora continua del proceso.
Entregas de producto	Se espera una entrega única del sistema completo al final del proyecto.	Se realizan entregas parciales frecuentes; los incrementos regulares permiten validar progresos con los usuarios y mitigar riesgos constantemente.
Gestión de riesgos y satisfacción del cliente	Aportan mayor previsibilidad y control cuando los objetivos son muy claros desde el inicio.	Facilitan adaptarse a requisitos cambiantes y obtener resultados útiles tempranamente.

Tabla 1 Comparación tradicional vs ágil.

3.5.4 Metodología SCRUM

Scrum es un marco de trabajo ágil muy popular para gestionar proyectos complejos de software [38]. En Scrum el trabajo se organiza en ciclos fijos llamados sprints (generalmente de 1 a 4 semanas) en los que se desarrolla un conjunto de funcionalidades acordadas. Al final de cada sprint se debe entregar un incremento funcional del producto, que puede utilizarse para obtener retroalimentación de los clientes. Esta cadencia corta de entrega continua permite validar avances frecuentemente y reajustar prioridades de forma ágil.

Scrum define tres roles principales en el equipo: el Product Owner, responsable de gestionar y priorizar el backlog del producto; el Scrum Master, que facilita el proceso, elimina obstáculos y vela por el cumplimiento de la metodología; y el Equipo de Desarrollo, grupo multifuncional que realiza el trabajo técnico [36]. Además, Scrum prescribe eventos regulares: la planificación del sprint (se acuerda qué se hará en el sprint), el Daily Scrum (reunión diaria breve de seguimiento), la revisión del sprint (demostración del incremento entregado) y la retrospectiva (evaluación interna para mejorar el proceso). Estos roles y ceremonias establecen transparencia y responsabilidad en el equipo. En conjunto, Scrum combina la entrega incremental de valor con la capacidad de adaptación rápida: al repartir el trabajo en sprints cortos y recibir feedback constante, facilita responder a cambios imprevistos y alinear el desarrollo con las necesidades reales del proyecto.

3.5.5 Metodología SCRUM aplicada al desarrollo del proyecto

El desarrollo del proyecto se llevó a cabo mediante la metodología SCRUM, permitiendo una gestión ágil, iterativa y colaborativa del proceso. SCRUM facilitó la descomposición del proyecto en sprints definidos, tales como:

- **Construcción del servidor Flask.**
- **Implementación del sistema mecánico.**
- **Integración del ESP32 con el backend mediante un endpoint.**
- **Elección del dataset y entrenamiento del modelo de IA**

Gracias a SCRUM, el equipo pudo adaptar el desarrollo conforme aparecían nuevos retos técnicos, priorizar funcionalidades críticas y mantener un flujo constante de entregables funcionales. Esto permitió evolucionar desde un sistema básico de clasificación local hasta un prototipo completamente integrado capaz de operar de forma autónoma.

Capítulo 4

Desarrollo

El desarrollo del sistema de clasificación automatizada de residuos se llevó a cabo mediante una serie de etapas secuenciales e iterativas que permitieron asegurar la correcta integración entre los componentes de software, hardware y el modelo de inteligencia artificial. Con el fin de garantizar un proceso organizado, eficiente y controlado, se empleó una metodología basada en análisis colaborativo, entrevistas internas y la adopción del marco ágil **SCRUM**, lo que permitió dividir la solución en incrementos funcionales que fueron evaluados de manera continua.

La fase inicial consistió en la identificación de las necesidades reales dentro del contexto de INFOTEC, por medio de reuniones y pláticas con nuestro asesor académico, personal de la institución y compañeros residentes que compartían problemáticas relacionadas con la gestión de residuos y el manejo responsable dentro de los espacios de trabajo. Estas interacciones permitieron reconocer puntos clave tales como:

- Falta de mecanismos de separación eficiente
- Escasa sensibilización sobre el reciclaje
- Necesidad de soluciones accesibles para instituciones educativas y centros de investigación

así como el interés de INFOTEC en promover tecnologías emergentes aplicadas a problemas ambientales.

A partir de este análisis colaborativo se consolidaron los requisitos funcionales y no funcionales del sistema, estableciendo un camino claro para el desarrollo tecnológico. Posteriormente, se desarrolló el modelo de inteligencia artificial, entrenado con un conjunto de datos compuesto por imágenes de residuos orgánicos e inorgánicos capturadas bajo diversas condiciones de luz y ángulos.

Se implementaron técnicas de *data augmentation* para mejorar la capacidad de generalización y se evaluaron varias arquitecturas ligeras basadas en MobileNetV2, buscando un equilibrio adecuado entre rendimiento y velocidad en dispositivos embebidos como el ESP32. Tras múltiples iteraciones de entrenamiento, validación y ajuste de hiperparámetros, se seleccionó el modelo final que ofreció la mayor precisión manteniendo tiempos de inferencia óptimos.

Una vez obtenido el modelo final, se procedió a la construcción del entorno de pruebas local, mediante un servidor Flask encargado de recibir las imágenes enviadas por el ESP32, procesarlas, ejecutar la inferencia y devolver la clasificación correspondiente. Este entorno permitió depurar

eficazmente el flujo de comunicación, medir los tiempos de respuesta HTTP, validar el funcionamiento del pipeline de inteligencia artificial y realizar pruebas controladas antes de la implementación en hardware.

Con el software base implementado, la siguiente etapa fue la integración del hardware, que incluyó el ESP32, el sensor ultrasónico, el servomotor para el mecanismo de separación física y la pantalla para mostrar el historial de clasificaciones y el estado del sistema. Durante esta fase se realizaron pruebas de conexión eléctrica, medición de consumo energético, calibración del sensor de distancia y verificación del movimiento del servomotor. También se desarrolló la interfaz visual que permite al usuario monitorear el funcionamiento del sistema en tiempo real.

Para organizar y controlar el proceso, se utilizó la metodología SCRUM, estructurando el trabajo en sprints semanales. Cada sprint incluyó sesiones de planificación, ejecución de tareas, reuniones diarias de seguimiento (*daily scrum*), revisiones al finalizar cada incremento y retrospectivas para identificar mejoras en el flujo de trabajo. Este enfoque permitió corregir problemas oportunamente, priorizar funcionalidades críticas y asegurar un avance continuo y ordenado del proyecto.

Finalmente, se realizó el ensamblaje físico del prototipo, integrando todos los componentes dentro de una estructura diseñada para optimizar el flujo de residuos, la captura de imágenes y la clasificación automática. Se llevaron a cabo pruebas de campo en condiciones reales, donde se midió la precisión del modelo, la estabilidad de la conexión WiFi, los tiempos de respuesta del servidor, la operación del servomotor y la fiabilidad general del sistema ante distintos tipos de residuos.

El resultado de este proceso de desarrollo fue un sistema funcional, accesible y escalable, capaz de realizar clasificación automatizada en tiempo real. Este prototipo demuestra la viabilidad de aplicar inteligencia artificial y microcontroladores de bajo costo dentro de instituciones como INFOTEC, fomentando prácticas sostenibles y apoyando la transición hacia una gestión de residuos más eficiente y responsable.

4.1 Entrevistas y Análisis de Requerimientos

Para el diseño del sistema de clasificación automatizada de residuos, fue indispensable realizar un proceso inicial de levantamiento de información mediante entrevistas y conversaciones con actores clave dentro de INFOTEC. Se llevaron a cabo reuniones informales y formales con el asesor académico, personal administrativo, personal de operación y compañeros residentes, quienes aportaron una visión directa sobre los retos reales relacionados con la separación y gestión de residuos dentro del centro.

Durante estas entrevistas se identificaron diversas problemáticas, entre ellas:

- Falta de uniformidad en la separación de residuos dentro de las áreas comunes.

- Ausencia de herramientas tecnológicas que apoyen la correcta clasificación.
- Escasa sensibilización del personal respecto a la importancia de la separación.
- Necesidad de soluciones accesibles que puedan escalarse a otras instalaciones.
- Interés institucional por integrar tecnologías emergentes en procesos ambientales.

Con base en estas observaciones se definieron los requerimientos funcionales, entre los que destacaron:

1. El sistema debe capturar imágenes de residuos automáticamente.
2. El modelo debe clasificar en tiempo real entre residuo orgánico e inorgánico.
3. El servidor debe procesar imágenes y devolver resultados inmediatos.
4. Debe integrarse un mecanismo físico para mover o separar los residuos.
5. Se requiere una interfaz visual para mostrar estado de la clasificación.

Asimismo, se establecieron requerimientos no funcionales:

- Bajo consumo energético.
- Tiempo de inferencia menor a 2 segundos.
- Capacidad de operar con WiFi local.
- Uso de hardware económico y fácilmente reemplazable.
- Tolerancia básica a condiciones ambientales variables.

Este análisis permitió sentar las bases del diseño del prototipo, alineando los objetivos técnicos con las necesidades reales de INFOTEC.

4.1.1 Aspectos generales del código.

En este proyecto se implementa la nomenclatura en su mayoría Camel Case y Snake Case para la creación de clases, con el objetivo de mejorar la legibilidad y mantener un estilo de código uniforme.

Además de CamelCase, se utiliza una nomenclatura de tipo militar (por letras como Alpha, Bravo, etc.) para nombrar las instancias principales del sistema. Esta estrategia facilita la identificación de módulos clave y permite distinguir rápidamente las responsabilidades de cada componente.

Hasta el momento, se han utilizado dos identificadores principales:

Letra utilizada	Clase encargada
Alpha	ManejadorHTTP Asignado al backend principal, encargado del manejo general del sistema.
Bravo	pruebaModelosTF Asignado al backend de identificación mediante inteligencia artificial.

Tabla 2 Nombre de instancias

La nomenclatura general adoptada combina claridad semántica, orden y una estructura que facilita la escalabilidad del proyecto. De esta manera, cada nueva clase o instancia podrá integrarse sin perder consistencia ni generar ambigüedades en el código.

4.1.2 Hardware a utilizar



Ilustración 2 Servomotor MG90S.

El servomotor MG90S es una opción común y eficiente debido a su excelente relación tamaño-par. Es un microservo de engranaje metálico que, a pesar de su pequeño tamaño, es capaz de proporcionar suficiente potencia para tareas ligeras y medianas, como mover pequeños brazos robóticos, operar interruptores o posicionar con precisión sensores y cámaras. Su capacidad de ser controlado por una simple señal PWM (modulación de ancho de pulso) proporciona un control de ángulo preciso [39].



Ilustración 3 Sensor ultrasónico HC-SR04.

El sensor ultrasónico HC-SR04 destaca por su capacidad de medir distancias de forma discreta, fiable y además a un precio reducido. Utiliza pulsos de sonido ultrasónicos para determinar la distancia al objeto y exhibe una sorprendente resistencia a las fluctuaciones de la luz, lo que le da una ventaja sobre otros sensores como el infrarrojo. Su operación simple de tiempo de vuelo y su disparador de dos pines e interfaz de eco simplifican la integración en tareas [40].




Ilustración 4 ESP32-S3 N16R8.

Se eligió el ESP32-S3 N16R8 para ser el cerebro detrás de esta iniciativa debido a su conectividad avanzada y alto rendimiento. La hoja de especificaciones del N16R8 indica que tiene 8 MB de PSRAM (RAM pseudoestática) y 16 MB de memoria flash, lo que proporciona una enorme capacidad para almacenar y procesar datos esenciales para controlar la transmisión de video de la cámara OV2640. Además, su soporte integrado para Bluetooth 5 (LE) y Wi-Fi permite la comunicación inalámbrica y el control remoto [41].



Ilustración 5 Pantalla oled 128x64 i2c.

Se eligió una pantalla OLED de 128x64 con interfaz I2C por su bajo consumo de energía y alta legibilidad. Su tecnología OLED (diodo emisor de luz orgánico) significa que cada píxel genera su propia luz, perfectos para ofrecer información clara en una variedad de situaciones. Además, su pequeño tamaño y la simplicidad de la interfaz I2C (que requiere solo dos pines de reloj/datos además de la fuente de alimentación) lo hacen ideal para proyectos donde el espacio y el cableado son esenciales [42].



Ilustración 6 Cámara esp32 OV2640.

Se eligió la cámara OV2640 para agregar capacidades de visión al proyecto. Ofrece una resolución máxima de 2 megapíxeles, que es más que suficiente para la mayoría de las aplicaciones de transmisión o visión integrada. Su forma de control de configuración y la capacidad de generar datos de imágenes en varios formatos lo hacen compatible y configurable [43].

4.2 Planificación y Ejecución de la Metodología Scrum.

El desarrollo del proyecto se estructuró bajo la metodología Scrum, un marco ágil que facilita la gestión de proyectos complejos mediante la división del trabajo en iteraciones cortas y de duración fija llamadas Sprints. Cada Sprint se enfoca en entregar un incremento de producto funcional y potencialmente entregable.

La priorización de los elementos del Product Backlog (tales como la construcción del servidor, la implementación mecánica y el entrenamiento del modelo) se definió para asegurar que el Mínimo Producto Viable (MVP) la clasificación funcional de residuos con respuesta del servidor se completara en los primeros Sprints.

No.	Actividades	Semanas																							
		1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24
1	Requerimientos																								
2	Investigación inicial																								
3	Planeación del sistema																								
4	Adquisición de materiales																								
5	Construcción del prototipo																								
6	Pruebas de hardware																								
7	Entrenamiento del modelo de IA																								
8	Desarrollo del software																								
9	Integración y pruebas																								
10	Entrega y documentación																								

Tabla 3 Cronograma de actividades.

Los primeros Sprints (semanas 1 a 6) estuvieron orientados a la definición de requerimientos, investigación inicial y planificación del sistema, sentando las bases técnicas y conceptuales del proyecto. Posteriormente, durante los Sprints intermedios (semanas 7 a 16), se concentró el mayor esfuerzo de desarrollo, abarcando la adquisición de materiales, la construcción del prototipo físico, el entrenamiento inicial del modelo de inteligencia artificial y el desarrollo del software backend y de la interfaz. Finalmente, los últimos Sprints (semanas 17 a 24) se destinaron principalmente a la integración de componentes, pruebas de funcionamiento, ajustes derivados de los resultados experimentales, así como a la documentación y entrega final del proyecto.

4.2.1 Construcción del servidor.

El objetivo de este sprint fue establecer la base del sistema: el Servidor Flask que actuaría como el backend central del sistema de clasificación. Se definió y probó el endpoint de recepción de datos y se integró el core de la Inteligencia Artificial.

Historia de Usuario / Elemento	Tareas Clave	Criterios de Aceptación
Construcción del Servidor Flask y Core de Clasificación.	1.1 Crear la aplicación Flask e inicializar el manejador ManejadorHTTP cargando el modelo de IA (model_retrained_REALDATA_v2.h5).	El servidor se inicia correctamente en la IP local y el modelo de IA está cargado en memoria.
Implementación del Endpoint de Clasificación (POST).	1.2 Crear la ruta principal (/) que maneja solicitudes POST. 1.3 Implementar la lógica de recepción del mensaje JSON (<u>recepcionMensaje</u>). 1.4 Manejar el evento "imagen bytes": guardar la imagen y pasarla al modelo de IA.	El endpoint (/) recibe un JSON con imagen_bytes, guarda el archivo JPG (guardarImagen) y lo procesa.
Integración del Modelo de Clasificación (MobileNetV2).	1.5 Implementar la pre-carga (<u>loadModel</u>) y pre-procesamiento de la imagen (tamaño 224x224). 1.6 Ejecutar la predicción (<u>predictImage</u>) y obtener la clase y probabilidad. 1.7 Implementar la regla de confianza insuficiente (≤ 60) y devolver el estado "reintentar".	La predicción devuelve una clase y una probabilidad. El servidor responde con "ok" y clasificacion ('B' o 'N') o "reintentar".
Desarrollo del Servicio de Actualización (Long Polling).	1.8 Crear la ruta /verificar_actualizacion para la actualización del frontend.	El endpoint espera hasta que haya una nueva clasificación disponible

	1.9 Implementar la lógica de Long Polling con un while True para esperar nuevos datos. 1.10 Actualizar la variable global ultima_actualizacion al recibir una nueva clasificación.	(ultima_actualizacion > timestamp_cliente) o hasta un timeout de 30 segundos.
--	--	---

Tabla 4 Construcción del Servidor Flask

4.2.2 Implementación del sistema mecánico.

El objetivo de este Sprint fue consolidar la capa física del sistema de clasificación. Se integraron y probaron los componentes esenciales bajo el control del ESP32-S3 CAM, asegurando su funcionamiento coordinado. Asimismo, se validó la comunicación HTTP bidireccional entre el dispositivo embebido y el servidor Flask, estableciendo así una interacción confiable entre el hardware y el backend del sistema.

Historia de Usuario / Elemento	Tareas Clave	Criterios de Aceptación
Integración del ESP32 con el Backend Mediante un Endpoint	2.1 Configurar la conectividad Wi-Fi del ESP32. 2.2 Inicializar la cámara (init_camera) y ajustarla para la captura de imagen. 2.3 Implementar el envío de una notificación de detección. 2.4 Implementar la función <u>enviarImagenComoBytes</u>, leyendo la imagen de la cámara (esp_camera_fb_get) y serializándola en un array de bytes JSON.	El ESP32 se conecta al Wi-Fi, la cámara inicializa con ajustes optimizados y el microcontrolador toma un frame y procesa la imagen en bytes para su incorporación en un JSON.
Implementación del Sistema Mecánico (Servomotor y Sensor Ultrasónico)	2.5 Inicializar el servomotor y el sensor ultrasónico (NewPing sonar).	El sensor ultrasónico activa la función <u>enviarDeteccionYClasificacion</u> .

	2.6 Implementar la lógica de detección de objeto: si la distancia es menor a 10 cm y ha pasado un delay de 3 segundos desde la última detección. 2.7 Implementar el control suave del servomotor (<u>moverServoSuave</u>) hacia los ángulos definidos (0 y 180).	El servomotor se mueve suavemente al ángulo de clasificación y regresa a la posición central (100)
Procesamiento de Respuesta y Feedback Visual (OLED).	2.8 Implementar la inicialización robusta de la pantalla OLED. 2.9 Implementar la función <u>procesarComando</u> para mover el servo al recibir 'B' o 'N' y mostrar el resultado en la OLED.	El ESP32 parsea la respuesta del servidor. Si recibe 'B' o 'N', mueve el servo e imprime "Basura Biodegradable/No-Biodegradable" en la OLED. Si hay un error, se notifica en la OLED.
Modelado 3D para Visualización de Escalabilidad y Diseño Final	2.10 Diseñar la estructura completa (carcasa y soporte) del prototipo final con dimensiones comerciales en software 3D. 2.11 Generar renders de alta calidad que muestren el prototipo industrializado y apto para producción. 2.12 Documentar las vistas clave del modelo 3D para su inclusión en el informe	El modelo 3D debe integrar todos los componentes electrónicos ESP32, cámara, servomotor y sensor junto con el mecanismo de separación de residuos de forma viable, reflejando además la capacidad de mejora del proyecto en entornos reales mediante una apariencia robusta y una estética moderna.

Tabla 5 Implementación del sistema mecánico

4.2.3 Integración del ESP32 con el backend mediante un endpoint.

El enfoque de este Sprint fue establecer la comunicación bidireccional robusta entre el ESP32 y el servidor Flask, utilizando la biblioteca HTTPClient y el formato de datos JSON. La clave fue desarrollar el protocolo de envío de imágenes capturadas como un array de bytes y la lógica de respuesta para procesar la clasificación y ejecutar la acción física.

Historia de Usuario / Elemento	Tareas Clave	Criterios de Aceptación
Implementación del Protocolo de Envío de Notificación.	3.1 Configurar el endpoint HTTP del ESP32 usando la URL del servidor Flask (ej. <code>http://<ip_servidor>:5000/</code>). 3.2 Implementar <code>enviarNotificacionDeteccion()</code> : Iniciar la conexión HTTP y enviar un POST al servidor con el evento "objeto identificado". 3.3 Incluir el identificador del dispositivo (<code>WiFi.macAddress()</code>) en la notificación JSON.	El ESP32 se conecta directamente al servidor mediante un endpoint y este como primer parte envía una solicitud JSON inicial al servidor para indicar que hay un objeto y está listo para enviar la imagen.
Envío de la Imagen de la Cámara como Bytes.	3.4 Implementar <code>enviarImagenComoBytes</code> para obtener el frame buffer JPEG (<code>camera_fb_t</code>). 3.5 Construir el payload JSON con el evento "imagen bytes" y crear un <code>JsonArray</code> para almacenar cada byte de la imagen. 3.6 Enviar el payload JSON mediante HTTP POST al	El servidor Flask recibe el array de bytes de la imagen de forma exitosa y devuelve un código de respuesta HTTP válido.

	servidor con un timeout amplio (15 segundos).	
Manejo de Respuestas del Servidor.	3.7 Procesar la respuesta HTTP del servidor y deserializar el JSON de respuesta (responseDoc). 3.8 Analizar el status de la respuesta: si es "reintentar", mostrar el mensaje de confianza baja. 3.9 Si el status es "ok", extraer el campo clasificacion y llamar a <u>procesarComando</u> para ejecutar la acción física ('B' o 'N').	El ESP32 es capaz de distinguir entre una clasificación exitosa ("ok") y una solicitud de repetición ("reintentar") basada en la respuesta JSON del servidor.
Manejo de Errores de Conexión/JSON.	3.10 Implementar manejo de errores para timeout de HTTP y fallos en el código de respuesta.	Los errores de conexión o de formato JSON son detectados, reportados a la consola Serial, y se muestra un mensaje temporal en la pantalla OLED.

Tabla 6 Integración del ESP32 con el backend mediante un endpoint.

4.2.4 Elección del dataset y entrenamiento del modelo de IA

Este Sprint abordó la fase crucial de investigación y desarrollo del Modelo de Clasificación de Residuos. Se priorizó el uso de modelos de Transfer Learning tanto como MobileNetV2 y ResNet50 para acelerar el entrenamiento y optimizar los recursos. El trabajo incluyó la gestión y preparación de diferentes datasets (públicos y propios) y la ejecución de cuatro ciclos de entrenamiento iterativos para afinar la arquitectura y el rendimiento del modelo.

Historia de Usuario / Elemento	Tareas Clave	Criterios de Aceptación
Elección y Preparación de los Datasets.	4.1 Selección de un Dataset Público inicial (e.g., Waste Classification Data V2 en el notebook).	Los datasets están estructurados con directorios de entrenamiento/validación. El generador de imágenes está configurado para la normalización.

	4.2 Creación de un Dataset Propio (REALDATA) de residuos bajo condiciones controladas para Fine-tuning. 4.3 Definición y aplicación de la Aumentación de Datos (ImageDataGenerator) para ambas fuentes, incluyendo rotación y zoom.	
Entrenamiento 1: ResNet50 con Dataset Público.	4.4 Cargar la arquitectura ResNet50 (pesos 'imagenet'). 4.5 Congelar las capas base y añadir capas densas (GlobalAveragePooling2D, Dense con 2 clases) para clasificación binaria. 4.6 Compilar el modelo con el optimizador Adam y callbacks (ModelCheckpoint, ReduceLROnPlateau).	Se ejecuta el entrenamiento con el dataset público, y los resultados iniciales se guardan para comparar con los demás modelos.
Entrenamiento 2: MobileNetV2 con Dataset Público.	4.7 Cargar y adaptar la arquitectura MobileNetV2 para la clasificación binaria (similar a 4.5). 4.8 Ejecutar el entrenamiento con el mismo dataset público para comparar la precisión y velocidad con ResNet50.	El modelo MobileNetV2 entrenado existe y su precisión de validación es registrada, para su posterior uso en pruebas.
Entrenamiento 3: MobileNetV2 con Dataset Personalizado Fusionado.	4.9 Fusionar el Dataset "RealWaste Image Classification" con el Dataset "TrashNet" para crear el Dataset Personalizado.	El modelo MobileNetV2 ha sido expuesto a la diversidad de imágenes de dataset públicos de fotografías reales y presenta un aumento en la precisión de validación.

	4.9 Cargar nuevamente la arquitectura del MobileNetV2. 4.10 Entrenar el modelo MobileNetV2 con el Dataset Personalizado Fusionado.	
Entrenamiento 4: Fine-tuning Iterativo por Dominio (MobileNetV2).	4.11 En este entrenamiento se buscó aplicar la técnica de Dominio Iterativa (Iterative Domain Technique). 4.12 Cargar el modelo anterior para conseguir un entrenamiento utilizando fine-tuning. 4.13 Reentrenar el modelo MobileNetV2 exclusivamente con el Dataset Propio (Imágenes propias y el dataset personalizado) a una tasa de aprendizaje baja para fine tuning.	El modelo es ajustado finamente para las condiciones reales de iluminación y perspectiva del proyecto. El modelo final (model_retrained_REALDATA_v2.h5) está listo para ser integrado en el backend.

Tabla 7 Elección del dataset y entrenamiento del modelo de IA.

4.3 Diseño de la Arquitectura del Sistema.

4.3.1 Módulo C++: Esp32ToPythonOledHttpCAM.ino.

Este módulo constituye el firmware principal del sistema embebido, diseñado para operar sobre el microcontrolador ESP32-S3 CAM. Su función es orquestar la interacción entre el entorno físico y el servidor de inteligencia artificial, integrando la captura de imágenes, la detección de proximidad y la actuación mecánica en un flujo automatizado.

El código gestiona el ciclo completo de clasificación de residuos: monitorea constantemente un sensor ultrasónico para detectar la presencia de objetos, captura y serializa imágenes en tiempo real para su transmisión vía HTTP, e interpreta las respuestas de clasificación recibidas para

controlar un servomotor. Este actuador segrega físicamente el material en sus respectivas categorías (biodegradable o no biodegradable), mientras el sistema proporciona retroalimentación visual continua sobre el estado de la conexión y el proceso mediante una pantalla OLED.

- **Paqueterías**

WiFi.h: Para gestionar la conexión a la red inalámbrica del dispositivo.

HTTPClient.h: Permite al ESP32 actuar como cliente para enviar peticiones HTTP POST (incluyendo los bytes de la imagen) al servidor Python.

ArduinoJson.h: Esencial para la serialización de la imagen capturada en un array de bytes JSON para su envío, y para la deserialización de la respuesta del servidor.

esp_camera.h: Librería de bajo nivel para la configuración y captura de frames del sensor de cámara (OV2640/OV5640) del ESP32-S3 CAM.

Adafruit_SSD1306.h / Adafruit_GFX.h: Para el control gráfico y del hardware de la pantalla OLED I2C, mostrando el estado del sistema y los resultados.

NewPing.h: Utilizada para realizar una lectura precisa y estable del sensor ultrasónico.

ESP32Servo.h: Para el control del servomotor que ejecuta la segregación física del material clasificado.

- **Variables predefinidas y su significado**

Variable / Constante	Tipo	Propósito
SCREEN_WIDTH / SCREEN_HEIGHT	#define	Definen las dimensiones físicas de la pantalla OLED (128x64 píxeles) para el manejo gráfico.
I2C_SDA_PIN / I2C_SCL_PIN	#define	Asignan los pines GPIO 42 y 41 del ESP32-S3 para la comunicación I2C con la pantalla OLED.
TRIG_PIN / ECHO_PIN	#define	Definen los pines GPIO (1 y 2) conectados al sensor ultrasónico HC-SR04 para medir la distancia.
SERVO_PIN	#define	Pin GPIO 3 utilizado para enviar la señal PWM que

		controla la posición angular del servomotor.
MAX_DISTANCE	#define	Establece el umbral de distancia máxima (10 cm) para que el sensor ultrasónico dispare el evento de "Objeto Detectado".
CAM_PIN_	#define	Conjunto extenso de definiciones de pines que mapean las líneas de datos y control del sensor de cámara (OV2640/OV5640) al chip ESP32-S3.
ssid / password	const char*	Almacenan las credenciales necesarias (nombre y contraseña) para conectarse a la red WiFi local.
serverUrl	const char*	Dirección IP y puerto estático del servidor Flask (ej. http://192.168.0.121:5000/) al que el ESP32 enviará las peticiones HTTP.
displayIniciada	bool	Variable bandera que indica si la pantalla OLED se inicializó correctamente; se usa para evitar fallos de escritura si la pantalla no está conectada.

Tabla 8 Definición de variables iniciales ESP32.

- **Configuración setup()**

Componente/Objeto	Tipo/Librería	Descripción
Serial	HardwareSerial	Inicializa la comunicación serie a 115200 baudios para depuración en consola.
display	Adafruit_SSD1306	Inicializa el bus I2C y configura la pantalla OLED, verificando las direcciones 0x3C o 0x3D.
servoMotor	Servo (ESP32Servo)	Asigna el servomotor al pin GPIO 3 y lo coloca en una posición neutral inicial de 100 grados.
esp_camera	esp_camera.h	Configura los pines, frecuencia del reloj (20MHz) y ajustes de imagen (brillo/contraste) del sensor.
WiFi	WiFiClass	Establece la conexión a la red inalámbrica utilizando las credenciales (SSID/Password) definidas.

Tabla 9 Atributos del setup del microcontrolador.

- **Métodos Principales del código**

init_camera(): Configura los pines, la frecuencia y los ajustes de calidad de imagen (brillo, contraste, saturación) necesarios para inicializar el sensor de la cámara .

inicializarOLED(): Establece la comunicación I2C con la pantalla, verificando las direcciones de memoria (0x3C o 0x3D) para asegurar su correcto encendido .

mostrarMensajeTemporal(mensaje, tamano, tiempo): Despliega texto informativo en la pantalla OLED durante un intervalo definido para dar retroalimentación visual al usuario .

moverServoSuave(anguloObjetivo): Controla el servomotor para que se desplace hacia la posición deseada de manera incremental y fluida, evitando movimientos bruscos.

moverYVolverSuave(anguloObjetivo): Ejecuta la secuencia mecánica completa, llevando el servomotor a la posición de clasificación y retornándolo automáticamente a la posición neutra (100°)

procesarComando(cmd): Interpreta el carácter de clasificación recibido ('B' o 'N') y activa la función mecánica correspondiente para segregar el residuo.

enviarNotificacionDeteccion(): Envía una solicitud HTTP inicial al servidor para notificar que se ha detectado un objeto y preparar el backend .

enviarImagenComoBytes(): Captura la imagen, serializa sus bytes en un JSON, la envía al servidor y procesa la respuesta para determinar si se debe clasificar o reintentar .

enviarDeteccionYClasificacion(): Coordina el flujo lógico de red, ejecutando secuencialmente el envío de la notificación y posteriormente el envío de la imagen .

setup(): Inicializa todos los componentes del sistema (Serial, OLED, Servo, Cámara, WiFi) al arrancar el dispositivo .

loop(): Monitorea cíclicamente el sensor ultrasónico para detectar la presencia de objetos y detonar el proceso de clasificación si se cumplen las condiciones de distancia y tiempo .




Ilustración 7 Diagrama de clases esp32.

- **Lógica de init_camera()**

Configuración de Estructura:

Crea un objeto de configuración (camera_config_t) y asigna los canales de temporizador LEDC.

Mapea todos los pines físicos de la cámara (D0-D7, XCLK, PCLK, VSYNC, HREF, SDA, SCL) a los pines correspondientes del ESP32-S3.

Parámetros de Captura:

Define la frecuencia de reloj XCLK en 20MHz y el formato de píxeles como JPEG.

Establece la resolución de imagen en 240x240 (FRAME_SIZE_240X240) y la calidad de compresión en 10 (donde menor número es mayor calidad).

Configura el almacenamiento del frame buffer en la memoria DRAM.

Inicialización del Driver:

Ejecuta `esp_camera_init()` con la configuración establecida.

Verifica si el resultado es distinto a `ESP_OK`; si hay error, imprime un mensaje y retorna false

Ajustes del Sensor:

Obtiene el puntero del sensor de la cámara para realizar ajustes finos.

Modifica los parámetros de imagen: establece la saturación en 0, reduce el brillo a -2 y aumenta el contraste a 1 para mejorar la definición de bordes.

Retorno:

Devuelve true indicando que la cámara está lista para operar.

- **Lógica de inicializarOLED()**

Reinicio del Bus I2C:

Reinicia la comunicación Wire y la inicia explícitamente con los pines SDA (42) y SCL (41) definidos para este hardware.

Búsqueda de Dirección:

Intenta iniciar la pantalla en la dirección I2C 0x3C.

Si falla, realiza un segundo intento con la dirección 0x3D.

Confirmación Visual:

Si se logra la conexión, limpia el buffer de la pantalla, configura el texto y muestra el mensaje "OLED OK" por un segundo.

Manejo de Errores:

Si ambas direcciones fallan, imprime un error en serial y retorna false.

- **Lógica de mostrarMensajeTemporal(mensaje, tamaño, tiempo)**

Verificación de Pantalla:

Comprueba la variable `displayIniciada` para confirmar que la pantalla OLED se conectó correctamente durante la inicialización (`setup`).

Si la pantalla no fue inicializada, la función termina inmediatamente.

Preparación de Pantalla:

Limpia el buffer de la pantalla (`display.clearDisplay()`) para borrar cualquier mensaje previo.

Establece el color del texto en blanco (`display.setTextColor(SSD1306_WHITE)`) y la posición del cursor en el origen (0, 0).

Configuración de Texto:

Define el tamaño de la fuente (`display.setTextSize(tamano)`) basándose en el argumento de entrada.

Escritura:

Escribe el mensaje de entrada en el buffer de la pantalla mediante `display.print(mensaje)`.

Visualización:

Muestra el contenido del buffer en el hardware de la pantalla con `display.display()`.

Temporización:

Mantiene el mensaje visible durante el tiempo especificado por el parámetro `tiempo` (en milisegundos) usando la función `delay()`.

Limpieza Final:

Limpia de nuevo el buffer de la pantalla (`display.clearDisplay()`) después de la pausa temporal.

- **Lógica de moverServoSuave(anguloObjetivo)**

Lectura de Posición Inicial:

Obtiene la posición actual del servomotor (en grados) usando `servoMotor.read()`.

Asigna esta posición inicial a la variable `anguloActual`.

Determinación de Dirección:

Compara el `anguloObjetivo` con el `anguloActual`.

Establece la dirección del movimiento (incremento) como +1 si el objetivo es mayor, o -1 si el objetivo es menor.

Bucle de Movimiento:

Inicia un bucle while que continúa mientras el `anguloActual` no haya alcanzado el `anguloObjetivo`.

Paso Incremental: Incrementa (o decrementa) el `anguloActual` en la cantidad definida por la velocidad (generalmente 5 grado por paso).

Control del Servo: Envía el nuevo valor del `anguloActual` al servomotor mediante `servoMotor.write(anguloActual)`.

Temporización:

Introduce un pequeño retardo (`delay(10)`) en cada paso para suavizar el movimiento y controlar la velocidad.

Finalización:

Una vez que el `anguloActual` alcanza o supera el `anguloObjetivo`, el bucle termina.

Asegura que el servo quede posicionado exactamente en el `anguloObjetivo` al salir del bucle.

- **Lógica de moverYVolverSuave(int anguloObjetivo)**

Movimiento de Clasificación:

Invoca a la función `moverServoSuave(anguloObjetivo)`.

Esto causa que el servomotor se mueva desde su posición actual (generalmente 100°) hacia el ángulo de clasificación definido (0 para Biodegradable o 180 para No Biodegradable).

Pausa de Segregación:

Aplica una pausa de medio segundo (`delay(500)`).

Este retardo asegura que el servomotor permanezca en la posición de clasificación el tiempo suficiente para que el residuo caiga en el contenedor correspondiente.

Retorno a Posición Neutra:

Invoca nuevamente a la función `moverServoSuave(100°)`.

Esto hace que el servomotor regrese a la posición central (100°), dejando el sistema listo para la siguiente detección y evitando el bloqueo del mecanismo.

- **Lógica de procesarComando(cmd)**

Validación de Entrada:

Recorre el arreglo de comandos válidos ({'B', 'N'}) para verificar si el carácter recibido coincide.

Ejecución Mecánica:

Si hay coincidencia, llama a moverYVolverSuave() pasando el ángulo correspondiente (0° o 180°) según el índice del comando.

Retroalimentación Visual:

Si el comando es 'B', muestra "Basura Biodegradable" en la OLED; si es 'N', muestra "Basura No-Biodegradable".

Manejo de Error:

Si el comando no es reconocido, muestra un mensaje de error en la pantalla indicando clasificación inválida.

- **Logica de enviarNotificacionDeteccion()**

Inicialización HTTP:

Crea una instancia de HTTPClient y establece la conexión con la URL del servidor (serverUrl).

Configura la cabecera HTTP Content-Type como application/json para indicar el formato de los datos que se van a enviar.

Construcción JSON:

Crea un documento JSON estático (StaticJsonDocument) de 512 bytes, suficiente para la carga útil.

Define el par clave-valor {"evento": "objeto identificado"} en el documento JSON, que es la señal que espera el servidor para iniciar el proceso de clasificación.

Serializa el documento JSON a un String (jsonPayload) listo para la transmisión.

Envío y Validación:

Envía la petición HTTP POST con el jsonPayload serializado.

Almacena el código de respuesta HTTP (httpResponseCode).

Manejo de Errores:

Si el httpResponseCode es positivo (generalmente 200), la notificación se considera exitosa y se imprime el código en la consola serial.

Si el código es negativo (indicando un error de conexión o envío), imprime el error en la consola y muestra "Error Notificacion" en la pantalla OLED.

Limpieza:

Cierra la conexión HTTP con `http.end()` para liberar los recursos de red utilizados por la solicitud .

- **Logica de enviarImagenComoBytes()**

Captura de Imagen:

Obtiene el frame buffer actual de la cámara mediante `esp_camera_fb_get()`.

Introduce una pausa de estabilización de 500ms para asegurar la integridad de los datos.

Valida que la captura sea exitosa; si el puntero del buffer (fb) es nulo, aborta la función inmediatamente para evitar errores de memoria.

Serialización JSON:

Calcula el tamaño necesario para el documento JSON (tamaño de la imagen + 1024 bytes de cabecera) y crea un `DynamicJsonDocument`.

Define el tipo de evento como "imagen bytes" y agrega un campo "tamano_imagen" con la longitud total del buffer.

Crea un arreglo anidado (`imagen_bytes`) e itera byte por byte sobre el buffer de la imagen para llenarlo.

Transmisión HTTP:

Inicializa un cliente HTTP, configura la cabecera `Content-Type: application/json` y establece un tiempo de espera (timeout) de 15 segundos.

Serializa el documento JSON a un String y lo envía mediante una petición POST al servidor.

Procesamiento de Respuesta:

Si el código HTTP es positivo, descarga el cuerpo de la respuesta (`http.getString()`) e intenta deserializar el JSON recibido.

Manejo de Estados:

Caso "reintentar": Si el servidor devuelve confianza insuficiente, extrae el mensaje y el valor de confianza. Muestra "Confianza baja" en la pantalla OLED y aplica una espera de 3 segundos antes de continuar.

Caso "ok": Si la clasificación es exitosa, extrae el carácter de clasificación. Valida que sea exactamente un carácter ('B' o 'N') antes de llamar a procesarComando(). Si el carácter no es válido, muestra un error en pantalla.

Errores de Parseo: Si la respuesta no es un JSON válido o el estado es desconocido, alerta sobre "Error respuesta del servidor" en la OLED.

Error de Envío: Si la petición HTTP falla (código de error negativo), imprime la causa en el monitor serial y muestra "Error envio imagen" en la pantalla OLED.

Limpieza:

Libera obligatoriamente la memoria del frame buffer usando `esp_camera_fb_return(fb)` para prevenir fugas de memoria en el ESP32.

Cierra la conexión HTTP con `http.end()` para liberar recursos de red .

- **Lógica de enviarDeteccionYClasificacion()**

Verificación de Conexión:

Comprueba el estado de la conexión WiFi (`WiFi.status()`).

Notificación al Servidor:

Invoca a la función `enviarNotificacionDeteccion()`.

Este paso es una señal rápida al servidor Python que establece el evento: "objeto identificado", indicando que la secuencia de clasificación va a comenzar.

Retraso:

Genera un retraso de 2 segundos para que haya un tiempo de espera para el vaciado del buffer del anterior frame.

Procesamiento de Imagen:

Invoca a la función `enviarImagenComoBytes()`.

Este paso es el flujo pesado que ejecuta la captura de imagen, la serialización en JSON, la transmisión HTTP y el manejo de la respuesta.

Actualización de Estado (Implícita):

Después de completar todo el proceso, el control regresa al `loop()`, y la variable `ultima_deteccion` se actualiza para evitar que el proceso se dispare inmediatamente de nuevo (debounce).




Ilustración 8 Diagrama secuencia de esp32 y servidor.

- **Lógica de loop()**

Monitoreo de Sensor:

Calcula el tiempo actual y realiza una lectura de distancia en centímetros usando el objeto sonar.

Evaluación de Condiciones:

Verifica tres condiciones simultáneas: que la distancia sea válida (>0), que esté dentro del rango máximo (10cm), y que hayan pasado más de 3 segundos desde la última detección.

Disparo de Acción:

Si se cumplen las condiciones, notifica en la pantalla "Objeto detectado".

Invoca la función `enviarDeteccionYClasificacion()` para iniciar el proceso de red .




Ilustración 9 Diagrama de flujo del loop esp32.

- **Lógica de setup()**

Inicialización de Comunicación Serial:

Inicia la comunicación serial a 115200 baudios (`Serial.begin(115200)`) para permitir el debugging y la impresión de estados.

Inicialización de OLED:

Llama a inicializarOLED () para configurar el bus I2C y la pantalla.

Si la inicialización falla, imprime el mensaje de error "OLED Fallo" en la consola serial y aborta la ejecución para evitar errores posteriores.

Configuración del Servomotor:

Asigna el objeto servoMotor al pin GPIO 3 (SERVO_PIN) mediante servoMotor.attach().

Mueve el servo a la posición neutra inicial de 100 grados (servoMotor.write(100)) y añade un breve retardo de 500ms para estabilizar el componente.

Inicialización de la Cámara:

Muestra el mensaje "Iniciando camara" en la pantalla OLED.

Llama a la función init_camera() para configurar el sensor .

Validación de Cámara: Si init_camera() retorna false (fallo), imprime "Fallo inicializacion camara" y muestra "Error Camara" en la OLED. Si es exitosa, imprime y muestra "Camara OK".

Conexión WiFi:

Imprime "Conectando a WiFi..." en la consola y muestra "Conectando WiFi" en la OLED.

Inicia la conexión (WiFi.begin(ssid, password)) usando las credenciales definidas.

Bucle de Espera: Entra en un bucle que espera hasta que el estado sea WL_CONNECTED o hasta que se exceda el límite de 20 intentos (con una pausa de 500ms en cada intento).

Validación de WiFi:

Si la conexión es exitosa, imprime la dirección IP local en la consola y muestra "WiFi OK" junto con la IP en la pantalla OLED.

Si la conexión falla después de los 20 intentos, imprime "Error WiFi" en la consola y muestra un mensaje de error en la pantalla.

Finalización:

Finaliza el proceso de configuración con los mensajes "Sistema listo" en la consola y la pantalla OLED.

El programa procede a ejecutar la función loop().

- **Resumen de funcionalidad**

Funcionalidad / Método	Descripción Técnica
Configuración del microcontrolador loadModel(ruta_modelo)	Inicialización de todo el hardware (WiFi, Cámara, OLED, Servomotor) al encender el dispositivo.
Ciclo de control loop()	Ciclo de control principal. Monitorea continuamente el sensor ultrasónico.
Iniciador de cámara init_camera()	Configura los pines, formato (JPEG 240x240), y ajusta los parámetros ópticos (brillo, contraste) del sensor de la cámara. Retorna true si es exitosa.
Iniciador de pantalla Okled inicializarOLED()	Inicializa la comunicación I2C y el driver de la pantalla OLED. Retorna true si la pantalla es detectada.
Controlador de mensajes mostrarMensajeTemporal(...)	Despliega un mensaje específico en la pantalla OLED, lo mantiene visible durante el tiempo definido y luego limpia el display .
Notificación inicial enviarNotificacionDeteccion()	Envía una petición POST inicial al servidor con el evento "objeto identificado" para alertar que el proceso de captura va a comenzar.
Captura y transformación de bytes enviarImagenComoBytes()	Captura la imagen, la serializa en un array JSON, la envía al servidor, procesa la respuesta (ok/reintentar) y libera el frame buffer.
Manejador de mensajes enviarDeteccionYClasificacion()	Función orquestadora que llama a enviarNotificacionDeteccion() y enviarImagenComoBytes().
Procesamiento de la clasificación procesarComando(cmd)	Traduce el carácter recibido del servidor ('B' o 'N') a una acción mecánica, llamando a la función de movimiento del servo y actualizando la OLED.
Control suave de servo motor moverServoSuave(...)	Mueve el servomotor de su posición actual al anguloObjetivo de forma gradual (incremental) para asegurar la suavidad del movimiento.
Regreso a la posición del servomotor moverYVolverSuave(...)	Ejecuta la secuencia mecánica completa: va al ángulo de clasificación, espera un momento y retorna a la posición neutra (100°).

Tabla 10 Funcionalidad de Esp32ToPythonOledHttpCAM.

4.3.2 Módulo Python: appHTTP.py.

Este módulo implementa un servidor web utilizando el framework Flask para exponer el sistema de clasificación de imágenes y permitir su monitoreo en tiempo real.

El código integra la funcionalidad de la clase Manejador para procesar las peticiones de inferencia del modelo de inteligencia artificial (cargado desde un archivo .h5) y presentar los resultados en una interfaz gráfica. Está diseñado para gestionar la concurrencia y utiliza técnicas de Long Polling, garantizando que la visualización de los datos clasificados se actualice dinámicamente y al instante en el navegador del usuario sin necesidad de recargas manuales.

- **Paqueterías**

Flask: Para el despliegue del servidor web, la gestión de solicitudes HTTP (GET/POST), la renderización de plantillas HTML y la estructuración de respuestas en formato JSON.

Time: Para el control de la ejecución temporal, gestión de timestamps y manejo de intervalos de espera en la lógica de actualización en tiempo real (Long Polling).

Módulo externo ManejadorHTTP: Interfaz personalizada que encapsula la lógica de TensorFlow/Keras, permitiendo la carga del modelo .h5 y la gestión de las predicciones fuera del hilo principal del servidor.

- **Variables predefinidas y su significado**

Variable / Constante	Tipo	Propósito
<code>app = Flask(__name__)</code>	Instancia de Objeto Flask	Inicializar la aplicación web, configurar el servidor y gestionar el enrutamiento de las peticiones HTTP (GET/POST).
<code>alpha = Manejador(modelo="")</code>	Objeto de clase	Gestionar la lógica de IA, cargando el modelo .h5 y procesando las solicitudes de clasificación de imágenes recibidas.
<code>ultima_actualizacion = 0</code>	Int (luego Float)	Controlar la sincronización en tiempo real; actúa como una bandera temporal para que el cliente sepa cuándo actualizar la interfaz (Long Polling).

Tabla 11 Definición de variables iniciales appHTTP.

- **Métodos Principales**

Index(): Despliega la interfaz de usuario principal. Valida el estado actual del diccionario de identificación y renderiza la plantilla HTML (index.html), inyectando los resultados de la clasificación o un estado de espera inicial ("Esperando detección...") si no hay datos previos.

clasificar_objeto(): Procesa las solicitudes HTTP POST entrantes para la inferencia. Coordina la comunicación con el objeto **alpha** para recibir la imagen y ejecutar la predicción, actualizando posteriormente la marca de tiempo global (ultima_actualizacion) para sincronizar a los clientes conectados.

verificar_actualizacion(): Gestiona la comunicación en tiempo real mediante la técnica de Long Polling. Mantiene la conexión activa en un bucle controlado (con timeout de 30s) comparando timestamps, y retorna una respuesta JSON solo cuando detecta que el modelo ha generado una nueva clasificación.

if __name__ == '__main__': Inicializa el servidor Flask en el puerto 5000. Obtiene la dirección IP dinámica mediante **alpha.getIpServidor()** y habilita el soporte para múltiples hilos (threaded=True), permitiendo manejar peticiones de clasificación y actualización simultáneamente.

- **Lógica de Index():**

Estado: "Inicial o Sin Detección"

Valida si el atributo `alpha.diccionarioidentificacion` es `None` (aún no se ha procesado ninguna imagen).

Construye un diccionario local (`resultado_default`) estableciendo valores de espera: clase "Esperando detección...", probabilidad 0.0 y la ruta a una imagen de marcador de posición (`placeholder.jpg`).

Retorna la plantilla HTML renderizada (`index.html`) inyectando este diccionario por defecto para mostrar una interfaz de estado 'en espera'.

Estado: "Con Resultados Previos"

Se ejecuta implícitamente si `alpha.diccionarioidentificacion` contiene datos.

Retorna la plantilla HTML (`index.html`), pasando directamente el objeto `alpha.diccionarioidentificacion` al contexto de la vista para desplegar la imagen real procesada, la clase detectada y su porcentaje de certeza."

- **Lógica de clasificar_objeto():**

Acceso Global: Se declara la variable `ultima_actualizacion` como global para garantizar que su valor pueda ser modificado, habilitando el mecanismo de notificación de nuevos datos.

Recepción de Datos: Ejecuta el método `alpha.recepcionMensaje()` para parsear y preparar los datos de la imagen recibidos en el cuerpo de la petición POST del cliente.

Ejecución de Clasificación: Llama a `alpha.enviarMensaje()`, que dispara la lógica de inferencia del modelo de IA (contenida en la clase `ManejadorHTTP`) y obtiene el resultado de la clasificación.

Sincronización: Actualiza la variable `ultima_actualizacion` con el timestamp actual (`time.time()`), señalizando a los clientes que usan Long Polling que hay un nuevo resultado disponible.

Retorno: Devuelve la respuesta JSON generada por el manejador (que contiene el resultado de la clasificación o el estado del proceso) junto con el código de estado HTTP correspondiente.

- **Lógica de verificar_actualizacion():**

Inicialización y Recepción de Parámetros

Obtiene el valor de la marca de tiempo del cliente (`timestamp_cliente`) a partir de los argumentos de la URL (`request.args.get('timestamp')`). Este valor representa el momento de la última actualización que el cliente posee.

Establece un límite de tiempo máximo de espera (timeout = 30 segundos) para evitar que la conexión del navegador se cuelgue o expire.

Almacena el tiempo actual en la variable inicio (time.time()) para monitorizar la duración del ciclo de espera.

Ciclo de Espera (Long Polling Bucle while)

El servidor entra en un bucle infinito que comprueba continuamente si la marca de tiempo global del servidor (ultima_actualizacion) es mayor que el timestamp_cliente recibido.

Si hay nuevos datos (el servidor predijo algo después de la última vez que el cliente preguntó), se cumple el bloque:

Confirma que **alpha.diccionarioidentificacion** contenga un resultado real (no el placeholder "Esperando detección...").

Retorna inmediatamente una respuesta JSON indicando 'actualizado': True, incluyendo el nuevo timestamp y los datos de clasificación (**alpha.diccionarioidentificacion**). El ciclo termina.

Condición de Timeout

Comprueba si el tiempo transcurrido desde el inicio ha superado el timeout (30 segundos).

Si Supera el Timeout Retorna una respuesta JSON indicando 'actualizado': False. Esto libera la conexión del navegador y le permite realizar una nueva petición de Long Polling inmediatamente después. El ciclo termina.

Control del Bucle

Si ninguna de las condiciones anteriores se cumple, el método induce una pausa mínima (time.sleep(0.5)) para reducir la carga de la CPU antes de volver a verificar las condiciones, manteniendo la conexión en espera.




Ilustración 10 Diagrama secuencia Long Polling.

- **Lógica de main():**

Implementación de Manejo de Errores (try-except):

Intenta iniciar el servidor Flask para el servicio de inferencia.

Si el servidor no puede iniciarse (por ejemplo, si el puerto está ocupado o hay un problema de red), captura la excepción y ejecuta el código dentro del bloque.

Configuración e Inicio del Servidor:

Llama a `app.run()`, usando `alpha.getIpServidor()` para determinar la dirección IP de host y el puerto 5000 para la escucha.

`debug=False`: Deshabilita el modo de depuración de Flask, lo cual es apropiado para entornos de producción/despliegue.

`threaded=True`: Habilita el manejo multi-hilo, permitiendo que el servidor procese múltiples peticiones de clientes de manera concurrente (por ejemplo, atendiendo una clasificación POST mientras maneja una petición de Long Polling GET).

Manejo de Excepciones:

Si ocurre un error al iniciar el servidor (e.g., `PortAlreadyInUseError`), el bloque `except` lo captura.

Imprime un mensaje en la consola (`print(f"Error al iniciar el servidor: {e}")`) indicando que el servidor no pudo arrancar, mostrando el error específico que ocurrió.

- **Resumen de funcionalidad**

Funcionalidad / Método	Descripción Técnica
Página principal index()	Muestra la página web principal (index.html). Si hay resultados de clasificación disponibles, los muestra; si no, muestra un mensaje de espera.
Manejador de respuestas del backend clasificar_objeto()	Recibe una solicitud y la procesa para realizar una clasificación o identificación. Luego, envía una respuesta con el resultado.
Confirmación de nuevo objeto verificar_actualizacion()	Permite que el cliente (navegador) compruebe si hay nuevos resultados de clasificación. Utiliza un bucle de espera (Long Polling) para enviar el resultado tan pronto como esté disponible, o después de un tiempo de espera.
Iniciador de servidor if __name__ == '__main__':	Es el punto de entrada principal del programa. Inicia el servidor web Flask para que la aplicación esté disponible en la red.

Tabla 12 Resumen funcionalidad main




Ilustración 11 Diagrama de clases Python.

4.3.3 Módulo Python: pruebaModelosTF.py.

Este módulo permite realizar la clasificación automática de imágenes en dos categorías: biodegradable y no biodegradable, utilizando un modelo de inteligencia artificial previamente entrenado en TensorFlow/Keras.

El código encapsula la funcionalidad en una clase orientada a objetos (**pruebaModeloIA**) que gestiona la carga del modelo, el procesamiento de imágenes, la predicción y la visualización de resultados. Está diseñado para ser modular, fácil de usar y adaptable a distintos modelos de red neuronal preentrenados (ej. ResNet, MobileNet, etc.).

- **Paqueterías**

TensorFlow / Keras : Para cargar y ejecutar el modelo entrenado.

NumPy : Manipulación de arreglos numéricos.

Matplotlib : Visualización de resultados.

OS : Manejo de rutas de archivos.

- **Clase: pruebaModeloIA**

La clase pruebaModeloIA actúa como un módulo de procesamiento autónomo encargado de gestionar todo el flujo de clasificación de imágenes, desde la carga del modelo de Inteligencia Artificial hasta la visualización de los resultados. Su diseño orientado a objetos encapsula y organiza de forma secuencial las tareas esenciales del pipeline de la Red Neuronal Convolucional (RNC).

- **Inicialización (__init__)**

Atributo	Tipo	Descripción
Self.modelo	Modelo de tensorflow	Guardar el modelo en una variable global lista para usarse en el sistema
Self.clases	array	Un diccionario que contiene las clases, sirve para mapear los resultados dados por el modelo de IA

Tabla 13 Atributos del constructo de "pruebaModelosIATF".

- **Métodos Principales**

loadModel(ruta_modelo): Carga el modelo de inteligencia artificial desde un archivo .h5 para su uso en las predicciones.

processImage(imagen): Preprocesa la imagen de entrada, adaptándola al formato y tamaño requeridos por el modelo.

predictImage(img_array): Realiza la predicción sobre la imagen procesada y determina la clase más probable junto con su nivel de confianza.

showResults(imagen, prediccion): Muestra la imagen original con el resultado de la clasificación superpuesto en pantalla.

run(imagen): Ejecuta el flujo completo de clasificación (procesamiento, predicción y visualización) en una sola llamada.

- **Lógica de loadModel (ruta_modelo)**

Carga un modelo previamente entrenado en formato .h5 desde el almacenamiento local.

Usa la librería tensorflow.keras.models.load_model() para reconstruir la arquitectura, pesos y configuración del modelo.

Verifica que la carga sea exitosa antes de continuar.

Devuelve el modelo ya preparado para hacer inferencias.

- **Lógica de processImage (imagen)**

Recibe la ruta de una imagen como entrada.

Abre la imagen y la redimensiona al tamaño de entrada del modelo.

Convierte la imagen a un arreglo NumPy y aplica normalización de valores.

Expande las dimensiones del tensor (de 3D a 4D) para que el modelo lo interprete como un lote de una sola imagen.

Devuelve la imagen procesada lista para ser clasificada.

- **Lógica de predictImage (img_array)**

Recibe una imagen ya procesada por processImage().

Usa el modelo cargado para hacer una predicción (model.predict()).

Obtiene las probabilidades de cada clase (por ejemplo, biodegradable o no biodegradable).

Selecciona la clase con mayor probabilidad como resultado final.

Devuelve el nombre de la clase detectada y el porcentaje de confianza.

- **Lógica de showResults (imagen, prediccion)**

Recibe la imagen original y la etiqueta predicha.

Usa OpenCV (cv2.putText) para escribir en la imagen el nombre de la clase y el nivel de confianza.

Muestra la imagen en una ventana gráfica (cv2.imshow).

Espera la interacción del usuario para cerrar la ventana.

- **Lógica de run (imagen)**

Ejecuta de forma secuencial los métodos anteriores (processImage(), predictImage(), showResults()).

Controla el flujo completo desde la entrada de una imagen hasta la visualización del resultado.

Puede utilizarse como punto de entrada para automatizar pruebas o ejecuciones rápidas.

- **Resumen de funcionalidad**

Funcionalidad / Método	Descripción Técnica
Carga del Modelo loadModel(ruta_modelo)	Carga el modelo de Inteligencia Artificial desde un archivo .h5 almacenado localmente. Utiliza tensorflow.keras.models.load_model() para reconstruir la arquitectura, pesos y configuración necesaria para realizar inferencias.
Preprocesamiento processImage(imagen)	Adapta la imagen de entrada a los requisitos del modelo. Esto incluye redimensionar la imagen, convertirla a un arreglo NumPy, normalizar los valores y expandir las dimensiones del tensor (de 3D a 4D) para simular un lote de una sola imagen.
Inferencia y Predicción predictImage(img_array)	Realiza la predicción utilizando la imagen procesada mediante model.predict(). Calcula las probabilidades de cada clase, selecciona la mayor y retorna tanto la etiqueta de la clase detectada como el porcentaje de confianza.
Visualización showResults(imagen, prediccion)	Muestra la imagen original con el resultado de la clasificación superpuesto. Utiliza OpenCV (cv2.putText y cv2.imshow) para escribir la clase y la confianza sobre la imagen y presentarla en una ventana gráfica.
Ejecución de Flujo run(imagen)	Actúa como orquestador, ejecutando secuencialmente el preprocesamiento, la predicción y la visualización en una sola llamada para automatizar el flujo completo.

Tabla 14 Funcionalidad de pruebaModelosTF.

4.3.4 Módulo Python: ManejadorHTTP.py.

Este módulo forma parte del backend del sistema de clasificación inteligente de residuos. Es responsable de la comunicación entre el microcontrolador ESP32-S3 CAM y el modelo de inteligencia artificial alojado en un servidor Flask.

Se ejecuta de manera local creando un endpoint para que se pueda conectar el microcontrolador ESP32, procesando peticiones HTTP y devolviendo respuestas con la clasificación del objeto detectado.

- **Paqueterías:**

Datetime: Módulo estándar de Python para manipular fechas y horas.

io (BytesIO): Módulo para trabajar con flujos de E/S (Input/Output) en memoria (como si fueran archivos), pero usando cadenas o bytes.

Uuid: Genera Identificadores Únicos Universales (UUIDs), que son números aleatorios de 128 bits.

Os: para manejo de archivos y directorios.

Flask: Un framework liviano para construir aplicaciones web en Python.

request (de flask): Objeto que proporciona acceso a los datos entrantes de la petición HTTP, como el cuerpo del mensaje y el formato.

jsonify (de flask): Ayuda a crear respuestas JSON para las peticiones HTTP.

Módulo externo static.pruebaModelos: Contiene la clase **pruebaModeloIA**, encargada del preprocesamiento de imágenes y de la inferencia con el modelo entrenado.

processImage(imagen): Convierte bytes a formato compatible con TensorFlow.

predictImage(imagen_procesada): Retorna un diccionario con las claves "clase" y "probabilidad".

socket: Módulo estándar de Python que proporciona acceso a la interfaz de sockets de red.

- **Clase: Manejador**

Esta clase gestiona la recepción de datos JSON del ESP32, coordina la inferencia del modelo de IA, maneja la persistencia de imágenes capturadas y formula la respuesta que se envía de vuelta al dispositivo.

- **Inicialización (__init__)**

Atributo	Tipo	Descripción
modelo (Argumento)	str	Ruta al archivo del modelo de Keras/TensorFlow a cargar.
self.bravo.pruebaModeloIA	Objeto de clase	Instancia de la clase pruebaModeloIA que maneja la lógica de la IA.
self.data	dict o None	Contenido JSON de la última solicitud recibida.
self.diccionarioIdentificacion	dict o None	Último resultado completo de la predicción de la IA.
self.ultimaimagenCapturada	str o None	Ruta del sistema de archivos donde se guardó la última imagen.
self.imagenes_dir	str	Ruta de la carpeta donde se guardan las imágenes (por defecto: 'Programacion/static/imagenes').
self.imagen	str o None	Almacena la ruta temporal de la imagen actual que se está procesando.
self.no_biodegradables	list	Lista de etiquetas que se clasifican como 'N' ("No biodegradable", "plastico", "metal", "vidrio").

Tabla 15 Atributos del constructo de "manejadorHTTP".

- **Métodos Principales**

recepcionMensaje(): Recepción y Validación. Verifica si la solicitud entrante es de formato JSON. Si es válido, almacena el contenido en self.data y lo devuelve. En caso contrario, retorna un error HTTP 400.

getIpServidor(): Utilidad de Red. Obtiene la dirección IP local del servidor de forma programática.

guardarImagen(imagen_bytes): Persistencia de Datos. Crea un nombre de archivo único utilizando un timestamp y un UUID, y guarda los bytes de la imagen JPEG recibida en el directorio configurado (self.imagenes_dir). Retorna la ruta completa del archivo guardado.

enviarMensaje(): Este método representa la Lógica Central del servidor Python. Procesa el contenido JSON que ha sido previamente almacenado en self.data por recepcionMensaje(), utilizando la clave "evento" para determinar el flujo de trabajo a seguir.

- **Flujo de errores y respuestas HTTP**

Código HTTP	Descripción	Caso
200	Éxito	Clasificación completada o reintento solicitado
400	Solicitud inválida	Datos incompletos o formato JSON incorrecto
500	Error interno del servidor	Falla al procesar o guardar imagen

Tabla 16 Significado códigos http.

- **Lógica de enviarMensaje()**

El método `enviarMensaje` maneja dos flujos de trabajo principales, correspondientes a las dos peticiones HTTP que envía el ESP32:

Evento: "objeto identificado"

Imprime un mensaje en consola indicando que el proceso de detección ha comenzado.

Retorna {"status": "ok", "message": "Notificación recibida"} con un código de estado 200.

Evento: "imagen bytes"

Valida que el array de bytes ("imagen_bytes") exista en el JSON recibido; si no, retorna error 400.

Delega el procesamiento complejo llamando al método **`self.logicaRecepcionImagen(imagen_bytes_array)`**.

Implementa un bloque try-except para capturar errores imprevistos durante el procesamiento de imagen (retornando error 500 si falla).

Evento Desconocido

Si el evento no coincide con los anteriores, retorna un mensaje de error indicando "Evento no reconocido" (código 400).

- **Lógica de logicaRecepcionImagen (imagen_bytes_array)**

Conversión de Datos:

Recibe el array de enteros proveniente de la solicitud JSON.

Convierte este array en un objeto de bytes puro para su manipulación.

Persistencia:

Invoca a `self.guardarImagen()` para almacenar el archivo físicamente y actualiza `self.ultimaimagenCapturada`.

Interacción con Modelo IA:

Llama a `self.bravo.processImage()` pasando la ruta de la imagen guardada para adaptarla a los tensores del modelo.

Ejecuta `self.bravo.predictImage()` para obtener el diccionario con la clase y la probabilidad.

Evaluación de Confianza (Umbral ≤ 0.60):

Si la probabilidad detectada es menor o igual al 60%, se considera insuficiente.

Actualiza `self.diccionarioIdentificacion` indicando "Objeto no identificado".

Retorna un JSON con estado "reintentar" y la confianza actual.

Clasificación Final (Umbral > 0.60):

Si la confianza es suficiente, verifica si la etiqueta detectada (ej. "vidrio", "plastico") se encuentra en la lista `self.no_biodegradables`.

Asigna "N" (No Biodegradable) si hay coincidencia, o "B" (Biodegradable) en caso contrario.

Retorna un JSON con estado "ok", la clasificación ("B" o "N") y la clase específica detectada.

- **Lógica de recepcionMensaje()**

Validación JSON

Verifica si la solicitud entrante (`request`) está en formato JSON utilizando `request.is_json`.

Manejo de Error

Si no es JSON, imprime un mensaje de error en consola y retorna una respuesta JSON de error ("Se espera JSON") con el código de estado HTTP 400 (Bad Request).

Extracción de Datos

Si es JSON válido, extrae los datos del cuerpo de la solicitud utilizando `request.get_json()`.

Almacenamiento

Almacena los datos JSON extraídos en el atributo de instancia `self.data`.

Retorno Exitoso

Retorna los datos JSON almacenados (`self.data`).

- **Lógica de getIpServidor()**

Creación del Socket

Intenta crear un socket de Internet (AF_INET) de datagrama (SOCK_DGRAM).

Conexión Simulación

Se conecta al servidor DNS de Google ("8.8.8.8", puerto 80). Nota: Esta conexión no envía datos, solo establece la ruta de red necesaria para que el sistema operativo asigne una IP de origen.

Obtención de IP

Recupera la dirección IP local utilizada para la conexión a través de s.getsockname()[0].

Cierre del Socket

Cierra la conexión del socket (s.close()).

Retorno Exitoso

Retorna la dirección IP local obtenida.

Manejo de Error

Si ocurre cualquier excepción (ej. sin conexión de red), retorna la cadena "0.0.0.0"

- **Lógica de guardarImagen(imagen_bytes)**

Verificación de Directorio

Verifica si el directorio de imágenes (self.imagenes_dir) existe.

Creación de Directorio

Si no existe, lo crea recursivamente (os.makedirs).

Generación de Nombre Único

Genera un nombre de archivo único componiendo:

Un timestamp de la hora actual (YYYYMMDD_HHMMSS).

Un identificador único de 8 caracteres (uuid.uuid4()[:8]).

El prefijo "waste_" y la extensión ".jpg".

Construcción de Ruta

Combina el directorio (`self.imagenes_dir`) y el nombre de archivo (`filename`) para obtener la ruta completa del archivo (`filepath`).

Escritura del Archivo

Abre el archivo en modo de escritura binaria ('wb') y escribe los `imagen_bytes` proporcionados en el archivo.

Retorno Exitoso

Retorna la ruta completa (`filepath`) donde se guardó la imagen.

Manejo de Error

Si ocurre una excepción durante el proceso (ej. error de I/O), imprime el error en consola y retorna `None`.

- **Resumen de Funcionalidad**

Funcionalidad / Método	Descripción Técnica
Inicialización __init__(modelo)	Configura el manejador instanciando la clase pruebaModeloIA con el modelo especificado. Define las rutas de almacenamiento y establece la lista de categorías consideradas "No biodegradables" (plástico, metal, vidrio).
Validación de Solicitud recepcionMensaje()	Verifica que la solicitud HTTP entrante tenga el formato correcto (application/json). Si es válida, extrae y almacena los datos; de lo contrario, rechaza la petición con un código de estado 400.
Enrutamiento de Eventos enviarMensaje()	Actúa como el controlador principal. Analiza la clave "evento" del JSON recibido para determinar si se trata de una simple notificación ("objeto identificado") o de un procesamiento de imagen ("imagen bytes"), delegando la lógica o respondiendo errores según corresponda.
Lógica de Clasificación logicaRecepcionImagen(bytes)	Ejecuta el flujo crítico: convierte el array de bytes a imagen, la guarda en disco, invoca al modelo de IA y aplica la lógica de negocio. Determina si el residuo es "B" o "N" basándose en la clase detectada y el umbral de confianza (> 0.60).
Persistencia de Archivos guardarImagen(imagen_bytes)	Genera un nombre de archivo único utilizando un timestamp y un UUID para evitar colisiones. Escribe los datos binarios de la imagen en el directorio static/imagenes para su posterior auditoría o reentrenamiento.
Utilidad de Red getIpServidor()	Determina la dirección IP local del servidor abriendo una conexión socket temporal (sin envío de datos reales) hacia un servidor DNS externo (8.8.8.8). Permite identificar dinámicamente dónde está alojado el servicio.

Tabla 17 Funcionalidad: ManejadorHTTP.

4.4 Diseño del Modelo de Inteligencia Artificial

A lo largo del desarrollo del prototipo se crearon dos interfaces principales de inteligencia artificial, las cuales son: ResNet50 y MobileNetV2.

4.4.1 Elección de arquitectura de inteligencia artificial.

La fase inicial del desarrollo se centró en la implementación de un modelo de inteligencia artificial (IA) basado en la arquitectura ResNet50. Se partió de la hipótesis de que la reconocida capacidad de generalización y la profundidad de capas de esta red neuronal convolucional (CNN) proporcionarían la precisión predictiva necesaria para la tarea de procesamiento de imágenes del prototipo.

No obstante, las pruebas experimentales revelaron limitaciones significativas en la viabilidad operativa de ResNet50 para este sistema específico. Se observó una desproporción entre el costo computacional y la ganancia en precisión, lo que resultaba en tiempos de inferencia elevados que afectaban la latencia de respuesta hacia el microcontrolador ESP32-S3.

Ante este escenario, se determinó migrar hacia una arquitectura optimizada para la eficiencia sin sacrificar significativamente la precisión: MobileNetV2. La transición a este modelo demostró una mejora sustancial en el rendimiento del sistema, logrando un equilibrio óptimo entre velocidad de procesamiento en el servidor y exactitud en la clasificación. En consecuencia, se estableció MobileNetV2 como la arquitectura definitiva para la etapa de inferencia, procediendo posteriormente a la selección y curación del conjunto de datos (dataset) funcional.

4.4.2 Selección y evolución del dataset

El rendimiento de un modelo de aprendizaje profundo es intrínsecamente dependiente de la calidad y representatividad de los datos con los que se entrena. Para este proyecto, la conformación del conjunto de datos (dataset) no fue estática, sino que siguió un proceso iterativo de cuatro etapas, evolucionando desde datos genéricos hasta una adaptación específica al dominio del prototipo.

Primera iteración: datos sintéticos y de stock

En una primera instancia, la fase de entrenamiento se fundamentó en el conjunto de datos "Non and Biodegradable Material Dataset", curado por Rayhan Zamzamy. Este dataset se utilizó inicialmente para entrenar el modelo preliminar (basado en ResNet50). Sin embargo, las pruebas de campo evidenciaron una deficiencia crítica: el modelo sufría de una alta tasa de error al procesar imágenes capturadas por el prototipo. Se determinó que la causa raíz era la naturaleza de las imágenes del dataset: fotografías de stock con iluminación perfecta y fondos limpios, aunque eran un gran número de imágenes aun presentaban una discrepancia significativa respecto a las condiciones reales de operación del sistema.

Segunda Iteración: Transición a Imágenes Reales (trashnet)

Reconociendo la debilidad de los datos sintéticos, se procedió a sustituir la fuente de entrenamiento por el dataset "TrashNet" de Feyza Ozkefe. Este conjunto representó una mejora cualitativa al contener fotografías de residuos reales en lugar de imágenes de stock. A pesar de utilizar objetos físicos reales, el modelo resultante aún presentaba brechas importantes en la clasificación. El análisis sugirió que, aunque los objetos eran correctos, el entorno (fondo, ángulo y distorsión de la cámara del ESP32-S3) difería demasiado del entorno controlado en el que se capturó TrashNet.

Tercera Iteración: Fusión de Datos

Con el objetivo de mejorar la capacidad de generalización del modelo, se implementó una estrategia de fusión de datos. Se integró el dataset "RealWaste Image Classification" de Joakim Arvidsson junto con el conjunto "TrashNet" previamente utilizado. Esta fusión incrementó el volumen de datos y la variabilidad de las muestras, logrando un mejor rendimiento teórico en las métricas de validación. No obstante, al desplegar el modelo en el prototipo final, la identificación de los tipos de objetos continuaba fallando en escenarios específicos. El sistema carecía de la capacidad para interpretar las particularidades visuales únicas del contenedor y la cámara del dispositivo.

Cuarta Iteración: Adaptación de Dominio y Fine-Tuning

Finalmente, para la cuarta y definitiva iteración, se optó por una estrategia de Adaptación de Dominio Iterativa (Iterative Domain Technique). Esta metodología consistió en la recolección manual de un subconjunto de datos personalizado ("custom dataset"), capturando 200 imágenes por categoría directamente desde la cámara del ESP32-S3 en su entorno de operación real.

Utilizando este nuevo conjunto de datos, se aplicó una técnica de Ajuste Fino (Fine-Tuning) sobre la arquitectura MobileNetV2 previamente seleccionada. Este proceso permitió:

- **Retener el conocimiento previo:** Se conservaron los pesos y características aprendidas de los datasets anteriores (TrashNet + RealWaste).
- **Adaptación al entorno:** La red neuronal ajustó sus capas finales para reconocer los patrones específicos de iluminación, perspectiva y ruido del sensor del prototipo.

El resultado fue un modelo capaz de reconocer patrones del mundo real con alta precisión, validando la hipótesis de que la especificidad de los datos es superior al volumen de los mismos

4.4.3 Estrategia y procesamiento del conjunto de datos

La gestión de los datasets iniciales se vio influenciada por la curva de aprendizaje en el equipo, mientras que las etapas finales aplicaron técnicas de ingeniería de datos más rigurosas.

Primera Iteración: Procesamiento Nulo (ResNet50)

El conjunto de datos inicial, utilizado para la arquitectura ResNet50, se integró directamente al flujo de entrenamiento sin modificaciones de preprocesamiento o redimensionamiento. Esta decisión se basó en la premisa errónea de que las plataformas de frameworks de deep learning (como TensorFlow o PyTorch) realizarían el redimensionamiento necesario de forma automática o que un conjunto de datos extremadamente grande sería suficiente para que pudiera interpretar el mundo como se debe sin embargo el preprocesamiento no se realizó debido a la idea que requeriría un tiempo de procesamiento excesivamente largo.

El único paso realizado fue la creación de un dataframe para mapear la ruta de las imágenes a sus etiquetas. Esta ausencia de preprocesamiento contribuyó a los resultados subóptimos observados, ya que el modelo se vio obligado a procesar imágenes de dimensiones variables e inconsistentes, afectando la estabilidad de los gradientes durante el entrenamiento.

Segunda Iteración: Procesamiento Nulo (TrashNet)

El segundo conjunto de datos, TrashNet, se incorporó al modelo con la misma omisión de preprocesamiento que en la etapa inicial. La persistencia en esta estrategia, fundamentada en la falta de experiencia técnica en ese momento, resultó en un rendimiento deficiente.

Se comprobó que ignorar la estandarización de las dimensiones de entrada impedía que la red neuronal convergiera eficientemente, confirmando que la consistencia dimensional es un requisito fundamental para el entrenamiento efectivo de CNNs.

Tercera Iteración: Desarrollo del Script de Fusión y Redimensionamiento

La deficiencia en las iteraciones previas condujo al desarrollo de un script dedicado de preprocesamiento de datos. Este script se diseñó para la fusión y estandarización de los conjuntos TrashNet y RealWaste Image Classification, buscando corregir dos problemas principales:

- **Uniformidad Categórica y Reclasificación:** El dataset RealWaste Image Classification contenía originalmente nueve categorías, mientras que TrashNet contenía seis. Dado que el objetivo del proyecto era la clasificación binaria (Biodegradable (B) o No Biodegradable (N)), fue necesario implementar un esquema de mapeo categórico para reubicar cada imagen en las dos carpetas específicas finales (B o N).
- **Redimensionamiento y Consistencia Dimensional:** Se determinó que las dimensiones de entrada requeridas para la arquitectura MobileNetV2, con el objetivo de optimizar la

inferencia y el balance de memoria, eran de 224×224 píxeles. El script automatizó el proceso de redimensionamiento de todas las imágenes.

Este dataset fusionado y preprocesado se dividió en ≈ 2000 imágenes para entrenamiento y ≈ 2000 para prueba, con una estructura de nombres de archivo estandarizada (e.g., biodegradable0001.jpg), facilitando la correcta ingesta de datos por parte de las funciones de carga de la plataforma de entrenamiento.

Cuarta Iteración: Preprocesamiento de Datos Custom

Para la cuarta y última iteración (Adaptación de Dominio), el dataset custom recolectado se integró por separado para el fine-tuning. La organización categórica se mantuvo desde la captura fotográfica, con las imágenes siendo clasificadas manualmente por el equipo de desarrollo directamente en sus carpetas B o N.

Aunque este dataset se mantuvo separado del conjunto fusionado de la tercera iteración para asegurar una prueba de validación de dominio más limpia, también fue sometido al mismo script de preprocesamiento para redimensionar las imágenes a 224×224 , manteniendo la consistencia dimensional con los pesos pre-entrenados del modelo MobileNetV2.

Justificación de la Redimensión 224×224

La elección de la dimensión 224×224 no fue arbitraria, sino que se basa en el requisito estándar de la mayoría de las arquitecturas de CNN pre-entrenadas, incluyendo MobileNetV2.

- **Requisito de Modelo Base:** La arquitectura MobileNetV2 fue originalmente entrenada en el dataset ImageNet utilizando 224×224 como dimensión de entrada. Utilizar este mismo tamaño en el fine-tuning asegura que las capas convolucionales puedan interpretar y procesar las características de las imágenes de entrada de manera consistente con los pesos pre-entrenados, maximizando el beneficio del Aprendizaje por Transferencia.
- **Eficiencia Computacional:** Dimensiones mayores aumentarían la carga computacional ($O(N^2)$) incrementando el consumo de memoria RAM y el tiempo de entrenamiento, mientras que dimensiones menores comprometerían la calidad de la información visual.

4.4.4 Scripts de procesamiento

El procesamiento y la curación del conjunto de datos fusionado (TrashNet + RealWaste Image Classification) se gestionaron mediante el desarrollo de dos scripts personalizados en Python, diseñados para automatizar la estandarización categórica y la división en conjuntos de entrenamiento y prueba. Estos scripts aseguraron la estructura homogénea requerida para el proceso de fine-tuning con MobileNetV2.

AcomodoDataset.py (Reclasificación y Reorganización Categórica)

Este script fue el responsable de la etapa crítica de adaptación de dominio, realizando las siguientes funciones:

- **Mapeo Categórico:** Se implementó un mapeo que relacionó las categorías originales de los datasets con las dos categorías binarias del proyecto: B (Biodegradable) y N (No Biodegradable).
- **Movimiento de Archivos:** El script iteró sobre la ubicación original de todas las imágenes. Con base en el mapeo definido, movió físicamente cada archivo a su carpeta de destino (/B o /N), asegurando que la estructura de directorios reflejara con precisión las etiquetas binarias del problema.
- **Redimensionamiento:** En esta etapa, las imágenes también fueron redimensionadas a las dimensiones estandarizadas de 224×224 píxeles (como se detalló en la sección anterior), garantizando la consistencia dimensional para la entrada al modelo MobileNetV2.




Ilustración 12 Diagrama de flujo AcomodoDataset.

AcomodoDatasetTest.py (División de Entrenamiento y Prueba)

Una vez que todas las imágenes estaban correctamente clasificadas en las carpetas /B y /N, este script se encargó de la división controlada del conjunto de datos, asegurando una distribución equitativa para evitar sesgos de clase:

- **Asignación de Entrenamiento:** De manera sistemática, el script seleccionó 2000 imágenes de la carpeta /B y 2000 imágenes de la carpeta /N para ser asignadas al conjunto de Entrenamiento. Esta cantidad se consideró suficiente para adaptar los pesos del modelo pre-entrenado.
- **Asignación de Prueba:** Las imágenes restantes de ambas categorías (aquellas no seleccionadas para entrenamiento) se destinaron automáticamente al conjunto de Prueba (Test). Este conjunto final se utilizó para evaluar el rendimiento del modelo en datos no vistos, garantizando una métrica de generalización objetiva.

La separación estricta y cuantificada de los conjuntos de entrenamiento y prueba fue esencial para validar la capacidad predictiva del modelo en condiciones reales y evitar el sobreajuste (overfitting).




Ilustración 13 Diagrama de flujo AcomodoDatasetTestTrain.

4.4.5 Scripts de entrenamiento

Una vez completado el procesamiento y la curación final del conjunto de datos, la siguiente fase crítica fue seleccionar la infraestructura adecuada para el entrenamiento del modelo MobileNetV2. Se optó por utilizar una plataforma de computación en la nube para garantizar la eficiencia, estabilidad y acceso a recursos de hardware especializado.

Elección de la Plataforma de Entrenamiento

Se seleccionó Google Colaboratory (Google Colab) como el entorno principal para el entrenamiento del modelo de inteligencia artificial. Google Colab es un servicio de notebooks Jupyter basado en la nube que proporciona acceso gratuito a Unidades de Procesamiento Gráfico (GPU) y Unidades de Procesamiento de Tensor (TPU).

La decisión de utilizar esta infraestructura de nube se justificó por las siguientes consideraciones:

- **Acceso Optimizado a Recursos de Cómputo:** El entrenamiento de redes neuronales convolucionales profundas como MobileNetV2 requiere una alta capacidad de paralelización, la cual es proporcionada de manera eficiente por las GPU virtuales de Colab.
- **Minimización de Configuración Local:** El uso de Google Colab eliminó la necesidad de complejas configuraciones de software, dependencias de frameworks y la gestión de drivers en equipos locales.

Es importante notar que el registro detallado del proceso de entrenamiento en la plataforma Google Colab abarca solo tres de las cuatro iteraciones de datos descritas previamente, debido a las limitaciones de registro iniciales. No obstante, las métricas y conclusiones de las cuatro iteraciones son conocidas y se presentarán detalladamente en el Capítulo 5 (**Pruebas y resultados**).

El enfoque del siguiente texto se centrará únicamente en los scripts y el código fuente desarrollado para la definición, configuración y ejecución del entrenamiento del modelo MobileNetV2 y ResNet50.

- **Paqueterías**

tensorflow y tensorflow.keras: Son el framework fundamental para el aprendizaje automático y el aprendizaje profundo. TensorFlow gestiona la computación de gráficos de flujo de datos a gran escala, mientras que Keras es su API de alto nivel, utilizada para definir, configurar, entrenar y evaluar modelos de redes neuronales de manera eficiente y modular.

Modelos Preentrenados (ResNet50, MobileNetV2): Se importan estas arquitecturas preentrenadas en el dataset ImageNet para aplicar la técnica de Aprendizaje por Transferencia (Transfer Learning). Estas bases convolucionales permiten reutilizar características de bajo y medio nivel aprendidas de millones de imágenes, acelerando la convergencia del modelo para la tarea específica de clasificación de residuos.

Capas y Modelos (Dense, Dropout, GlobalAveragePooling2D, Model): Los módulos layers y models se utilizan para personalizar las arquitecturas preentrenadas. Dense define las capas de salida, Dropout previene el sobreajuste (overfitting) al apagar neuronas aleatoriamente, y GlobalAveragePooling2D reduce las dimensiones espaciales de los mapas de características. Model permite construir y ensamblar el modelo final a partir de estas capas.

Preprocesamiento de Imágenes (preprocess_input_resnet, preprocess_input_mobilenet, ImageDataGenerator): Estas funciones son esenciales para normalizar los píxeles de las imágenes de entrada según las especificaciones de los modelos ResNet50 y MobileNetV2. ImageDataGenerator es una herramienta crucial para el Aumento de Datos (Data Augmentation), aplicando transformaciones en tiempo real (rotaciones, zoom, inversión) para aumentar la variabilidad del conjunto de entrenamiento y robustecer el modelo.

Entrenamiento y Control (Adam, Callbacks): Adam es el optimizador utilizado para ajustar los pesos del modelo durante el entrenamiento. Los Callbacks (ModelCheckpoint, ReduceLROnPlateau, EarlyStopping, CSVLogger) son mecanismos que permiten automatizar acciones durante el entrenamiento, tales como guardar el mejor modelo, ajustar la tasa de aprendizaje y detener el proceso anticipadamente si no hay mejora, asegurando una gestión eficiente del workflow.

pandas (pd) y numpy (np): NumPy es el estándar para la computación científica en Python, permitiendo operaciones eficientes con matrices y vectores. Pandas construye sobre NumPy, proporcionando estructuras de datos de alto nivel como DataFrames, esenciales para la carga, limpieza y gestión estructurada de los metadatos del conjunto de imágenes.

matplotlib.pyplot (plt) y seaborn (sns): Son las librerías primarias de visualización. Matplotlib es la base para la creación de gráficos estáticos, mientras que Seaborn ofrece una interfaz

de alto nivel para generar visualizaciones estadísticas atractivas y complejas, como los gráficos de las curvas de entrenamiento o las matrices de confusión.

Métricas de Clasificación (`precision_score`, `recall_score`, `f1_score`, etc.): Estas funciones se emplean para calcular las métricas de rendimiento más relevantes en problemas de clasificación binaria, ofreciendo una visión completa de la capacidad predictiva del modelo más allá de la precisión simple (`accuracy`). La `confusion_matrix` y el `classification_report` son fundamentales para analizar los tipos de errores (falsos positivos y falsos negativos).

Validación y Balanceo (`train_test_split`, `class_weight`, `resample`): `train_test_split` permite dividir el conjunto de datos de manera adecuada para el entrenamiento y la prueba. Los módulos de `sklearn.utils` (`class_weight`, `resample`) son utilizados para gestionar el desbalance de clases, asegurando que el modelo no esté sesgado hacia la clase mayoritaria.

`os`, `shutil`: Estos módulos proveen herramientas para interactuar con el sistema operativo y el sistema de archivos. `os` se utiliza para la gestión de rutas y directorios, mientras que `shutil` se emplea para operaciones de alto nivel con archivos y directorios, como la copia y eliminación de estructuras de archivos.

`kagglehub`: Este módulo facilita la descarga directa del conjunto de datos desde la plataforma Kaggle, permitiendo un acceso y una replicación del entorno de trabajo más eficientes.

- **Creación del dataframe ResNet50**

Adquisición y Centralización del Dataset

Ejecuta la extracción remota mediante la librería `kagglehub`, descargando el conjunto de datos "non-and-biodegradable-waste-dataset" a una ubicación temporal en el sistema.

Gestiona la estructura de directorios validando y creando el directorio de destino local (dataset). Itera sobre el contenido descargado y, discriminando entre directorios y archivos individuales, traslada la totalidad de la información a la ruta de trabajo permanente.

Depura el entorno eliminando recursivamente la ruta de descarga original (`shutil.rmtree`) para liberar espacio y evitar redundancia de datos.

Confirma la operación imprimiendo en consola la ruta final donde se han consolidado los archivos, asegurando que el entorno está listo para el procesamiento.

Indexación y Construcción del dataframe de Entrenamiento

Define el espacio de búsqueda estableciendo las rutas base y generando dinámicamente una lista de directorios de entrenamiento (`train_dirs`) que comprende desde TRAIN.1 hasta TRAIN.4.

Instancia la lógica de recolección mediante la función `create_dataframe`, la cual inicializa listas vacías para almacenar las rutas de las imágenes y sus correspondientes etiquetas.

Itera y valida jerárquicamente explorando cada directorio de entrenamiento y subdirectorios de clase ('B' para Biodegradable y 'N' para No Biodegradable). Aplica un filtro de extensión para asegurar que solo se procesen archivos de imagen válidos (.png, .jpg, .jpeg), los cuales son imágenes sin preprocesar correctamente para el modelo de IA, como se mencionó anteriormente.

Retorna un objeto estructurado (`pd.DataFrame`) que vincula cada ruta de archivo (`filename`) con su etiqueta de clasificación (`class`), consolidando los metadatos necesarios para la fase de entrenamiento del modelo.

- **Entrenamiento de ResNet50**

Preparación de Datos y Balanceo de Clases

Se calcula automáticamente los pesos de las clases.

Se aplica la estrategia 'balanced', que asigna a cada clase un peso inversamente proporcional a su frecuencia de aparición en el dataset de entrenamiento (`train_df['class']`).

Finalmente, se convierte el array de pesos a un diccionario, donde las claves son los índices de clase (0, 1, ...) y los valores son los pesos calculados, para su uso en la fase de entrenamiento.

Instanciación del Generador de Imágenes (train_datagen)

Se define un objeto `ImageDataGenerator` que establece una serie de técnicas de Aumento de Datos (Data Augmentation) para el conjunto de entrenamiento.

Esto incluye transformaciones geométricas (volteo horizontal, rotación, desplazamiento de ancho y alto, zoom) y ajustes de brillo.

Creación del Generador de Entrenamiento y de validación (train_gen, val_gen)

Se configuran parámetros clave: `target_size=(224, 224)` (tamaño requerido por ResNet50), `batch_size=32`, modo de clasificación 'categorical' y se activa la mezcla aleatoria (`shuffle=True`).

Se selecciona el subconjunto de entrenamiento (`subset='training'`).

Se configura de manera similar a `train_gen`, pero seleccionando el subconjunto de validación (`subset='validation'`).

Carga del Modelo Base (ResNet50)

La función `build_resnet()` inicia cargando la arquitectura ResNet50, pre-entrenada con el dataset ImageNet (`weights='imagenet'`).

Se omite la capa de clasificación superior original (`include_top=False`) para poder adaptar el modelo a la nueva tarea de 2 clases.

Se añade una capa `GlobalAveragePooling2D` para reducir las dimensiones de la salida de la ResNet50.

La capa final de salida es una capa `Dense` con 2 neuronas (para las 2 clases).

Configuración de Callbacks

`ModelCheckpoint`: Guarda automáticamente el modelo (`predictWaste12.h5`) únicamente cuando se alcanza la mínima pérdida de validación (`monitor='val_loss'`, `save_best_only=True`).

`ReduceLROnPlateau`: Reduce la tasa de aprendizaje a la mitad (`factor=0.5`) si la pérdida de validación no mejora después de 2 épocas (`patience=2`), ayudando a converger en el mínimo.

`EarlyStopping`: Detiene el entrenamiento si la pérdida de validación no mejora después de 3 épocas (`patience=3`) y restaura los mejores pesos guardados por el `ModelCheckpoint`.

Lanzamiento del Entrenamiento (`model.fit`)

El modelo es entrenado por un máximo de 25 épocas.

Se alimentan los datos mediante los generadores `train_gen` y `val_gen`.

Se especifican `steps_per_epoch` y `validation_steps` utilizando la longitud de los generadores.

Se utilizan los callbacks definidos para la gestión dinámica del entrenamiento.

```

# ===== DATA PREPARATION =====
# Balanceo con pesos
class_weights = class_weight.compute_class_weight('balanced',
                                                    classes=np.unique(train_df['class']),
                                                    y=train_df['class'])

class_weights = dict(enumerate(class_weights))

# ===== DATA GENERATORS =====
train_datagen = ImageDataGenerator(
    preprocessing_function=preprocess_input_resnet,
    validation_split=0.2,
    horizontal_flip=True,
    rotation_range=25,
    width_shift_range=0.15,
    height_shift_range=0.15,
    zoom_range=0.2,
    brightness_range=[0.8, 1.2],
    fill_mode='nearest'
)

train_gen = train_datagen.flow_from_dataframe(
    dataframe=train_df,
    x_col='filename',
    y_col='class',
    target_size=(224, 224),
    color_mode='rgb',
    batch_size=32,
    class_mode='categorical',
    shuffle=True,
    seed=42,
    subset='training'
)

val_gen = train_datagen.flow_from_dataframe(
    dataframe=train_df,
    x_col='filename',
    y_col='class',
    target_size=(224, 224),
    color_mode='rgb',
    batch_size=32,
    class_mode='categorical',
    shuffle=False,
    seed=42,
    subset='validation'
)

# ===== MODEL ARCHITECTURE =====
def build_resnet():
    base = ResNet50(weights='imagenet', include_top=False, input_shape=(224, 224, 3))
    for layer in base.layers[:140]:
        layer.trainable = False
    for layer in base.layers[140:]:
        layer.trainable = True

```

Ilustración 14 Código entrenamiento RestNet-50.

- **Creación del dataframe MobileNetV2**

Indexación y Construcción del dataframe de Entrenamiento

Se inicializa la función que acepta un único argumento, `base_dir`, que es la ruta principal donde se encuentra el dataset.

Se inicia un bucle (`for class_name in ['B', 'N']`) para procesar las dos clases objetivo: 'B' (Biodegradable) y 'N' (No Biodegradable).

Para cada clase, se construye la ruta completa (`class_dir = os.path.join(base_dir, class_name)`) y se verifica si el directorio de la clase existe. Si no existe, se imprime una advertencia y se salta a la siguiente clase.

Se aplica un filtro de extensión (`if file.lower().endswith(('.png', '.jpg', '.jpeg'))`) para asegurar que solo se procesen archivos que sean imágenes válidas (PNG, JPG, JPEG).

Una vez completada la iteración sobre todas las clases y archivos, la función retorna un objeto estructurado (un `pd.DataFrame`).

Este `DataFrame` tiene dos columnas: 'filename' (conteniendo todas las rutas de las imágenes) y 'class' (conteniendo sus etiquetas de clasificación correspondientes).

- **Entrenamiento de MobileNetV2**

Preparación de Datos y Balanceo de Clases

Se aplicó la misma estrategia utilizada en el proceso de entrenamiento previo, enfocada en el balanceo de clases con el objetivo de equilibrar la distribución de los datos.

Generación de Datos (ImageDataGenerator)

Se definió un generador de imágenes para el conjunto de entrenamiento, incorporando:

- Función de preprocesamiento propia de MobileNetV2.

- División interna del dataset (80% entrenamiento, 20% validación).

- Aumento de datos mediante volteo horizontal y zoom, con el fin de incrementar la variabilidad del conjunto.

Utilizando este generador, se creó el conjunto de entrenamiento (`train_gen`) y el de validación (`val_gen`), especificando:

- Tamaño de entrada de 224×224 píxeles.

- Modo de clasificación categórica.

- Mezcla aleatoria únicamente para el conjunto de entrenamiento.

Construcción del Modelo (MobileNetV2)

La función `build_mobilenetv2()` inicia cargando la arquitectura MobileNetV2, pre-entrenada con el dataset ImageNet (`weights='imagenet'`).

Se omite la capa de clasificación superior original (`include_top=False`) para poder adaptar el modelo a la nueva tarea de 2 clases.

Las capas del modelo base permanecieron congeladas para evitar alterar los pesos preentrenados.

Configuración de Callbacks

ModelCheckpoint: Guarda automáticamente el modelo únicamente cuando la pérdida de validación alcanza su mínimo.

ReduceLROnPlateau: Reduce la tasa de aprendizaje a la mitad cuando la pérdida de validación deja de mejorar por dos épocas.

EarlyStopping: Detiene el entrenamiento si no se observa mejora en la pérdida de validación durante 10 épocas consecutivas y restaura los mejores pesos registrados.

Proceso de Entrenamiento

El modelo fue entrenado durante un máximo de 35 épocas utilizando los generadores de entrenamiento y validación.

El cálculo de los pasos por época se obtuvo directamente del tamaño de cada generador.

Se incorporaron los class weights durante el entrenamiento para compensar el desbalance entre clases.

Los callbacks configurados permitieron gestionar dinámicamente la tasa de aprendizaje, el almacenamiento del mejor modelo y la interrupción temprana del proceso.


```

# ===== DATA PREPARATION =====
class_weights = class_weight.compute_class_weight('balanced', classes=np.unique(
class_weights = dict(enumerate(class_weights))

# ===== DATA GENERATORS =====
train_datagen = ImageDataGenerator(
    preprocessing_function=preprocess_input_mobilenet,
    validation_split=0.2,
    horizontal_flip=True,
    #rotation_range=25,
    #width_shift_range=0.15,
    #height_shift_range=0.15,
    zoom_range=0.2,
    #brightness_range=[0.8, 1.2],
    fill_mode='nearest'
)

train_gen = train_datagen.flow_from_dataframe(
    dataframe=df_balanced,
    x_col='filename',
    y_col='class',
    target_size=(224, 224),
    color_mode='rgb',
    batch_size=32,
    class_mode='categorical',
    shuffle=True,
    seed=42,
    subset='training'
)

val_gen = train_datagen.flow_from_dataframe(
    dataframe=df_balanced,
    x_col='filename',
    y_col='class',
    target_size=(224, 224),
    color_mode='rgb',
    batch_size=32,
    class_mode='categorical',
    shuffle=False,
    seed=42,
    subset='validation'
)

# ===== MODEL ARCHITECTURE =====
def build_mobilenetv2():
    base = MobileNetV2(weights='imagenet', include_top=False, input_shape=(224, 224, 3))
    base.trainable = False
    #for layer in base.layers[:-30]: # Congelar todas excepto las últimas 30 capas
    #    layer.trainable = False

    x = base.output

```

Ilustración 15 Código entrenamiento MobileNetV2.

- **Creación del dataframe con Iterative Domain Technique**

Función constructora de dataframes

Se inicializa una función llamada `creadorDataFrame` que acepta un único argumento, `base_dir`, que es la ruta principal donde se encuentra el dataset.

Se inicializan dos listas vacías: `image_paths` (para almacenar las rutas completas de las imágenes) y `labels` (para almacenar las etiquetas de clase), que se llenarán durante el recorrido.

Se inicia un bucle (`for class_name in ['B', 'N']`) para procesar las dos clases objetivo: 'B' (Biodegradable) y 'N' (No Biodegradable).

Se utiliza `os.walk(class_dir)` para recorrer recursivamente el directorio de la clase y todos sus subdirectorios. Esto es crucial porque permite encontrar imágenes anidadas en cualquier subcarpeta, no solo en la carpeta principal de la clase.

Para cada imagen válida, se construye su ruta completa (`img_path`) y se añade a la lista `image_paths`.

Simultáneamente, la etiqueta de la clase actual (`class_name`) se añade a la lista `labels`.

Una vez completada la iteración sobre todas las clases y archivos, la función retorna un objeto estructurado (`pd.DataFrame`).

Este `DataFrame` final tiene dos columnas: `'filename'` (conteniendo todas las rutas de las imágenes recopiladas) y `'class'` (conteniendo sus etiquetas de clasificación correspondientes).

Creación del DataFrame de Entrenamiento

Se define la ruta base para el conjunto de datos de entrenamiento en la variable `train_base_dir`.

Se llama a la función `creadorDataFrame` con esta ruta para construir y poblar el primer `DataFrame`, `df_train`, que contiene las rutas y etiquetas del conjunto de entrenamiento.

Creación del DataFrame de "Real Data"

Se define la ruta base para la carpeta de "real data" en la variable `real_data_base_dir`.

Se llama a la función `creadorDataFrame` nuevamente con esta ruta para construir el segundo `DataFrame`, `df_real_data`, indexando las imágenes de una fuente de datos adicional.

Combinación de DataFrames

Ambos DataFrames (df_train y df_real_data) se combinan verticalmente en un único DataFrame llamado df_combined mediante la función pd.concat.

- **Entrenamiento de MobileNetV2 con fine tuning**

Inicialización del Generador de Datos

Realizar el preprocesamiento usando una función de TensorFlow que escala y normaliza los píxeles exactamente igual que en el entrenamiento original de MobileNetV2, garantizando compatibilidad y rendimiento óptimo.

Dividir el dataframe de forma que el 20% de las imágenes se reserven para validación y el 80% restante para entrenamiento.

Aplicar aumentos de datos para mejorar la generalización sobre objetos similares; en este caso, permitir volteos horizontales aleatorios (horizontal_flip=True) y rellenar píxeles vacíos con interpolación cercana (fill_mode='nearest').

Creación del Generador de Entrenamiento y validación

Generar lotes de imágenes con datagen.flow_from_dataframe a partir de df_combined, usando subset="training" para acceder al 80% asignado al entrenamiento.

Redimensionar todas las imágenes a 224×224 px, tamaño requerido por MobileNetV2.

Formatear las etiquetas en representación one-hot mediante class_mode="categorical".

Establecer un batch_size de 32 para definir cuántas imágenes se procesan por paso.

Crear el generador de validación siguiendo la misma configuración, usando subset="validation" y manteniendo shuffle=False para no alterar el orden durante la evaluación.

Carga del Modelo

Definir la ruta del archivo .h5 que contiene el modelo previamente entrenado.

Cargar la arquitectura, los pesos y la configuración del optimizador mediante load_model, obteniendo un MobileNetV2 listo para ajuste fino.

Preparación para Ajuste Fino (Fine-Tuning)

Congelar las capas inferiores iterando sobre la mayoría de las capas del modelo y estableciendo layer.trainable = False; esto preserva las características básicas aprendidas en ImageNet.

Descongelar las últimas 30 capas habilitando trainable=True, permitiendo que aprendan patrones propios de los residuos captados.

Recompilar el modelo tras modificar las capas entrenables, usando el optimizador Adam con una tasa de aprendizaje muy baja ($1e-5$) para realizar ajustes graduales.

Configuración de Callbacks

EarlyStopping:

Monitorear val_loss y detener el entrenamiento si no mejora después de 3 épocas.

Restaurar automáticamente los mejores pesos alcanzados.

ReduceLROnPlateau:

Vigilar también val_loss y reducir la tasa de aprendizaje a la mitad cuando no mejore durante 2 épocas consecutivas.

Entrenamiento (Fine-Tuning)

Iniciar el reentrenamiento mediante model.fit usando los generadores de entrenamiento y validación.

Ejecutar hasta 10 épocas como máximo, aprovechando que el modelo ya cuenta con conocimiento previo y solo requiere ajuste fino.

```
Found 3520 validated image filenames belonging to 2 classes.
Found 880 validated image filenames belonging to 2 classes.
WARNING:absl:Compiled the loaded model, but the compiled metrics have yet to be built. 'model.compile_metrics' will be empty until you train or evaluate.
/usr/local/lib/python3.12/dist-packages/keras/src/trainers/data_adapters/py_dataset_adapter.py:121: UserWarning: Your 'PyDataset' class should call 'self._warn_if_super_not_called()'
  self._warn_if_super_not_called()
Modelo cargado: /content/drive/MyDrive/Modelos/predictwaste_mobilenetv2_v1.h5
Epoch 1/10
110/110 ————— 46s 245ms/step - accuracy: 0.6196 - loss: 0.8970 - val_accuracy: 0.8057 - val_loss: 0.4367 - learning_rate: 1.0000e-05
Epoch 2/10
110/110 ————— 19s 170ms/step - accuracy: 0.7095 - loss: 0.6594 - val_accuracy: 0.7648 - val_loss: 0.4893 - learning_rate: 1.0000e-05
Epoch 3/10
110/110 ————— 0s 136ms/step - accuracy: 0.7246 - loss: 0.6351
Epoch 3: ReduceLROnPlateau reducing learning rate to 4.999999873689376e-06.
110/110 ————— 19s 170ms/step - accuracy: 0.7248 - loss: 0.6346 - val_accuracy: 0.7534 - val_loss: 0.5287 - learning_rate: 1.0000e-05
Epoch 4/10
110/110 ————— 20s 163ms/step - accuracy: 0.7671 - loss: 0.5481 - val_accuracy: 0.7602 - val_loss: 0.5292 - learning_rate: 5.0000e-06
WARNING:absl:You are saving your model as an HDF5 file via 'model.save()' or 'keras.saving.save_model(model)'. This file format is considered legacy.
Modelo actualizado guardado como model_retrained_REALDATA.h5
```

Ilustración 16 Consola de entrenamiento FT.

4.5 Ensamblaje e integración del sistema embebido.

El ensamblaje del sistema embebido se realizó a partir de los módulos descritos en el apartado 4.1.2, integrando en un solo sistema funcional al ESP32-S3 CAM junto con el sensor ultrasónico HC-SR04, el servomotor MG90S, la pantalla OLED I2C y el módulo de cámara incorporado. Este capítulo detalla la arquitectura eléctrica, la disposición física de los componentes y las decisiones de diseño que permitieron obtener un prototipo estable, accesible y funcional. Adicionalmente, se describen las consideraciones técnicas empleadas para garantizar la operación adecuada del sistema bajo las limitaciones físicas del prototipo MVP.

4.5.1 Conexión eléctrica y lógica del sistema

La conexión eléctrica del sistema se diseñó para garantizar la estabilidad y el correcto funcionamiento de cada módulo. El ESP32-S3 CAM actúa como unidad de control principal, proporcionando tanto la alimentación como las señales de comunicación necesarias para el sensor ultrasónico HC-SR04, el servomotor SG90, la pantalla OLED I2C y el módulo de cámara integrado.

Módulo	Componente Específico	Pin del Módulo	Pin del ESP32 S3 CAM	Función
Sensor Ultrasónico	HC-SR04	VCC	5V	Alimentación del sensor
		GND	GND	Tierra común
		Trig	GPI01	Envío de señal de disparo
		Echo	GPI02	Recepción del pulso (medición por interrupción)
Pantalla OLED	128x64 i2c	VCC	5V	Alimentación
		GND	GND	Tierra común
		SDA	GPI42	Línea de datos I2C por software
		SCL	GPI41	Línea de reloj I2C por software
Servomotor	mg90s	VCC	5V	Alimentación
		GND	GND	Tierra común
		Señal	GPI13	Control PWM del ángulo

Tabla 18 Tabla de Conexiones.

La Tabla 18 y el diagrama electrónico de la ilustración 17 permiten visualizar de manera clara la distribución de señales y líneas de alimentación dentro del sistema. La reasignación de pines, especialmente en el caso de la interfaz I2C por software implementada en los GPIO 41 y 42, garantizó la compatibilidad con la cámara integrada del ESP32-S3 CAM sin comprometer la funcionalidad del resto de los módulos.

La elección de pines capaces de manejar interrupciones para el sensor ultrasónico, así como la configuración PWM del servomotor, contribuyeron a un funcionamiento estable y coherente con los requerimientos del prototipo. Con esta arquitectura eléctrica y lógica, el sistema embebido queda plenamente integrado y preparado para su montaje físico, descrito en los apartados posteriores.




Ilustración 17 Diagrama de electrónico.

4.5.2 Distribución física de los componentes

La distribución física de los componentes se realizó considerando criterios de funcionalidad, accesibilidad, estabilidad estructural y aprovechamiento del espacio disponible dentro del prototipo. Para este fin se utilizó un contenedor plástico tipo bote de basura con dimensiones aproximadas de 10.8 cm de ancho, 16 cm de alto y 12.4 cm de profundidad, el cual sirvió como chasis para integrar todos los elementos electrónicos y mecánicos del sistema.

Antes del montaje, se establecieron los siguientes criterios:

- Mantener la línea de visión libre para la cámara.

- Minimizar vibraciones en el servomotor.
- Reducir interferencias eléctricas entre líneas de señal y alimentación.
- Garantizar accesibilidad para mantenimiento y pruebas.
- Optimizar el recorrido del cableado interno.
- Aprovechar al máximo el volumen interno sin comprometer la estabilidad.

El ESP32-S3 CAM se ubicó en la parte superior interna del contenedor con el objetivo de proporcionar a la cámara integrada un campo visual amplio y despejado. Para fijarlo, se diseñó una base artesanal compuesta por una placa de cartón rígido doblada y reforzada mediante palos de madera de 2 cm de grosor, y posteriormente adherida con silicón caliente. Esta estructura permitió mantener el microcontrolador estable, reducir vibraciones y garantizar que la cámara permaneciera en una posición adecuada durante la operación.




Ilustración 18 ESP32 S3 Cam ubicación.

Con el fin de garantizar condiciones de iluminación constantes un factor crucial para mejorar la calidad de las imágenes capturadas por la cámara se integró un aro de luz LED de 6 pulgadas (aproximadamente 15 cm de diámetro). Este aro se colocó en la parte inferior de la base donde se sostiene el ESP32-S3 CAM, generando un entorno luminoso uniforme dentro del contenedor. Este aro genera una iluminación uniforme, reduce sombras y mejora la detección el modelo de IA en condiciones de baja luz.

Para su alimentación, se perforó discretamente la misma base, permitiendo el paso del cable USB hacia la parte posterior de la estructura. Finalmente, el aro fue fijado con silicón caliente, asegurando su estabilidad y alineación con el campo visual de la cámara. Esta adaptación mejora significativamente el desempeño del sistema en condiciones de baja iluminación y reduce sombras que podrían interferir con la identificación visual.



Ilustración 19 Iluminación prototipo.

El cableado interno del prototipo se realizó mediante la unión de múltiples cables de conexión (jumpers) para alcanzar la longitud necesaria y permitir una manipulación externa más cómoda de los módulos. En algunos casos fue necesario enlazar tres o hasta cuatro jumpers de datos, garantizando así que las señales pudieran extenderse sin comprometer la movilidad o la accesibilidad durante las pruebas.

Estos conjuntos de cables fueron fijados cuidadosamente con silicón caliente en la parte posterior del prototipo, específicamente en la zona donde se localiza la base estructural elaborada con cartón. Esta fijación evitó desplazamientos indeseados y contribuyó a mantener un orden adecuado dentro del sistema.

Para la conexión con el microcontrolador se emplearon jumpers hembra, mientras que para los módulos se utilizaron jumpers macho, asegurando compatibilidad con los pines correspondientes y facilitando el montaje y desmontaje durante el proceso de integración.

Para optimizar la distribución de energía y reducir la carga directa sobre el ESP32-S3 CAM, se incorporó una protoboard mini como módulo auxiliar de alimentación. En esta se organizaron los puertos de entrada y salida de los distintos componentes, permitiendo suministrar de manera ordenada los 5 VCC requeridos por los módulos previamente descritos. La protoboard actúa como punto central de distribución eléctrica, asegurando que cada dispositivo reciba la energía necesaria sin sobrecargar el regulador del microcontrolador y facilitando además la gestión del cableado interno del prototipo.




Ilustración 20 Cableado y protoboard prototipo.

El sensor ultrasónico HC-SR04 se colocó en la parte frontal del prototipo, sobre la misma plataforma que sostiene al ESP32-S3 CAM, realizando dos cavidades circulares en la superficie para alojar los transductores del sensor. Esta ubicación frontal asegura una línea de detección directa hacia el exterior, evitando obstrucciones y permitiendo mediciones más precisas de distancia.



Ilustración 21 Sensor ultrasónico frente al prototipo.

La pantalla OLED se instaló también en la parte frontal del contenedor, en una posición visible para el usuario. Esta ubicación permite consultar fácilmente los valores y mensajes generados por el sistema, facilitando que el usuario pueda interpretar las instrucciones de clasificación de residuos o mensajes operativos del dispositivo.



Ilustración 22 Pantalla Oled en el prototipo.

Por su parte, el servomotor MG90S se montó en la zona inferior derecha del contenedor, para lo cual se realizó una perforación con una broca de ¼ de pulgada, permitiendo el paso del eje del servomotor hacia el mecanismo de apertura. La conexión mecánica entre el servomotor y la tapa del contenedor se efectuó mediante cables UTP reforzados y fijados a través de un orificio adicional perforado con una broca fina. Esta configuración garantiza que la tapa pueda moverse de forma controlada conforme a las posiciones establecidas por el sistema.




Ilustración 23 Servomotor en el prototipo y conexión a la tapa.

La disposición final de los componentes facilita un flujo operativo lógico:

Detección → Procesamiento → Visualización → Acción Mecánica

Permitiendo que el prototipo funcione de manera integrada y eficiente. Además, esta organización interna optimiza el espacio reducido del contenedor sin comprometer la accesibilidad para el mantenimiento y ajustes posteriores.

4.5.3 Render en 3D del producto final para producción

El desarrollo del render 3D tuvo como propósito ofrecer una representación visual clara, detallada y estéticamente refinada del producto final al que se pretende llegar en caso de contar con

el financiamiento necesario. Dado que el prototipo construido corresponde a un MVP (Producto Mínimo Viable). Este tipo de visualización también facilita anticipar la integración de los componentes internos, prever posibles mejoras estructurales y presentar el concepto en un contexto realista para potenciales inversionistas o evaluadores técnicos.




Ilustración 24 Modelo 3D construcción inicial.

Para la elaboración del modelo tridimensional se empleó Autodesk 3ds Max, en lugar de SolidWorks, debido a la experiencia previa con este software y a su versatilidad para el modelado y renderizado. Su motor de render nativo permitió generar imágenes con materiales realistas, iluminación controlada y superficies mejor definidas, proporcionando una proyección visual precisa del producto final deseado. Asimismo, la flexibilidad del software facilitó ajustes iterativos en la geometría, proporciones y disposición interna del diseño.

La ilustración 26 muestra el modelo 3D en tres diferentes posiciones frontal, lateral y superior con el objetivo de mostrar de manera clara la estructura general del dispositivo. Estas vistas permiten identificar la posición proyectada del sensor ultrasónico, la pantalla OLED, el servomotor y la ruta del cableado, mostrando una distribución más limpia, compacta y profesional en comparación con el prototipo físico. Gracias a ello, se facilita la comprensión espacial del diseño final y se evidencian las mejoras previstas respecto al modelo MVP.




Ilustración 25 Modelado en tres posiciones.

Es importante destacar que existen diferencias significativas entre el prototipo físico y el render 3D. Mientras que el prototipo se construyó con materiales accesibles y técnicas manuales debido a limitaciones de recursos, el render propone una versión optimizada: superficies más uniformes, un chasis rediseñado para una integración más eficiente de los módulos, una estructura interna más estable y acabados visuales propios de un producto final manufacturable. Estas modificaciones buscan reflejar de forma fiel la intención del diseño original, pero elevando su presentación a un estándar adecuado para producción.



Ilustración 26 Modelo 3D finalizado versión manufacturable.

La Ilustración 26 muestra la apariencia final del producto, destacando los acabados uniformes y la integración de los componentes externos. Para complementar esta visión, la Ilustración 28 presenta una vista del modelo. Esta vista interna es esencial para la evaluación técnica, ya que confirma las dimensiones internas, la gestión de espacio y la estabilidad estructural necesaria para la manufactura en serie, demostrando la asignación precisa del volumen para cada módulo.




Ilustración 27 Visión interna del modelo 3D.

En base a lo anterior presentado el render 3D no busca replicar el prototipo artesanal, sino representar la versión final deseada del dispositivo, utilizando materiales adecuados, una estructura interna optimizada y un acabado estético propio de un producto comercial. Mientras el prototipo MVP demuestra la funcionalidad básica del sistema, el render comunica de forma clara la visión final del proyecto, facilitando su evaluación técnica, apoyando la toma de decisiones y proyectando las mejoras previstas para una futura manufactura. En otras palabras, el modelo tridimensional funciona como una herramienta esencial para mostrar el potencial del proyecto más allá del prototipo inicial, evidenciando cómo podría evolucionar hacia una versión completamente manufacturable y lista para su implementación real.

Capítulo 5

Pruebas y resultados

En este capítulo se presentan las pruebas realizadas tanto al sistema embebido (hardware) como al servidor y al modelo de inteligencia artificial desarrollado (software), así como los resultados obtenidos de su evaluación. El objetivo principal es validar el funcionamiento individual de cada uno de los módulos que conforman el sistema. En el apartado de hardware, esto incluye el servomotor, el sensor ultrasónico, la pantalla OLED y la cámara ESP32-S3; mientras que en el apartado de software se busca comprobar el funcionamiento general del servidor, las rutas implementadas, el backend principal de la aplicación y el desempeño del modelo de inteligencia artificial, basándose en las métricas obtenidas durante las pruebas.

Para lograrlo, el capítulo se estructura en cuatro partes.

- En primer lugar, se describen las pruebas diseñadas y ejecutadas para evaluar la precisión, estabilidad, confiabilidad y tiempos de respuesta de cada módulo, tanto a nivel de hardware como de software (Sección 5.1).
- En segundo lugar, se presentan los datos obtenidos junto con un análisis crítico que permite identificar comportamientos relevantes del sistema (Sección 5.2).
- En tercer lugar, se examina el funcionamiento en tiempo real del prototipo, verificando la integración dinámica de todos los componentes durante su operación (Sección 5.3).
- Finalmente, se exponen las conclusiones generales sobre el rendimiento global, el grado de cumplimiento de los requisitos funcionales establecidos al inicio del proyecto y las limitaciones encontradas durante las pruebas (Sección 5.4).

Este conjunto de evaluaciones permite determinar de manera objetiva si el sistema propuesto cumple con los objetivos funcionales y operativos definidos en las etapas iniciales del proyecto, los cuales abarcan áreas como diseño electrónico, diseño mecánico, arquitectura del servidor, estructura del modelo de IA e integración completa del sistema. Además, los resultados obtenidos permiten valorar si el prototipo es adecuado para su aplicación final y para su posterior entrega como producto funcional dentro del alcance planteado.

5.1 Explicación de pruebas realizadas

Con el fin de validar el desempeño total del sistema propuesto, se diseñaron y ejecutaron diversas pruebas destinadas a evaluar tanto los componentes de hardware que conforman el sistema embebido como los elementos de software. Estas pruebas permiten identificar el nivel de precisión, estabilidad, eficiencia y confiabilidad de cada componente.

5.1.1 Pruebas Unitarias por Módulo: Hardware

Las pruebas de hardware se enfocaron en confirmar que los módulos físicos del sistema embebido operaran correctamente de manera individual. Los componentes evaluados incluyen **el servomotor, el sensor ultrasónico, la pantalla OLED y la cámara ESP32-S3.**

Servomotor

Se realizaron pruebas de movilidad para validar la precisión y repetibilidad del movimiento. El servomotor fue programado para desplazarse entre diversos ángulos predeterminados (0°, 100° y 180°), verificando que alcanzara la posición indicada, que se mantuviera estable y que respondiera dentro de un tiempo aceptable.

Sensor Ultrasónico

El sensor fue evaluado para determinar su precisión al medir distancias. Se posicionó un objeto a distancias conocidas y fijas, repitiendo mediciones para obtener un promedio y valorar tanto el error absoluto como la variación entre lecturas consecutivas.

Pantalla OLED

Se evaluó su capacidad para mostrar información en tiempo real proveniente del microcontrolador. Las pruebas consistieron en mostrar datos dinámicos y la consistencia de la información procesada. También se evaluó si existían parpadeos, retrasos visibles o cuelgues durante la operación continua.

Cámara ESP32-S3 CAM

Se realizaron pruebas de captura y transmisión de imágenes. Se evaluó su latencia y el tiempo requerido para enviar los datos a través de Wi-Fi hacia el servidor. Además, se probaron configuraciones de parámetros que modificaban el comportamiento del sensor de iluminación para lograr el mejor desempeño del sensor óptico.

5.1.2 Pruebas Unitarias por Módulo: Software

Por la parte del software, se evaluaron tres elementos críticos: el servidor, las rutas API implementadas y el modelo de inteligencia artificial reentrenado para la clasificación correspondiente. El propósito fue asegurar que el sistema de software funcionara de manera estable, rápida y precisa.

Servidor y Arquitectura Backend

Se realizaron pruebas para verificar la correcta inicialización del servidor, la estabilidad durante periodos de operación continua y la capacidad para recibir, procesar y almacenar información enviada desde el microcontrolador. También se evaluaron los tiempos de respuesta del servidor.

Pruebas de Rutas (API REST)

Se validaron las rutas diseñadas para recibir imágenes, procesarlas, enviarlas al modelo de IA, devolver una predicción y enviar respuestas de estado al ESP32. Las pruebas incluyeron:

- Verificación del formato correcto de los datos recibidos.
- Manejo de errores ante solicitudes incompletas o corruptas.
- Verificación de la carga dinámica con AJAX.

Estas pruebas permitieron garantizar que la comunicación entre el hardware y el software fuera estable, coherente y eficiente.

Modelo de Inteligencia Artificial

Se evaluó el desempeño de los cuatro modelos entrenados mediante métricas estándar como precisión (accuracy), matriz de confusión, recall, f1 score y curva roc. Además, se realizaron pruebas utilizando imágenes reales capturadas por la cámara del sistema embebido para asegurar que el modelo reconociera correctamente los objetos en condiciones del mundo real.

5.2 Evaluación de las pruebas realizadas

5.2.1 Prueba Hardware

Servomotor

```

#include <ESP32Servo.h>

#define SERVO_PIN 3

Servo servoMotor;

const byte angulos[2] = {0, 180};
const char comandos[2] = {'b', 'n'};
const int velocidad = 5;

void setup() {
  Serial.begin(115200);
  servoMotor.attach(SERVO_PIN);
  servoMotor.write(90);
}

void moverServoSuave(int anguloObjetivo) {
  int posicionActual = servoMotor.read();
  int incremento = (anguloObjetivo > posicionActual) ? 1 : -1;

  while (posicionActual != anguloObjetivo) {
    posicionActual += incremento;
    if ((incremento == 1 && posicionActual > anguloObjetivo) ||
        (incremento == -1 && posicionActual < anguloObjetivo)) {
      posicionActual = anguloObjetivo;
    }
    servoMotor.write(posicionActual);
    delay(velocidad);
  }
}

```

Ilustración 28 Prueba servomotor.

Prueba realizada	Parámetros evaluados	Resultado obtenido	Observaciones
Movilidad por ángulos predeterminados	0°, 100°, 180°	Movimientos completados con precisión	Sin vibraciones excesivas; operación estable
Repetibilidad de movimiento	10 cambios de rango repetitivo entre B y N, variación por ángulos	Variación máxima: $\pm 1.5^\circ$	El servomotor mantiene consistencia en posiciones repetidas
Tiempo de respuesta	Tiempo entre comando y posición final	0.18 s promedio	Dentro del rango funcional para el sistema
Estabilidad en posición	Tiempo de sostenimiento de la posición sin oscilaciones	sin desviaciones perceptibles	Adecuado para operación coordinada con otros módulos

Tabla 19 Resultados servomotor

Sensor Ultrasónico

```
#include <NewPing.h>

#define TRIG_PIN 1
#define ECHO_PIN 2
#define MAX_DISTANCE 200 // Distancia máxima a medir (en cm)

NewPing sonar(TRIG_PIN, ECHO_PIN, MAX_DISTANCE);

void setup() {
  Serial.begin(9600);
  Serial.println("Iniciando prueba del sensor ultrasónico");
  Serial.println("Mostrando lecturas de distancia...");
}

void loop() {
  static unsigned long ultimo_tiempo = 0;
  const unsigned intervalo = 500; // Intervalo entre lecturas (ms)

  if (millis() - ultimo_tiempo >= intervalo) {
    ultimo_tiempo = millis();

    // Obtener distancia en centímetros
    unsigned int distancia = sonar.ping_cm();

    // Mostrar resultado
    if (distancia == 0) {
      Serial.println("Fuera de rango");
    } else {
      Serial.print("Distancia: ");
    }
  }
}
```

Ilustración 29 Prueba sensor.

Prueba realizada	Distancia real	Lectura promedio	Error absoluto	Observaciones
Medición 1	2 cm	2.6 cm	+0.6 cm	Error pequeño, consistente
Medición 2	5 cm	5.4 cm	-0.6 cm	Ligera variación, dentro de tolerancia
Medición 3	9 cm	10.2 cm	+1.2 cm	Se mantuvo estable entre lecturas
Variación entre lecturas		±0.8 cm entre muestras		Comportamiento aceptable para detección de proximidad

Tabla 20 Resultados sensor

Pantalla OLED

```
#include <Adafruit_GFX.h>
#include <Adafruit_SSD1306.h>
#include <Wire.h>

// Definiciones para la pantalla OLED
#define SCREEN_WIDTH 128 // Ancho de la pantalla en píxeles
#define SCREEN_HEIGHT 64 // Alto de la pantalla en píxeles
#define OLED_RESET -1 // Pin de reset (se usa -1 para ESP32)

// Definir los pines de I2C para ESP32 52 Mini
#define I2C_SDA_PIN 42
#define I2C_SCL_PIN 41

Adafruit_SSD1306 display(SCREEN_WIDTH, SCREEN_HEIGHT, &Wire, OLED_RESET);

void setup() {
  Serial.begin(115200);

  // Inicializa la comunicación I2C con los pines correctos antes de la pantalla.
  Wire.begin(I2C_SDA_PIN, I2C_SCL_PIN);

  // Inicializa la pantalla OLED
  if(!display.begin(SSD1306_SWITCHCAPVCC, 0x3C)) { // Dirección I2C: 0x3C
    Serial.println(F("Error en la inicialización de la pantalla OLED"));
    for(;;); // Detiene el programa
  }

  // Limpia el buffer de la pantalla y la apaga
  display.clearDisplay();
  display.display();

  // Configura el texto a mostrar
  display.setTextSize(1); // Tamaño del texto
  display.setTextColor(SSD1306_WHITE); // Color del texto (blanco)
}
```

Ilustración 30 Prueba pantalla oled.

Prueba realizada	Parámetros evaluados	Resultado obtenido	Observaciones
Actualización en tiempo real	1–5 actualizaciones/segundo	Sin parpadeos visibles	Flujo de datos estable
Consistencia de datos mostrados	Lecturas dinámicas del microcontrolador	Información mostrada correctamente	No se observaron errores de refresco
Operación continua	30 min de funcionamiento	Sin cuelgues	Comportamiento óptimo bajo pruebas prolongadas
Legibilidad	Contraste y brillo	Correctos sin ajuste adicional	Pantalla adecuada para operación del sistema

Tabla 21 Resultados pantalla oled

Cámara ESP32-S3 CAM

```
const char* servidor = "http://192.168.0.121:5000/";
// -----
#define CAM_PIN_D0      11
#define CAM_PIN_D1      9
#define CAM_PIN_D2      8
#define CAM_PIN_D3      10
#define CAM_PIN_D4      12
#define CAM_PIN_D5      18
#define CAM_PIN_D6      17
#define CAM_PIN_D7      16

#define CAM_PIN_XCLK     15
#define CAM_PIN_PCLK     13
#define CAM_PIN_VSYNC    6

#define CAM_PIN_HREF     7
#define CAM_PIN_SDA      4
#define CAM_PIN_SCL      5

#define CAM_PIN_PWDN     -1
#define CAM_PIN_RESET    -1

// -----

/**
 * @brief Inicializa la cámara.
 */
bool init_camera() {
    camera_config_t config;
    config.ledc_channel = LEDC_CHANNEL_0;
    config.ledc_timer = LEDC_TIMER_0;

    config.pin_d0 = CAM_PIN_D0;
```

Ilustración 31 Prueba cámara.

Prueba realizada	Parámetros evaluados	Resultado obtenido	Observaciones
Captura de imagen	Resolución para el modelo de inteligencia artificial (240×240)	Imágenes nítidas	Buen desempeño en interiores
Latencia de transmisión	Tiempo desde captura hasta recepción	220–310 ms	Aceptable para el sistema
Envío vía Wi-Fi	Estabilidad de enlace	Conexión sostenida sin interrupciones	Buen rendimiento a 2.4 GHz
Ajuste de exposición e iluminación	ajustes manuales aplicados al sensor: saturación = 0, brillo = –2, contraste = 1.	Mejoró claridad en condiciones de baja luz	La cámara se adapta bien a variaciones ambientales

Tabla 22 Resultados cámara

5.2.2 Pruebas del Servidor y Arquitectura Backend

Prueba de Inicialización del Servidor

Prueba realizada:

Se arrancó el servidor desde un entorno local usando Flask server

Se monitoreó la correcta carga de dependencias, inicialización de variables de entorno y activación del puerto definido.

Se verificó mediante herramientas que el servidor respondiera en la ruta base (/index).

Resultado:

El servidor se inicia sin errores, haciéndolo disponibilidad de forma inmediata.

Pruebas de Estabilidad en Operación Continua

Prueba realizada:

El servidor se dejó activo por 4 horas mientras recibía peticiones periódicas.

Se usó un script automatizado que enviaba solicitudes POST, simulando la actividad real del microcontrolador.

Resultado:

Durante las pruebas de estabilidad se observó un incremento moderado en el uso de memoria del servidor al mantener activa la actualización dinámica en la ruta index. Este comportamiento se debe a la renovación constante de la imagen mostrada, la cual se actualizaba de forma continua durante varias horas de prueba.

Sin embargo, este aumento no representa un fallo ni afecta la funcionalidad del sistema, ya que dicho escenario no corresponde a condiciones reales de operación. En un entorno real, el flujo de imágenes no sería constante durante largos periodos, por ejemplo, no se estarían depositando residuos de manera **continua** durante 4 horas, por lo que la carga de trabajo sería significativamente menor.

Prueba de Recepción y Almacenamiento de Datos

Prueba realizada:

Desde el microcontrolador se enviaron imágenes en intervalos de 15 segundos durante 2 minutos.

El servidor almacenó cada solicitud en un diccionario de datos temporal.

Se verificó:

Integridad del archivo recibido.

Estructura correcta del JSON enviado.

Resultado:

Durante las pruebas se observó que, aunque la mayoría de las imágenes eran procesadas sin inconvenientes, existieron casos aislados en los que el servidor tardó demasiado en responder, provocando un read timeout en el cliente. Este comportamiento ocurrió aproximadamente en un 10 de cada 100 imágenes enviadas.

El origen del problema no está relacionado con fallos en el servidor, sino con latencia en la red durante el envío de datos. Aunque el servidor alcanzaba a generar una respuesta inicial ("objeto detectado"), la imagen enviada se incluía dentro de un archivo JSON con un peso considerable. Debido a este tamaño excesivo en la carga útil, la transmisión se veía afectada y, en situaciones de latencia elevada, parte del contenido se perdía o no alcanzaba a recibirse de forma completa.

5.2.3 Pruebas de Rutas (API REST)

Prueba de Recepción de Mensajes

Ruta evaluada: POST "/"

Prueba realizada:

Se capturo un frame por el microcontrolador.

Se envió una imagen en formato JPG proveniente del microcontrolador.

Se verificó que el servidor le llegara la imagen correspondiente.

Se revisó que los datos llegaran completos y que el tamaño del archivo se mantuviera conforme al original.

Resultado:

La transformación de los datos en formato bytes a una imagen dentro del servidor se realizó correctamente, conservando el mismo tamaño y calidad que la imagen enviada originalmente desde el microcontrolador. El servidor procesó la información sin alteraciones, completó la conversión y respondió de manera adecuada, devolviendo un código http 200, lo que confirma que la operación se efectuó satisfactoriamente.

Prueba De Procesamiento y Envío al Modelo de IA

Ruta evaluada: POST "/"

Prueba realizada:

El backend tomó la imagen recibida y la envió al modelo de IA.

El modelo devolvió la clasificación del objeto y el nivel de certeza.

Se verificó que la respuesta fuera consistente, que el proceso no excediera el tiempo permitido y que no se generaran errores inesperados.

Resultado:

La prueba destinada a verificar que el backend enviara la predicción dada en el formato JSON correspondiente se consideró un éxito. La predicción devuelta por el servidor coincidió con el formato esperado por el microcontrolador.

Los tiempos de respuesta se mantuvieron por debajo de los 2 segundos, lo cual es posible debido a que únicamente se envía la letra correspondiente a la clase detectada, con un tamaño aproximado de 1 byte.

Tanto en el servidor como en el cliente se implementó un manejo adecuado de excepciones, lo que permitió validar y procesar correctamente diferentes tipos de JSON recibidos.

Prueba De Carga Dinámica Del Frontend

Ruta evaluada: GET "/verificar_actualizacion"

Prueba realizada:

El microcontrolador envió una solicitud GET al servidor junto con el comando de predicción y la imagen correspondiente en formato bytes.

El backend recibió la solicitud, procesó los datos y almacenó la imagen en la carpeta asignada dentro del servidor.

Una función interna del backend actualizó el estado global del sistema, registrando la nueva información disponible para el cliente.

El frontend, mediante AJAX, ejecutó solicitudes periódicas cada 30 segundos para verificar si existía una actualización pendiente.

Cuando se detectó un cambio, la interfaz gráfica se actualizó automáticamente mostrando la nueva imagen, la clase predicha y la probabilidad asociada.

Resultado:

El servidor detectó correctamente la nueva actualización, transformó la imagen enviada desde el microcontrolador manteniendo su integridad y tamaño original, y devolvió un código HTTP 200 indicando una respuesta válida. Asimismo, el frontend recibió la actualización sin errores y reflejó de inmediato los nuevos datos gracias al mecanismo de sondeo implementado con AJAX. Esto confirma que el flujo de comunicación backend–frontend funciona de manera estable, eficiente y coherente.

Prueba de Renderizado del Estado del Sistema

Ruta evaluada: GET “/index”

Prueba realizada:

Se accedió a la ruta /index desde el navegador con el sistema recién iniciado, sin que el microcontrolador hubiera enviado aún una predicción.

El servidor evaluó el estado de la variable `alpha.diccionarioIdentificacion`, la cual se encontraba en `None`, indicando ausencia de datos.

Ante esta condición, el backend generó un diccionario de datos por defecto con los valores:

Clase: "Esperando detección..."

Probabilidad: 0.0

Imagen: placeholder.jpg

El servidor renderizó la plantilla `index.html` junto con la información por defecto, cargando correctamente la interfaz inicial.

Posteriormente, se realizó una prueba adicional enviando una predicción real desde el microcontrolador. Tras actualizarse `alpha.diccionarioIdentificacion`, se volvió a solicitar la ruta /index.

El servidor cargó la interfaz nuevamente, esta vez incorporando la información real enviada por el ESP32-S3 CAM (clase detectada, probabilidad e imagen asociada).

Resultado:

La ruta /index mostró un comportamiento correcto tanto en estado inicial como en estado actualizado. Cuando no existían detecciones previas, el servidor devolvió un contenido por defecto coherente y funcional. Una vez que el microcontrolador envió datos reales, la interfaz se actualizó adecuadamente con la predicción y la imagen procesada. En ambos casos, el

servidor devolvió un código HTTP 200, confirmando que el renderizado y la entrega de información al frontend operan de manera estable y sin errores.

5.2.4 Prueba Modelo de Inteligencia Artificial

Para evaluar el desempeño de los modelos de clasificación de residuos se utilizaron métricas estándar de visión computacional, incluyendo exactitud (accuracy), precisión, recall y F1-score.

Modelo	Accuracy (%)	Precisión (%)	Recall (%)	F1-Score (%)	Tamaño (MB)	Observaciones
ResNet50 Dataset masivo imágenes de stock	92.49%	93%	92.5%	92.5%	218 MB	Buen desempeño, pero baja interpretación de objetos en la vida real
MobileNetV2 Dataset crudo	72.97%	79%	73%	71.5%	18.2 MB	Buen rendimiento, pero limitado debido al conjunto de datos
MobileNetV2 Dataset fusionados	75.51%	79%	75.5%	75%	18.2 MB	Comprensión real del entorno en la vida real, pero no entiende la visión del prototipo
MobileNetV2 Dataset fusionados con técnica de dominio iterativo	82.01%	82%	82%	82%	27.4 MB	La adaptación del dominio del dataset, mejoro su desempeño real sin sacrificar el entendimiento anterior de IA

Tabla 23 Métricas de los modelos de IA.

ResNet50

ResNet50 es una arquitectura de redes neuronales convolucionales profunda que incorpora bloques residuales para facilitar el entrenamiento de modelos de gran profundidad. Su capacidad para mantener gradientes estables y extraer características de alto nivel la ha convertido en una de las arquitecturas más utilizadas en tareas de clasificación de imágenes.

En este proyecto se seleccionó ResNet50 debido a la idea errónea de que un modelo más complejo y potente necesariamente ofrecería mejores resultados. Sin embargo, las pruebas demostraron que, a pesar de su alta capacidad, el desempeño obtenido no se traduce en una utilidad real para aplicaciones prácticas.




Ilustración 32 Matriz de confusión de ResNet50.



Ilustración 33 Prueba real ResNet50.




Ilustración 34 Curva ROC de ResNet50.

Aunque ResNet50 alcanzó niveles de confianza superiores al 90% durante las pruebas, estos resultados deben interpretarse con cautela. El rendimiento observado sugiere la presencia de sesgo en el modelo, principalmente debido a dos factores:

Falta de preprocesamiento adecuado del conjunto de datos

Las imágenes utilizadas para el entrenamiento no fueron normalizadas ni sometidas a técnicas de limpieza o equilibrio. Esto provoca que el modelo aprenda patrones ruidosos o irrelevantes, lo que incrementa la probabilidad de sobreajuste.

Dependencia exclusiva de imágenes de stock

El modelo se entrenó únicamente con imágenes obtenidas de internet, las cuales presentan condiciones ideales: buena iluminación, fondos limpios y objetos bien centrados.

En consecuencia, ResNet50 desarrolla una fuerte dependencia de estas condiciones controladas, lo que limita su capacidad para generalizar en entornos reales donde las imágenes presentan variaciones en iluminación, orientación, distancias y ruido visual.

Debido a estos factores, a pesar de los altos valores de confianza, el modelo resulta poco efectivo para escenarios reales. Su uso práctico queda restringido a contextos similares a los datos de entrenamiento.

MobileNetV2 Dataset Único

MobileNetV2 es una arquitectura optimizada para dispositivos con recursos limitados, diseñada a partir de bloques “inverted residual” y convoluciones separables en profundidad. Estas características reducen significativamente el número de parámetros y el costo computacional sin sacrificar en exceso la precisión del modelo.

Fue seleccionada como candidata principal para este proyecto debido a su bajo peso, rápida capacidad de inferencia y eficiencia energética, cualidades indispensables para sistemas embebidos y otros microcontroladores con recursos reducidos.




Ilustración 35 Matriz de confusión de MobileNetV2 primera iteración.



Ilustración 36 Prueba real MobileNetV2 primera iteración.




Ilustración 37 Curva Roc MobileNetV2 primera iteración.

MobileNetV2 se considera, en teoría, el modelo ideal para sistemas embebidos debido a sus tiempos de inferencia reducidos y a la facilidad con la que se puede transferir y ejecutar en hardware

con capacidades limitadas. Sin embargo, durante esta primera iteración, su desempeño mostró limitaciones importantes derivadas principalmente del conjunto de datos utilizado:

Entrenamiento con un único dataset sin preprocesamiento adecuado

El modelo se entrenó exclusivamente con un conjunto de imágenes que no fue sometido a procesos de limpieza, balanceo o aumento de datos. Esto provoca que MobileNetV2 aprenda características inconsistentes y poco representativas, afectando directamente la calidad de la predicción.

Presencia significativa de sesgos

Debido a la falta de diversidad en el dataset y a la ausencia de técnicas de normalización o estandarización, el modelo desarrolló un sesgo marcado hacia los patrones presentes en las imágenes de entrenamiento.

A pesar de estas limitaciones, MobileNetV2 continúa siendo la arquitectura más adecuada para un despliegue en sistemas embebidos.

MobileNetV2 Fusión Dataset

En esta segunda iteración del modelo MobileNetV2 se realizó un proceso de mejora enfocado en aumentar la capacidad de generalización del sistema. Para ello, se combinaron dos conjuntos de datos provenientes de imágenes capturadas en entornos reales, con el objetivo de acercar el entrenamiento del modelo a las condiciones del prototipo físico. Esta fusión permitió diversificar los patrones visuales y reducir parte de los sesgos presentes en la primera versión del modelo, donde únicamente se utilizaba un dataset pequeño.




Ilustración 38 Matriz de confusión de MobileNetV2 segunda iteración.



Ilustración 39 Prueba real MobileNetV2 segunda iteración.




Ilustración 40 Curva Roc MobileNetV2 segunda iteración.

El desempeño del modelo MobileNetV2 en esta segunda iteración mostró una mejora considerable con respecto a la versión anterior. El método planteado hizo que el modelo adquiriera

representaciones visuales más fieles a las condiciones de trabajo del prototipo, lo cual se reflejó en métricas superiores y una reducción de sesgos durante el proceso de clasificación.

A pesar de estos avances, el modelo aún no logró identificar correctamente los objetos dentro del prototipo. Este problema se explica principalmente por las diferencias persistentes entre las imágenes del dataset y las imágenes capturadas directamente por el microcontrolador, incluyendo iluminación, resolución, ruido visual y variaciones no contempladas en el entrenamiento.

Aunque todavía incapaz de clasificar los objetos en tiempo real dentro del sistema embebido, MobileNetV2 mostró un avance notable respecto a la iteración previa y estableció una base más sólida para futuras mejoras. La siguiente etapa requerirá integrar imágenes capturadas directamente desde el prototipo para cerrar la brecha entre el entorno de entrenamiento y el entorno operativo final.

MobileNetV2 Adaptación de Dominio y Fine-Tuning

En la tercera iteración del modelo MobileNetV2 se aplicó una mejora significativa basada en técnicas de datos, utilizando como base el modelo obtenido durante la segunda interacción. El objetivo fue reducir la brecha entre las condiciones del dataset y las condiciones reales del prototipo, integrando imágenes capturadas directamente desde el sistema con el fin de adaptar el modelo al entorno operativo final.




Ilustración 41 Matriz de confusión de MobileNetV2 tercera iteración.



Ilustración 42 Prueba real MobileNetV2 tercera iteración.




Ilustración 43 Curva Roc MobileNetV2 tercera iteración.

La tercera iteración del modelo demostró un desempeño notablemente superior respecto a las versiones anteriores. La aplicación de dominio iterativo, sumado al fine-tuning sobre el modelo

previamente entrenado, permitió que MobileNetV2 adaptara sus representaciones internas a las condiciones reales capturadas por la cámara del prototipo.

Este proceso reveló un hallazgo clave: el problema principal no era la cámara ni la arquitectura del modelo, sino la calidad y pertinencia de los datos utilizados en las primeras etapas. Al incorporar imágenes reales del entorno operativo, el modelo logró comprender de manera mucho más precisa los patrones visuales reales, reduciendo drásticamente los errores de clasificación.

Los resultados obtenidos superaron incluso a modelos previos que alcanzaban más del 90% de confianza en pruebas artificiales, evidenciando que la mejora no provino de un aumento en la complejidad del modelo, sino de la correcta alineación entre los datos de entrenamiento y el dominio real.

Para finalizar esta iteración posiciona a MobileNetV2 como el modelo más adecuado y robusto para el sistema propuesto, demostrando una capacidad de adaptación destacable y un rendimiento altamente consistente bajo condiciones reales.

5.3 Prueba de prototipo en tiempo real

En este subcapítulo se expone como se ve el funcionamiento del prototipo en tiempo real, tomando imágenes del mismo en su funcionamiento real.

5.3.1 Escenario 1: Inicialización del sistema

Al energizarse el microcontrolador ESP32-S3, el flujo de ejecución ingresa a la subrutina `setup()`. Esta etapa es crítica para la integridad del sistema, ya que en ella se configuran los registros de hardware y las instancias de software necesarias para garantizar un funcionamiento estable durante el ciclo operativo.



Ilustración 44 Fase de inicialización de pantalla correcta.

El proceso inicia con la activación de la Interfaz Hombre-Máquina (HMI) a través de la inicialización de la pantalla OLED mediante el protocolo de comunicación I2C. Este componente cumple una función esencial al proporcionar retroalimentación visual en tiempo real, desplegando mensajes de confirmación que valida la operatividad.



Ilustración 45 Fase de inicialización de servomotor correcta.

Posteriormente, se realiza la configuración del servomotor, responsable de la clasificación física de los residuos. Durante esta fase, el motor se sitúa automáticamente en un ángulo de referencia neutral (100°) para garantizar que el mecanismo de selección esté alineado antes de iniciar cualquier operación. Una vez completada, el sistema notifica visualmente que está listo.



Ilustración 46 Inicialización cámara.

La inicialización del sensor de imagen requiere un intervalo de tiempo controlado. Este retardo deliberado es una medida de seguridad que previene errores de sincronización en el bus de datos y asegura que el hardware de la cámara esté listo para la transferencia de información hacia la memoria dinámica.



Ilustración 47 Fase de inicialización de cámara correcta.

Acto seguido, se ejecuta la configuración del módulo de visión ESP32-S3 CAM, donde se ajustan parámetros críticos de procesamiento de señal como el brillo, la saturación y el contraste para optimizar la captura de imágenes. El éxito de esta operación se confirma mediante una notificación específica, validando el estado del sensor.



Ilustración 48 Conectando WIFI.

Para integrar el dispositivo en una arquitectura de Internet de las Cosas (IoT), el sistema inicia la conexión a la red inalámbrica mediante el protocolo WiFi. El firmware intenta establecer el enlace con el punto de acceso predefinido, reportando en tiempo real el progreso del intento de conexión.



Ilustración 49 Fase de inicialización de WIFI correcta.

Una vez establecida la conectividad de red, se despliega en la pantalla la dirección IP asignada al dispositivo. Esta dirección constituye el identificador único dentro de la red local que permite la comunicación bidireccional mediante el protocolo HTTP con el servidor externo encargado del procesamiento de datos y la inferencia de inteligencia artificial.



Ilustración 50 Sistema inicializado correcto.

Finalmente, al concluir satisfactoriamente la validación de todos los componentes, el programa alcanza un estado de disponibilidad operativa total, indicado por el mensaje "Sistema listo". En este punto, el prototipo finaliza su fase de arranque y entra en un ciclo de vigilancia activa, utilizando el sensor ultrasónico para la detección de objetos en el área de depósito.

5.3.2 Escenario 2: Objeto detectado sin confianza suficiente



Ilustración 51 Notificación objeto detectado.

Al producirse una detección positiva por proximidad, el sistema inicia una secuencia de comunicación HTTP estructurada en dos fases. En la primera instancia, se envía una notificación en formato JSON al servidor informando sobre el evento de detección del objeto, permitiendo que la infraestructura remota se prepare para la recepción de datos.



Ilustración 52 Confianza insuficiente mensaje del servidor.

La fase final consiste en el procesamiento del resultado de clasificación devuelto por el servidor remoto. Dependiendo de si el residuo es identificado como biodegradable, no-biodegradable o si la inferencia no alcanza el umbral de confianza necesario, el sistema despliega el estatus correspondiente en la interfaz OLED para informar del análisis.

5.3.3 Escenario 3: Objeto detectado no biodegradable



Ilustración 53 Notificación objeto detectado no-bio.

En las pruebas experimentales, se utilizó un objeto catalogado como no-biodegradable para validar el sistema. El resultado de la inferencia realizada por la inteligencia artificial fue correcto, demostrando la capacidad del modelo para reconocer patrones visuales asociados a residuos inorgánicos bajo condiciones controladas.

Como consecuencia del resultado de la clasificación, el microcontrolador acciona el servomotor para desplazar el mecanismo de separación hacia la posición correspondiente al contenedor de residuos. Cabe señalar que, aunque la lógica de control es efectiva, la entrada física

del objeto está sujeta a las limitaciones del prototipo actual, diseñado para objetos de escala reducida.



Ilustración 54 Mensaje de confirmación no-bio.

Tras la ejecución del movimiento mecánico, la pantalla OLED refleja el resultado. En este caso, se confirma que la basura ha sido clasificada exitosamente como material no-biodegradable, cumpliendo con las expectativas de diseño y precisión del sistema.

5.3.4 Escenario 4: Objeto detectado biodegradable



Ilustración 55 Notificación objeto detectado bio.

Para validar la versatilidad del prototipo, se realizó una prueba adicional con un residuo biodegradable. El objeto se coloca en la posición de inferencia, activando de inmediato el protocolo de comunicación HTTP mediante la notificación de objeto identificado enviada al servidor.



Ilustración 56 Mensaje de confirmación bio.

Una vez enviada la notificación inicial, el sistema captura un frame de video que es transformado en un arreglo de bytes y transmitido al servidor. Tras el análisis de la imagen, el servidor devuelve al cliente ESP32 la etiqueta de detección correspondiente, completando el flujo de retroalimentación necesario para la toma de decisiones en tiempo real.

Finalmente, el sistema interpreta el comando de clasificación recibido y acciona el servomotor. Este movimiento del actuador, derivado de la inferencia de la imagen, garantiza que el residuo sea depositado en la sección correcta, culminando así el proceso de automatización.

5.4 Resultados finales

Los resultados obtenidos durante las pruebas permiten evaluar el nivel de cumplimiento de los requerimientos funcionales y no funcionales establecidos en las primeras etapas del proyecto. Con base en este análisis, se confirma que el sistema logró implementar de manera efectiva el flujo completo de captura, procesamiento y clasificación automatizada de residuos, cumpliendo la mayoría de los objetivos propuestos.

El sistema fue capaz de capturar imágenes automáticamente mediante la cámara ESP32-S3 CAM, integrándose adecuadamente con el microcontrolador y el servidor. Esta captura se realizó de forma estable y en tiempos adecuados para el proceso de clasificación, lo que demuestra una correcta sincronización entre los componentes de hardware y software involucrados en el prototipo.

El modelo de inteligencia artificial, especialmente en su tercera iteración con MobileNetV2, mostró un avance significativo en su capacidad para clasificar residuos entre orgánicos e inorgánicos en condiciones reales, acercándose a un comportamiento apto para operación en un entorno de prototipo funcional. Este progreso evidencia la importancia de la iteración del modelo, así como del ajuste de hiperparámetros y la mejora progresiva del conjunto de datos de entrenamiento.

No obstante, a pesar de presentar métricas de desempeño favorables durante las etapas de validación, el modelo aún exhibe sesgos relevantes en escenarios reales de operación. Dichos sesgos se deben principalmente a la diferencia entre los datos utilizados para el entrenamiento y las condiciones reales de adquisición de imágenes. Si bien se aplicaron técnicas de adaptación para mitigar esta discrepancia, los resultados indican que estas no son suficientes por sí solas. Para lograr una mayor robustez y generalización, es necesario contar con datos reales y representativos capturados directamente por la cámara empleada en el sistema, bajo condiciones de iluminación, ángulos y fondos propios del entorno de operación. El uso de conjuntos de datos de libre acceso resulta útil en etapas iniciales de desarrollo, pero introduce limitaciones en aplicaciones prácticas.

El servidor procesó las imágenes y devolvió respuestas de manera inmediata, cumpliendo con el flujo diseñado para una clasificación continua. Asimismo, se integró correctamente un mecanismo físico controlado por el servomotor, encargado de iniciar el proceso de separación del residuo una vez obtenida la predicción del modelo. Esta integración valida la correcta comunicación entre el sistema de visión, el procesamiento de datos y la ejecución de acciones físicas.

La interfaz desarrollada permitió mostrar el estado de la clasificación en tiempo real mediante la actualización dinámica de la imagen y la información del objeto detectado, cumpliendo el requisito de ofrecer retroalimentación clara al usuario. Esto contribuye a la usabilidad del sistema y facilita su supervisión, lo cual resulta relevante para futuras aplicaciones educativas o de monitoreo.

Adicionalmente, el sistema mantuvo un bajo consumo energético al utilizar hardware compacto y eficiente, como el ESP32-S3 y el servomotor SG90. El tiempo de inferencia del servidor, considerando únicamente la predicción del modelo, se mantuvo por debajo de los 2 segundos, cumpliendo el límite establecido para garantizar un funcionamiento fluido del sistema. Este desempeño resulta adecuado para aplicaciones en tiempo casi real y confirma la viabilidad de la arquitectura propuesta.

Toda la infraestructura operó mediante una red WiFi local, permitiendo la comunicación entre el prototipo y el servidor sin necesidad de conexiones externas. Esta característica incrementa la autonomía del sistema y reduce la dependencia de servicios en la nube, lo que puede ser ventajoso en entornos con conectividad limitada. Además, se emplearon componentes económicos y fáciles de reemplazar, cumpliendo con el objetivo de accesibilidad y reduciendo las barreras de adopción tecnológica.

Cabe destacar que el principal aporte novedoso del proyecto se encuentra en la integración eficiente de componentes de bajo costo con una arquitectura de procesamiento distribuido. A diferencia de otros enfoques similares, el sistema fue desarrollado utilizando módulos basados en Arduino y hardware económico, lo que reduce significativamente los costos de implementación y facilita su replicabilidad en contextos académicos, educativos o comunitarios.

Asimismo, se implementó un servidor externo encargado de realizar la detección del modelo de inteligencia artificial de manera independiente, eliminando la necesidad de ejecutar procesos de alto consumo computacional directamente en el microcontrolador. Esta decisión de diseño no solo permitió optimizar el rendimiento del sistema, sino que también abrió la posibilidad de actualizar o sustituir el modelo de inteligencia artificial sin modificar el hardware del prototipo.

La separación de responsabilidades entre el dispositivo embebido y el servidor permitió mantener un bajo consumo energético, mejorar la escalabilidad del sistema y demostrar la viabilidad de soluciones de clasificación automatizada accesibles, modulares y orientadas a contextos con recursos limitados. Además, esta arquitectura sienta las bases para futuras ampliaciones, como la incorporación de nuevos tipos de residuos, el uso de modelos más complejos o la conexión de múltiples dispositivos a un mismo servidor.

Para finalizar, el sistema propuesto cumplió satisfactoriamente con los requerimientos funcionales y no funcionales planteados. Si bien se identificaron áreas de mejora, particularmente en relación con la variabilidad del entorno y la necesidad de ampliar y refinar los datos de entrenamiento, los resultados obtenidos validan la viabilidad del prototipo y establecen una base sólida para futuras iteraciones más robustas, eficientes y escalables.

Conclusiones

El presente trabajo abordó de manera integral el desarrollo de un sistema inteligente para la clasificación automatizada de residuos, integrando hardware embebido, un servidor backend, un modelo de inteligencia artificial y una interfaz visual de monitoreo. El enfoque se centró en la captura automática de imágenes, el procesamiento en tiempo real y la operación del sistema bajo condiciones cercanas a un entorno real, demostrando la viabilidad técnica de una solución accesible y funcional.

El proceso de desarrollo se llevó a cabo mediante ciclos iterativos que permitieron identificar limitaciones, corregir fallas y optimizar componentes tanto de hardware como de software, destacando como factor crítico la calidad y representatividad del conjunto de datos para el desempeño del modelo de inteligencia artificial. Las pruebas realizadas validaron el correcto funcionamiento del sistema en sus distintos niveles. Si bien se identificaron desafíos relacionados con la variabilidad de la iluminación, la latencia de red y la limitada generalización del modelo ante condiciones muy específicas, los resultados obtenidos confirman que el prototipo cumple con los requerimientos funcionales y no funcionales establecidos.

Además, en este proyecto se propone un diseño sencillo pero funcional, de bajo costo, pensado para su uso en entornos domésticos u oficinas, con interacción en tiempo real con un servidor web y una pantalla OLED para la visualización inmediata del estado del sistema. Esta arquitectura refuerza la accesibilidad de la solución y demuestra que es posible implementar tecnologías inteligentes sin requerir infraestructura compleja o costosa.

Más allá de los resultados técnicos, este proyecto posee un alto valor estratégico que justifica plenamente la inversión en su desarrollo y evolución. El uso de tecnologías de bajo costo, permiten la creación de sistemas viables para su implementación en múltiples contextos. Esta característica abre la posibilidad de reducir significativamente los costos asociados a la clasificación manual de residuos.

El valor del proyecto trasciende la automatización de un proceso específico, ya que democratiza el acceso a tecnologías de inteligencia artificial aplicadas a la gestión de residuos, fomenta la cultura de separación y sienta las bases para futuros sistemas. Además, puede servir como referencia para estrategias de sostenibilidad apoyadas en tecnología.

A continuación, se presentan las conclusiones individuales que detallan el crecimiento técnico y profesional derivado de la ejecución del proyecto:

Melissa Mejía

Este proyecto demostró que es posible desarrollar un sistema inteligente para la clasificación automatizada de residuos utilizando tecnologías accesibles. El prototipo cumplió con su función en condiciones controladas, a pesar de las limitaciones propias del entorno y de los datos utilizados.

El desarrollo del sistema fue especialmente retador, ya que no se contaba con amplios conocimientos en el área de mecatrónica, lo que implicó un proceso constante de aprendizaje, prueba y corrección. Sin embargo, estos desafíos permitieron fortalecer el proyecto y mejorar su funcionamiento.

Más allá de lo técnico, esta experiencia representó un crecimiento personal y académico, al integrar conocimientos de programación, inteligencia artificial y hardware, sentando una base sólida para futuros proyectos y posibles aplicaciones en contextos reales.

Iván Pérez

El desarrollo del contenedor inteligente para la clasificación de residuos mediante inteligencia artificial representó una experiencia integral que combinó conocimientos de software, hardware y metodologías de trabajo colaborativo. A lo largo del proyecto se comprobó que la aplicación de tecnologías emergentes, como la visión por computadora y el aprendizaje profundo, puede trasladarse de entornos industriales complejos a soluciones accesibles y de bajo costo, con potencial de impacto a nivel local y comunitario.

Francisco Alvarado

Este trabajo representó un hito en mi formación profesional, impulsando un crecimiento sustancial en áreas críticas como la Ciencia de Datos, la Inteligencia Artificial y el despliegue de aplicaciones web en entornos de producción (DevOps). Fue necesario profundizar en tecnologías específicas, incluyendo el desarrollo frontend, la configuración de proxys inversos, la gestión de comunicaciones cliente-servidor y el manejo de peticiones en tiempo real. La complejidad de orquestar el modelo de IA, el servidor backend y el hardware embebido demandó un enfoque estructurado y sistémico para la resolución de problemas. El resultado final no solo valida la viabilidad técnica del sistema, sino que consolida mi perfil como ingeniero capaz de llevar una solución desde su etapa conceptual hasta una implementación funcional y estable.

Luis Soto

El presente trabajo desarrolló un sistema inteligente para la clasificación automatizada de residuos mediante el uso de hardware embebido, visión por computadora e inteligencia artificial. El prototipo demostró un funcionamiento adecuado bajo condiciones controladas, cumpliendo con los requerimientos establecidos.

A pesar de las limitaciones relacionadas con el entorno y la calidad de los datos, los resultados obtenidos validan la viabilidad de la solución y sientan una base sólida para futuras mejoras y posibles aplicaciones en contextos reales. Asimismo, la realización del proyecto del contenedor de basura con inteligencia artificial resultó una experiencia satisfactoria y enriquecedora, al permitir la aplicación práctica de los conocimientos adquiridos durante la formación profesional.

Finalmente, en el plano personal y profesional, el desarrollo de este proyecto representó un proceso de crecimiento integral, al permitir la interacción con áreas como redes neuronales, diseño de hardware, optimización de software y pruebas experimentales. Esta experiencia fortaleció habilidades de análisis, resolución de problemas y pensamiento sistémico, consolidando una base sólida para futuros proyectos tecnológicos.

En conjunto, este trabajo no solo demuestra la viabilidad de un sistema inteligente de clasificación de residuos, sino que constituye una aportación concreta a la transformación digital y ambiental, ofreciendo una base robusta para su mejora, escalamiento y aplicación en contextos reales, tanto en México como en otros países con problemáticas similares.

Glosario

A

Actuadores: Dispositivos que reciben señales eléctricas y las convierten en acciones físicas, como movimiento, luz o sonido. Ejemplos comunes son motores, relés y servomotores.

Arduino: Plataforma de hardware y software de código abierto basada en microcontroladores, ampliamente utilizada en prototipado electrónico y proyectos educativos por su facilidad de uso y amplia comunidad de desarrollo.

Arquitectura del software: Diseño estructural de un sistema de software que define la organización de los módulos, la interacción entre ellos y los principios que guían su desarrollo, garantizando escalabilidad y mantenibilidad.

Aprendizaje Automático (Machine Learning): Rama de la IA que permite a las máquinas aprender patrones a partir de datos y mejorar su desempeño en una tarea sin ser programadas explícitamente para cada caso.

Aprendizaje Profundo (Deep Learning): Subcampo del aprendizaje automático basado en redes neuronales artificiales con múltiples capas, que permite resolver tareas complejas como la visión por computadora o el reconocimiento de voz.

Automatización: Uso de tecnologías que permiten ejecutar procesos sin intervención humana directa, con el fin de mejorar la eficiencia y reducir errores.

API / APIs: Conjunto de funciones y protocolos que permiten que diferentes aplicaciones se comuniquen entre sí.

API RESTful / REST: Estilo de arquitectura para diseñar APIs que usan HTTP y principios como recursos, métodos (GET, POST, PUT, DELETE) y respuestas en formatos como JSON.

Arquitectura cliente-servidor: Modelo en el que un cliente solicita servicios o recursos y un servidor los provee.

Arquitectura de software distribuida: Sistema en el que múltiples componentes de software se ejecutan en diferentes máquinas y colaboran entre sí.

B

Basura: Material desechado después de haber cumplido su función principal, que puede clasificarse como orgánico o inorgánico.

Backlog: Lista priorizada de tareas, requisitos o funcionalidades pendientes en un proyecto

BID Banco Interamericano de Desarrollo: Organismo financiero internacional que

apoya proyectos de desarrollo económico y social en América Latina y el Caribe.

C

Clasificación de residuos: Proceso de separar los desechos en diferentes categorías (orgánico, plástico, papel, metal, vidrio, entre otros) para su adecuado reciclaje o disposición final.

Clasificación automática: Proceso mediante el cual un sistema asigna categorías o etiquetas a datos de manera autónoma.

Contaminación cruzada: Mezcla de materiales o residuos incompatibles que dificulta su reciclaje o tratamiento.

CNN Convolutional Neural Network (Red Neuronal Convolucional): Tipo de red neuronal profunda especializada en procesar datos en forma de imágenes, extrayendo características visuales como bordes, texturas y formas para tareas de clasificación o detección.

CPU Central Processing Unit (Unidad Central de Procesamiento): Componente principal de un sistema de cómputo encargado de ejecutar instrucciones y procesar datos.

Camel Case: Cada palabra comienza con mayúscula, excepto la primera palabra.

D

Dataset (Conjunto de Datos): Colección estructurada de datos utilizada para entrenar, validar o probar algoritmos de

aprendizaje automático e inteligencia artificial.

Dataset WasteNet: Conjunto de datos desarrollado por Recycleye que reúne más de 2.5 millones de imágenes de residuos en condiciones reales de reciclaje, considerado uno de los más grandes y completos en este campo.

Dispositivos Edge Computing: Equipos diseñados para procesar datos cerca de la fuente de generación (como cámaras o sensores), reduciendo la necesidad de enviar toda la información a servidores remotos. Mejoran la latencia y optimizan el uso de la red.

E

Economía Circular: Modelo económico que busca minimizar residuos y aprovechar al máximo los recursos a través de la reutilización, reciclaje y reducción de desechos.

ESP32-S3 CAM: Variante del ESP32 que incluye una cámara integrada, lo que permite capturar imágenes o video y transmitirlos para su procesamiento.

Edge Computing: Paradigma que procesa datos cerca de donde se generan (en el “borde” de la red), reduciendo latencia y carga en servidores centrales.

Escalabilidad: Capacidad de un sistema para manejar un mayor volumen de trabajo o usuarios sin perder rendimiento.

H

Hardware: Conjunto de componentes físicos y tangibles de un sistema informático, como procesadores, placas electrónicas, sensores y dispositivos de almacenamiento.

HTTP: Protocolo de comunicación que permite la transferencia de información en la web.

I

ImageNet: Dataset de referencia en visión por computadora que contiene más de 14 millones de imágenes etiquetadas en más de 20 000 categorías. Ha sido utilizado ampliamente en el entrenamiento y evaluación de modelos de aprendizaje profundo.

Inferencia: En inteligencia artificial, es el proceso de aplicar un modelo entrenado para obtener predicciones o clasificaciones sobre nuevos datos.

I2C: Inter-Integrated Circuit. Protocolo de comunicación serial utilizado para la conexión de múltiples dispositivos electrónicos mediante dos líneas de comunicación.

J

JSON: Formato ligero de intercambio de datos basado en texto, fácil de leer para humanos y procesar por máquinas.

M

Microcontrolador: Dispositivo electrónico programable que integra en un solo chip una unidad de procesamiento, memoria y

puertos de entrada/salida. Se utiliza para controlar sistemas embebidos y ejecutar tareas específicas de automatización.

MobileNetV2: Arquitectura de red neuronal ligera optimizada para dispositivos móviles y sistemas embebidos. Utiliza capas de convolución separables en profundidad para reducir el consumo de memoria y mantener una alta precisión.

Modelo preentrenado: Modelo de IA que ya fue entrenado con grandes cantidades de datos y puede reutilizarse o ajustarse para tareas específicas.

P

Pantalla TFT ILI9341: Pantalla gráfica que se conecta a microcontroladores como el ESP32-S3 CAM, utilizada para mostrar información visual o textual en proyectos embebidos.

Pipeline / Pipeline de procesamiento: Secuencia de pasos o módulos que procesan datos de manera ordenada, desde la entrada hasta la salida.

Product Owner: Rol en Scrum responsable de definir y priorizar el backlog, asegurando que el producto cumpla las necesidades del cliente.

R

Red Neuronal Convolutiva (CNN): Tipo de red neuronal utilizada principalmente en el procesamiento y clasificación de imágenes, capaz de extraer

características visuales como bordes, texturas y formas.

Red neuronal profunda: Modelo de IA compuesto por múltiples capas de neuronas artificiales, capaz de aprender representaciones complejas de datos.

Residuos sólidos urbanos (RSU): Basura generada en hogares, comercios y oficinas (ej. restos de comida, envases, papel).

Residuos inorgánicos: Desechos no biodegradables, como plásticos, vidrios, metales o empaques, que requieren procesos industriales para su reciclaje.

Residuos orgánicos: Desechos de origen biológico, principalmente restos de comida o materiales biodegradables.

ROC Receiver Operating Characteristic: Herramienta gráfica utilizada para evaluar el desempeño de modelos de clasificación mediante la relación entre la tasa de verdaderos positivos y falsos positivos.

S

Sensor ultrasónico: Dispositivo que mide distancias mediante la emisión y recepción de ondas sonoras de alta frecuencia. Se usa comúnmente en robótica y sistemas de detección de objetos.

Sensores: Dispositivos capaces de captar variaciones físicas o químicas del entorno (como luz, temperatura, movimiento o proximidad) y transformarlas en señales

eléctricas procesables por un sistema electrónico.

Servidor Flask: Framework minimalista de Python para el desarrollo de aplicaciones web, que en este proyecto se utiliza para recibir imágenes, procesarlas con IA y devolver los resultados de la clasificación.

Servomotor: Motores eléctricos que permiten controlar con precisión la posición, velocidad y aceleración de un eje, gracias a un sistema de realimentación interna. Son esenciales en robótica y automatización.

Software: Conjunto de programas, instrucciones y datos que permiten al hardware ejecutar tareas específicas, desde sistemas operativos hasta aplicaciones de usuario.

Scrum Master: Rol que facilita el proceso Scrum, elimina obstáculos y asegura que el equipo siga las prácticas ágiles.

Sistema embebido: Dispositivo electrónico con hardware y software diseñados para realizar funciones específicas (ej. microcontroladores en electrodomésticos).

Sprint: Periodo corto y definido (generalmente 2-4 semanas) en el que un equipo desarrolla un conjunto de tareas o funcionalidades.

Snake Case: Es un estilo de escritura en el que las palabras se separan por guiones bajos (_). En este estilo, todas las

letras son minúsculas y las palabras son fácilmente distinguibles.

T

TensorFlow: Biblioteca de código abierto desarrollada por Google, utilizada para crear y entrenar modelos de aprendizaje automático y profundo.

Transfer Learning (Aprendizaje por Transferencia): Técnica de entrenamiento en IA que aprovecha modelos previamente entrenados en grandes bases de datos y los adapta a un nuevo problema con menos recursos.

TrashNet: Dataset de imágenes creado en 2016 que contiene fotografías de distintos tipos de residuos (plástico, papel, metal, vidrio, cartón y desechos generales). Se utiliza ampliamente para entrenar modelos de clasificación automática de basura mediante visión por computadora.

V

Visión por Computadora: Área de la inteligencia artificial que permite a los sistemas interpretar y procesar información visual proveniente de imágenes o videos.

Capítulo 6

Referencias

- [1] INFOTEC Centro de Investigación e Innovación en Tecnologías de la Información y Comunicación, «Filosofía.» [En línea]. Available: https://www.infotec.mx/es_mx/Infotec/Filosofia. [Último acceso: 2025].
- [2] PortalAmbiental, «Tomra presentará soluciones para la industria mexicana del reciclaje en Residuos,» 20 Febrero 2025. [En línea]. Available: <https://www.portalambiental.com.mx/empresas/20230220/tomra-presentara-soluciones-para-la-industria-mexicana-del-reciclaje-en-residuos>. [Último acceso: 2025].
- [3] J. M. Sánchez Yáñez y L. Márquez Benavides, «Gestión de residuos sólidos y la inteligencia artificial en el contexto mexicano,» Ciencia Nicolaita, 2024. [En línea]. Available: <https://www.cic.cn.umich.mx/cn/article/view/722#:~:text=En%20M%C3%A9xico%20la%20gesti%C3%B3n%20de,La>. [Último acceso: 2025].
- [4] A. A. Salazar Nava, M. A. Dominguez Sanchez , F. A. Hernandez Cadena, F. A. Saavedra Violante, M. M. Maldonado Juarez y L. E. Alanis Carranza, «Algoritmo para la clasificación de residuos reciclables utilizando redes neuronales convolucionales,» 2024. [En línea]. Available: https://virtual.cuautitlan.unam.mx/intar/memoriasceiaait/wp-content/uploads/sites/19/2024/12/101-Algoritmo-para-la-clasificacion-de-residuos-__reciclables-utilizando-redes-neuronales-__convolucionales-EDITADO.pdf#:~:text=de%20otros%20autores%20con%20proye. [Último acceso: 2025].
- [5] L. E. Alanís Carranza , A. I. Altamirano Arroyo, E. R. Jiménez Hernández, I. D. Plasencia Gonzáles , J. A. Fuentes Luna, I. A. Pérez Luna y E. Sánchez Hernández, «DETECCIÓN Y CLASIFICACIÓN DE DESPERDICIOS HUMANOS A TRAVÉS DE YOLOV8 Y UNA CÁMARA WEB,» 25 Septiembre 2023. [En línea]. Available: <https://pistaseducativas.celaya.tecnm.mx/index.php/pistas/article/view/3123/2525>. [Último acceso: 2025].
- [6] R. Robledo, «Gana premio en NL estudiante del Tec con robot para basura con IA,» 13 Agosto 2024. [En línea]. Available: <https://www.jornada.com.mx/noticia/2024/08/13/estados/gana-premio-en-nl-estudiante-del-tec-con-robot-para-basura-con-ia-5070#:~:text=Monterrey%20%20NL,inteligente%20que%20utiliza%20Inteligencia%20Artificial>. [Último acceso: 2025].
- [7] Greentology, «México lidera con 4 startups en GreenTech Latam 2025,» greentology.life, 20 Noviembre 2025. [En línea]. Available: <https://greentology.life/scifitology/mexico-lidera-con-4-startups-en-greentech-latam-2025#:~:text=Finalmente%20%20SIR%20Soluciones%20Ambientales%20aborda,forma%20terminar%C3%ADan%20en%20rellenos%20sanitarios>. [Último acceso: Noviembre 2025].
- [8] H. G. Ramírez Escamilla y M. C. Martínez Rodríguez, «El papel de la tecnología para la gestión integral de residuos textiles en México,» Instituto Politécnico Nacional, 15 Noviembre 2023. [En línea]. Available: https://www.scielo.org.mx/scielo.php?pid=S2448-57052025000300149&script=sci_arttext#:~:text=Edge%20computing%20Implica%20procesar%20datos,informaci%C3%B3n%20de%20robo%20o%20alteraciones. [Último acceso: Noviembre 2025].

- [9] G. White, C. Cabrera, A. Palade, F. Li y C. Siobh'an, «WasteNet: Waste Classification at the Edge for Smart Bins,» Trinity College Dublin, Junio 2021. [En línea]. Available: https://www.researchgate.net/publication/342093739_WasteNet_Waste_Classification_at_the_Edge_for_Smart_Bins. [Último acceso: Noviembre 2025].
- [10] TRBL Services, «Sistemas embebidos y sus características | Conceptos fundamentales,» Tech Tribalyte, 1 Agosto 2021. [En línea]. Available: <https://trbl-services.eu/blog-sistema-embebido-caracteristicas/#:~:text=Un%20sistema%20embebido%20,reducido%20en%20el%20mismo%20chip>. [Último acceso: Noviembre 2025].
- [11] CPI (Control Para la Industria), «¿Qué es un Sensor de Proximidad Industrial?,» CPI (Control Para la Industria), 14 Abril 2025. [En línea]. Available: <https://cpi.com.ar/blogs/articulos/sensores-de-proximidad>. [Último acceso: Noviembre 2025].
- [12] Wenglor, «Funcionamiento y tecnología de un sensor de ultrasonidos,» Wenglor, [En línea]. Available: <https://www.wenglor.com/es/Principio-de-funcionamiento-y-tecnologia-de-un-sensor-de-ultrasonidos/s/Funktionsprinzip+und+Technologie+eines+Ultraschall-Sensors?BranchenundIndustrienlinks=%3A1&BranchenundIndustrienrechts=%3A1>. [Último acceso: Noviembre 2025].
- [13] ScienceDirect, «Sensors and Actuators – an overview,» ScienceDirect, 2022. [En línea]. Available: <https://www.sciencedirect.com/topics/computer-science/sensors-and-actuator>. [Último acceso: Noviembre 2025].
- [14] AdvancedMotionControls, «Qué es un servomotor: Definición, orígenes, componentes, tipos y aplicaciones,» AdvancedMotionControls, 30 Mayo 2025. [En línea]. Available: <https://www.a-m-c.com/es/servomotor/#:~:text=Un%20servomotor%20es%20un%20motor,preciso%20y%20un%20movimiento%20suave>. [Último acceso: Noviembre 2025].
- [15] Panox Display, «¿Cuáles son las ventajas y aplicaciones de OLED Displays?,» Panox Display, 11 Agosto 2025. [En línea]. Available: <https://www.panoxdisplay.com/es/solution/advantages-and-applications-of-oled-displays/>. [Último acceso: Noviembre 2025].
- [16] Gobierno de España (PRTR), «Qué es la Inteligencia Artificial,» Gobierno de España (PRTR), 19 Abril 2023. [En línea]. Available: <https://planderecuperacion.gob.es/noticias/que-es-inteligencia-artificial-ia-prtr#:~:text=La%20inteligencia%20artificial%20,el%20razonamiento%20y%20la%20percepci%C3%B3n>. [Último acceso: Noviembre 2025].
- [17] Gendy, W. y Patel, D., «Advancements in Computer Vision: A Comprehensive Survey of Image Processing and Interdisciplinary Applications,» drpress, 2024. [En línea]. Available: <https://drpress.org/ojs/index.php/ajst/article/view/27303#:~:text=interpreting%20images%20and%20videos%2C%20extracting,for%20enhancing%20image%20quality%20and>. [Último acceso: Noviembre 2025].
- [18] R. J. Casas Miranda, I. Crispín Sánchez, M. R. Cabana Cáceres, J. S. Nolasco Valenzuela y L. E. Nolasco Valenzuela, «Clasificación de imágenes con redes neuronales mejora el comportamiento del consumidor en estudiantes universitarios,» Universidad Nacional Federico Villarrea, 30 Septiembre 2025. [En línea]. Available: https://ve.scielo.org/scielo.php?script=sci_arttext&pid=S2739-00632026000202093#:~:text=Por%20otro%20lado%2C%20Kumar%20et,CNNs%2C%20pueden%20mejorar%20la%20precisi%C3%B3n. [Último acceso: Noviembre 2025].

- [19] MinTIC (iMaster Academy), «API REST,» MinTIC (iMaster Academy),, 2022. [En línea]. Available: https://imaster.academy/contenidos-tematicos/2022/ciclo4/Programacion/Ciclo%204A/Semana_4/02_API_Rest.pdf. [Último acceso: Noviembre 2025].
- [20] SEMANART, «Residuos Sólidos Urbanos y de Manejo Especial,» gob.mx, 1 Marzo 2017. [En línea]. Available: <https://www.gob.mx/semarnat/acciones-y-programas/residuos-solidos-urbanos-y-de-manejo-especial>. [Último acceso: 2025].
- [21] ONU, «Objetivos y metas de desarrollo sostenible,» Naciones Unidas, [En línea]. Available: <https://www.un.org/sustainabledevelopment/es/sustainable-development-goals/>. [Último acceso: 2025].
- [22] SEDEMA, «CDMX arranca la campaña “Transforma tu ciudad, cada residuo en su lugar”,» SEDEMA, 30 Noviembre 2025. [En línea]. Available: <https://www.sedema.cdmx.gob.mx/comunicacion/nota/cdmx-arranca-la-campana-transforma-tu-ciudad-cada-residuo-en-su-lugar>. [Último acceso: Diciembre 2025].
- [23] Cámara de Diputados, «LEY GENERAL PARA LA PREVENCIÓN Y GESTIÓN INTEGRAL DE LOS RESIDUOS,» Cámara de Diputados, 8 Mayo 2023. [En línea]. Available: <https://www.diputados.gob.mx/LeyesBiblio/pdf/LGPGIR.pdf>. [Último acceso: Diciembre 2025].
- [24] SEDEMA, «Instalan el Órgano de Gobierno de la Agencia de Gestión Integral de Residuos de la Ciudad de México,» SEDEMA, 9 Octubre 2025. [En línea]. Available: <https://www.sedema.cdmx.gob.mx/comunicacion/nota/instalan-el-organo-de-gobierno-de-la-agencia-de-gestion-integral-de-residuos-de-la-ciudad-de-mexico>. [Último acceso: Diciembre 2025].
- [25] G. A. Rocío, «Separación de residuos será obligatoria en la CDMX a partir del 1° de enero de 2026,» Jornada, 29 Enero 2026. [En línea]. Available: <https://www.jornada.com.mx/noticia/2025/10/08/capital/separacion-de-residuos-sera-obligatoria-en-la-cdmx-a-partir-del-1-de-enero-de-2026>. [Último acceso: Enero 2026].
- [26] SEDEMA, «Aclara tus dudas sobre la correcta separación de residuos en la Ciudad de México,» SEDEMA, 3 Enero 2026. [En línea]. Available: <https://sedema.cdmx.gob.mx/comunicacion/nota/dudas-sobre-separacion-de-residuos>. [Último acceso: Enero 2026].
- [27] R. T. Nicaretta y M. F. Sangines Uriarte Mendez, «El futuro del presupuesto por resultados en países en desarrollo: La importancia de simplificar,» 13 Diciembre 2022. [En línea]. Available: <https://www.iadb.org/es/blog/modernizacion-del-estado/gestion-fiscal/el-futuro-del-presupuesto-por-resultados-en-paises-en-desarrollo-la-importancia-de-simplificar>. [Último acceso: 2025].
- [28] Jefatura De Gobierno, «Instala Clara Brugada Órgano de Gobierno de la Agencia de Gestión Integral de Residuos, y anuncia campaña “Transforma tu Ciudad, cada basura en su lugar”,» jefaturadegobierno.cdmx.gob.mx, 8 Octubre 2025. [En línea]. Available: <https://jefaturadegobierno.cdmx.gob.mx/comunicacion/nota/instala-clara-brugada-organo-de-gobierno-de-la-agencia-de-gestion-integral-de-residuos-y-anuncia-campana-transforma-tu-ciudad-cada-basura-en-su-lugar>. [Último acceso: 2025].
- [29] AMCS Vision AI, «Detección de contaminación y sobrellenado mediante IA,» amcsgroup, Abril 2022. [En línea]. Available: <https://www.amcsgroup.com/es/soluciones/amcs-vision-ai/>. [Último acceso: 2025].
- [30] recycleye, «La IA y el reconocimiento de residuos: por qué funciona tan bien,» recycleye, 2024. [En línea]. Available: <https://recycleye.com/es/la-ia-y-el-reconocimiento-de-residuos/>. [Último acceso: 2025].

- [31] endesa, «¿Cómo la Inteligencia Artificial facilita el reciclaje?», endesa, 22 Abril 2024. [En línea]. Available: <https://www.endesa.com/es/la-cara-e/eficiencia-energetica/inteligencia-artificial-facilita-reciclaje>. [Último acceso: Diciembre 2025].
- [32] A. Lakhout, «Revolutionizing urban solid waste management with AI and IoT: A review of smart solutions for waste collection, sorting, and recycling», ScienceDirect, 11 Enero 2025. [En línea]. Available: https://www.sciencedirect.com/science/article/pii/S2590123025001069?utm_source=chatgpt.com. [Último acceso: Diciembre 2025].
- [33] Ecoembes, «Robots de reciclaje: la revolución tecnológica para un futuro sostenible», Ecoembes, 20 Noviembre 2023. [En línea]. Available: <https://reducereutilizarecicla.org/robots-reciclaje/>. [Último acceso: 2025].
- [34] BID, «Inteligencia Artificial: Hacia una economía circular y la eficiencia en la gestión de residuos», iadb.org, 31 Octubre 2023. [En línea]. Available: <https://www.iadb.org/es/blog/agua-saneamiento-y-residuos-solidos/inteligencia-artificial-hacia-una-economia-circular-y-la-eficiencia-en-la-gestion-de-residuos>. [Último acceso: 2025].
- [35] Santander Universidades, «Metodologías de desarrollo de software: ¿qué son?», Santander, 21 Diciembre 2020. [En línea]. Available: <https://www.santanderopenacademy.com/es/blog/metodologias-desarrollo-software.html>. [Último acceso: Diciembre 2025].
- [36] D. Radigan, «Introducción a la gestión de proyectos: comparación entre metodología ágil y metodología en cascada», Atlassian, [En línea]. Available: <https://www.atlassian.com/es/agile/project-management/project-management-intro#:~:text=El%20modelo%20de%20gesti%C3%B3n%20de,con%20ciclos%20de%20feedback%20regulares>. [Último acceso: Noviembre 2025].
- [37] Universitat Carlemany, «Metodologías de desarrollo de software: tipos, características y cuándo aplicarlas», Universitat Carlemany, 25 Noviembre 2025. [En línea]. Available: <https://www.universitatcarlemany.com/actualidad/blog/metodologias-de-desarrollo-de-software/#:~:text=El%20modelo%20incremental%20de%20ingenier%C3%ADa,fase%20supone%20a%C3%B1adir%20una%20funcionalidad>. [Último acceso: Diciembre 2025].
- [38] A. M. García, «Extensión de inteligencia artificial para navegadores web», Universidad d salamanca, Julio 2023. [En línea]. Available: <https://gredos.usal.es/bitstream/handle/10366/158155/aisknet-memoria.pdf;jsessionid=A5C5DE1CC578E44723346B07C0E6BAC0?sequence=1#:~:text=Scrum%20es%20un%20marco%20de,de%20entre%20una%20y%20cuatro>. [Último acceso: Diciembre 2025].
- [39] UNIT ELECTRONICS, «MG90S Servomotor 180° / 360° con Engranajes Metálicos», UNIT ELECTRONICS, [En línea]. Available: <https://uelectronics.com/producto/mg90s-servomotor-180-360-con-engranes-metalicos/>. [Último acceso: Diciembre 2025].
- [40] UNIT ELECTRONICS, «Sensor Ultrasónico HC-SR04», UNIT ELECTRONICS, [En línea]. Available: <https://uelectronics.com/producto/sensor-ultrasonico-hc-sr04/>. [Último acceso: Diciembre 2025].
- [41] UNIT ELECTRONICS, «ESP32-S3-WROOM-1-N16R8 16MB FLASH», UNIT ELECTRONICS, [En línea]. Available: <https://uelectronics.com/producto/esp32-s3-wroom-1-n16r8-16mb-flash/>. [Último acceso: Diciembre 2025].

- [42] UNIT ELECTRONICS, «Display Oled Azul y Blanco 128×64 0.96" I2C SSD1315,» UNIT ELECTRONICS, [En línea]. Available: <https://uelectronics.com/producto/display-oled-azul-y-blanco-128x64-0-96-i2c-ssd1306/>. [Último acceso: Diciembre 2025].
- [43] UNIT ELECTRONICS, «Cámara OV2640 120°/160°/3.6mm,» UNIT ELECTRONICS, [En línea]. Available: <https://uelectronics.com/producto/camara-ov2640-120-160-3-6mm/>. [Último acceso: Diciembre 2025].